



UNIVERSIDADE DE SÃO PAULO

INSTITUTO DE CIÊNCIAS MATEMÁTICAS E
COMPUTACIONAIS - ICMC

Métodos Numéricos para Equações Diferenciais

Renan Wenzel - 11169472

Professor(a): Fabrício Simeoni de Souza

E-mail: fsimeoni@icmc.usp.br

24 de junho de 2026

Avisos

Essas notas não possuem relação com professor algum.

Qualquer erro é responsabilidade solene do autor.

Caso julgue necessário, contatar:

renan.wenzel.rw@gmail.com.

Além disso, alguns textos em itálicos são clicáveis - normalmente, afim de facilitar o encontro de um resultado, definição ou uma continuação.

Conteúdo

0	Informações da Disciplina	6
1	Aula 01 - 22 de Fevereiro, 2026	7
1.1	Motivações	7
1.2	Aproximações Numéricas das Derivadas	7
1.3	Calculando os Coeficientes	16
2	Aula 02 - 04 de Março, 2026	19
2.1	Motivações	19
2.2	Problemas de Valor de Fronteira: Estados Estacionários	19
3	Aula 03 - 09 de Março, 2026	28
3.1	Motivações	28
3.2	Sistemas Expandidos	28

3.3	Problemas Bem-Postos	32
4	Aula 04 - 11 de Março, 2026	39
4.1	Motivações	39
4.2	Equações não lineares	39
5	Aula 05 - 16 de Março, 2026	44
5.1	Motivações	44
5.2	Métodos de Ordens Maiores para o Caso Não Linear	44
5.3	Equações e Problemas Elípticos	47
6	Aula 06 - 18 de Março, 2026	51
6.1	Motivações	51
6.2	Esquema de Diferenças Centrais e Acurácia	51
7	Aula 07 - 23 de Março, 2026	58
7.1	Motivações	58
7.2	Organização de Sistemas	58
7.3	Estimativas por Diferentes Fontes	61
8	Aula 08 - 08 de Abril, 2026	65
8.1	Motivações	65
8.2	Problemas de Valores Iniciais: método de Euler	65
9	Aula 09 - 13 de Abril, 2026	76
9.1	Motivações	76
9.2	Método Geral de 1-passo	76
10	Aula 10 - 15 de Abril, 2026	85
10.1	Motivações	85
10.2	Métodos do tipo Preditor-Corretor	85
10.3	Estabilidade Absoluta	90
11	Aula 11 - 20 de Abril, 2026	93
11.1	Motivações	93
11.2	Métodos Runge-Kutta Explícitos	97

12 Aula 12 - 11 de Maio, 2026	104
12.1 Motivações	104
12.2 Métodos Multipasso	104
13 Aula 13 - 20 de Maio, 2026	110
13.1 Motivações	110
13.2 Equação do Calor: método progressivo, retrógrado e Crank-Nickolson.	110
14 Aula 14 - 25 de Maio, 2026	116
14.1 Motivações	116
14.2 Consistência e Estabilidade da Equação Parabólica	116
14.3 Exemplos de Códigos	121
15 Aula 15 - 27 de Maio, 2026	125
15.1 Motivações	125
15.2 Análise de Convergência	125
16 Aula 16 - 01 de Junho, 2026	132
16.1 Motivações	132
16.2 Alguns Comentários Sobre Equações Parabólicas	132
16.3 Problemas Multidimensionais	133
17 Aula 17 - 03 de Junho, 2026	137
17.1 Motivações	137
17.2 Problemas Multidimensionais	137
18 Aula 18 - 10 de Junho, 2026	141
18.1 Motivações	141
18.2 Equações Hiperbólicas	141
19 Aula 19 - 15 de Junho, 2026	146
19.1 Motivações	146
19.2 Introduzindo Difusão à Advecção	146
20 Aula 20 - 17 de Junho, 2026	152
20.1 Motivações	152

20.2 Domínio de Dependências	152
20.3 Acompanhamento de Características e Interpolação	154
21 Aula 21 - 22 de Junho, 2026	158
21.1 Motivações	158
21.2 Equação da Onda	158
22 Aula 22 - 24 de Junho, 2026	163
22.1 Motivações	163
22.2 Estabilidade da Equação da Onda	163
22.3 Uma Breve Menção dos Problemas não Lineares	165

0 Informações da Disciplina

1 Aula 01 - 22 de Fevereiro, 2026

1.1 Motivações

- Método das Diferenças Finitas;
- Método da Interpolação.

1.2 Aproximações Numéricas das Derivadas

O primeiro tópico a ser explorado são as aproximações finitas das derivadas de uma certa função u . Vamos considerar, daqui adiante, uma função suficientemente suave, para que possamos diferenciar $u(x)$ várias vezes, com cada uma delas sendo funções bem-definidas e limitadas em um intervalo, contendo algum ponto de interesse x . Assim, por exemplo, para aproximar $u'(\bar{x})$ por um método de aproximação por diferenças finitas, então podemos partir da definição de derivada

$$u'(\bar{x}) = \lim_{h \rightarrow 0} \frac{u(\bar{x} + h) - u(\bar{x})}{h},$$

podemos tomar como referência esse quociente, considerar um h fixo e trocar a reta tangente no ponto pela reta secante, que corresponde a uma expressão do tipo

$$u'(\bar{x}) \approx D_+ u(\bar{x}) := \frac{u(\bar{x} + h) - u(\bar{x})}{h};$$

uma outra expressão com limite igualando a u' é

$$u'(\bar{x}) \approx D_- u(\bar{x}) := \frac{u(\bar{x}) - u(\bar{x} - h)}{h},$$

que corresponde à reta secante de pontos que vêm antes do $\bar{x}$, com uma delas errando para mais e outra errando para menos, mas não são apenas essas – também nos interessa, por exemplo, a média dessas duas aproximações! Afinal, se uma erra para mais e outra para menos, faz sentido considerar o meio termo, definindo o operador

$$u'(x) \approx D_0 u(\bar{x}) := \frac{u(\bar{x} + h) - u(\bar{x} - h)}{h} = \frac{1}{2} [D_+ u(\bar{x}) + D_- u(\bar{x})].$$

Estes três operadores respectivamente levam os nomes de **operador de diferenças progressivo**, **operador de diferenças regressivo** e **operador de diferenças centrais**.




Figura 1: as inclinações vão se aproximando da tangente por baixo ou por cima de acordo com o operador escolhido!

Outras aproximações poderiam ser feitas, como uma considerando o terceiro termo de uma série expansiva, que veremos mais adiante, mas com expressão dada por

$$u'(\bar{x}) \approx D_3u(\bar{x}) := \frac{1}{6h}[2u(\bar{x} + h) + 3u(\bar{x}) - 6u(\bar{x} - h) - 2u(\bar{x} - 2h)],$$

que envolve mais avaliações da função u .

Logo, um dos nossos objetivos será ver as diferenças, vantagens e desvantagens de cada uma dessas aproximações.

Exemplo 1. Considere uma função $u(x) = \sin x$ e o ponto $\bar{x} = 1$, cuja derivada no ponto 1 é o cosseno de 1, ou seja, queremos aproximar o ponto $u'(1) = \cos(1) = 0.5403023$. A tabela abaixo mostra o erro e ordem dele de cada um dos operadores que vimos:

h	$D_+u(x)$	$D_-u(\bar{x})$	$D_0u(\bar{x})$	$D_3u(\bar{x})$
1.0e-01	-4.2939e-02	4.1138e-02	-9.0005e-04	6.8207e-05
5.0e-02	-2.1257e-02	2.0807e-02	-2.2510e-04	8.6491e-06
1.0e-03	-4.2163e-03	4.1983e-03	-9.0050e-06	6.9941e-08
5.0e-03	-2.1059e-03	2.1014e-03	-2.2513e-06	8.7540e-09
1.0e-03	-4.2083e-04	4.2065e-04	-9.0050e-08	6.0979e-11

Tabela 1: erros em cada uma das diferentes aproximações finitas de $u'(x)$.

Por meio dela, percebemos que

$$\begin{aligned}D_+u(\bar{x}) - u'(\bar{x}) &\approx -0.42h, \\D_0u(\bar{x}) - u'(\bar{x}) &\approx -0.09h^2, \text{ \&} \\D_3u(\bar{x}) - u'(\bar{x}) &\approx 0.007h^3.\end{aligned}$$

Com este exemplo, o que nos interessa é avaliar como essas formas de avaliar a derivada de formas diferentes se comportam conforme h fica menor, além de ver qual é o processo e a ordem de convergência de cada uma delas para o verdadeiro valor. O que vemos, primeiramente, é que as aproximações D_+ e D_- são bem parecidas, mas com lineais opostos; a aproximação pela média, D_0 , produziu erros bem menores tanto comparada a D_+ quanto a D_- ; mais ainda, a terceira aproximação, D_3 , ficou ainda mais precisa, com taxa de convergência mais rápida ainda!

Nós podemos fazer uma figura chamada **Teste de Convergência**, responsável por fornecer informações sobre as convergências das aproximações, que aparecerá para todos os tipos de aproximações que faremos; o **teste de convergência** em si é verificar qual é a taxa de convergência que estamos obtendo conforme h é refinada cada vez mais. Assim, se o erro $E(h)$ se comporta a uma taxa exponencial, por exemplo $E(h) \approx C \cdot h^p$, então $\log |E(h)| \approx \log |C| + p \log |h|$, que traduz o gráfico outrora exponencial em um linear, facilitando as leituras que teremos; em relação às propriedades, para $0 < h_2 < h_1$ aproximações suficientemente pequenas, esperamos que, por essa definição, $E(h_1) \approx Ch_1^p$ e $E(h_2) \approx Ch_2^p$, de modo que

$$\log \frac{|E(h_1)|}{|E(h_2)|} \approx \log \frac{|C|h_1^p}{|C|h_2^p} = \log \left(\frac{h_1}{h_2} \right)^p = p \log \frac{h_1}{h_2},$$

ou seja, a ordem de convergência pode ser estimada por meio de

$$p \approx \frac{\log \left(\frac{|E(h_1)|}{|E(h_2)|} \right)}{\log \left(\frac{h_1}{h_2} \right)}.$$




Figura 2: cada uma das linhas corresponde a um diferente valor da ordem de convergência p ; aqui, a mais de cima seria o valor $p = 1$, seguido de $p = 2$ e $p = 3$.

Outro conceito importante de ser lembrado é a expansão de Taylor: se $f \in C^n([a, b])$ e existe a derivada $f^{(n+1)}$ no intervalo (a, b) , então para quaisquer pontos c e x dentro do intervalo $[a, b]$, vale a expressão

$$f(x) = P_n(x) + E_n(x),$$

onde $P_n(x)$ é o **n -ésimo polinômio de Taylor**, dado por

$$P_n(x) := \sum_{k=0}^n \frac{1}{k!} f^{(k)}(c)(x - c)^k$$

e o **termo residual/erro** $E_n(x)$ é dado por

$$E_n(x) := \frac{1}{(n+1)!} f^{(n+1)}(\zeta)(x - c)^{(n+1)},$$

onde ζ corresponde a algum ponto entre c e x .

Em vista das séries de Taylor, podemos também definir um conceito muito recorrente:

Definição. Se $f(h)$ e $g(h)$ são duas funções em h , então diremos que **f é da ordem de g quando h tende a zero**, denotado por $f(h) = O(g(h))$ (“big-o de g ”) se, para

todo h suficientemente pequeno, vale

$$|f(h)| \leq C|g(h)|. \square$$

Observação

O que a definição acima indica é que, se dividirmos f por g , esse valor vai ser constante a partir de certo h , correspondendo, então, a uma velocidade de decaimento para f :

$$|f(h)| \leq C|g(h)| \Rightarrow \frac{|f(h)|}{|g(h)|} \leq C.$$

Por exemplo, se $f(h) = O(h^2)$, então f tende a zero tão rápido quanto uma função de ordem h^2 :

$$|f(h)| \leq Ch^2.$$

Para a maior parte das nossas aproximações, usaremos essa notação, dizendo que ela é da ordem de h^p para representar exatamente esta noção.

Vamos ver, então, como ficam as ordens das aproximações ou **erros de truncamento** das aproximações que vimos anteriormente.

Exemplo 2 (Operador D_+). Assuma que $u \in C^2([a, b])$, sendo x um ponto de (a, b) e $0 < h \ll 1$; pelo Teorema de Taylor, vale a aproximação

$$u(\bar{x} + h) = u(\bar{x}) + hu'(\bar{x}) + \frac{1}{2}h^2u''(\zeta),$$

para algum $\zeta \in (\bar{x}, \bar{x} + h)$. Logo, temos

$$u'(\bar{x}) = \frac{u(\bar{x} + h) - u(\bar{x})}{h} - \frac{1}{2}hu''(\zeta) = D_+u(\bar{x}) - \frac{1}{2}hu''(\zeta).$$

Consequentemente, ganhamos a relação

$$|u'(\bar{x}) - D_+u(\bar{x})| = \left| -\frac{1}{2}hu''(\zeta) \right| \leq C|h| = Ch.$$

Portanto, concluímos que o erro da aproximação pelo operador $D_+(h)$ é da ordem h , ou seja, é um erro linear:

$$u'(\bar{x}) - D_+u(\bar{x}) = O(h) \Rightarrow u'(\bar{x}) = D_+u(\bar{x}) + O(h).$$

Esse exemplo ilustra as aproximações por diferenças finitas, porque passamos

a representar o **operador derivada** de uma certa função por uma certa **fórmula de diferenças finitas** e um **erro**:

$$\mathcal{D}u(\bar{x}) = \mathcal{F}(\bar{x}, h) + \mathcal{E}(\bar{x}, h).$$

Neste caso específico, essa fórmula se traduz como

$$u'(\bar{x}) = \frac{u(\bar{x} - h) - u(\bar{x})}{h} + \mathcal{O}(h).$$

Exemplo 3 (Operador D_-). Agora, suponha que $u \in C^2([a, b])$, que x pertence a (a, b) e que h é suficientemente pequeno, de modo que o Teorema de Taylor se aplica como

$$u(\bar{x} - h) = u(\bar{x}) - hu'(\bar{x}) + \frac{1}{2}h^2u''(\zeta), \quad \zeta \in (\bar{x} - h, \bar{x}).$$

Portanto, pela mesma lógica, temos

$$\begin{aligned} u'(\bar{x}) &= \frac{u(\bar{x}) - u(\bar{x} - h)}{h} + \frac{1}{2}hu''(\zeta) = D_-u(\bar{x}) - \frac{1}{2}hu''(\zeta) \\ &= D_-u(\bar{x}) + \mathcal{O}(h). \end{aligned}$$

Pelos exemplos, ambas as aproximações indicam que o erro cai linearmente com h para as aproximações, mas esse nem sempre é o caso:

Exemplo 4 (Operador D_0). Vamos olhar a ordem do erro do operador D_0 . Aqui, nossas hipóteses são que u é uma função com pelo menos 3 derivadas ($u \in C^3([a, b])$), enquanto que x e h são como antes. As expansões de Taylor deste exemplo são

$$\begin{aligned} u(\bar{x} + h) &= u(\bar{x}) + hu'(\bar{x}) + \frac{1}{2}h^2u''(\bar{x}) + \frac{1}{6}h^3u'''(\zeta_1) \\ u(\bar{x} - h) &= u(\bar{x}) - hu'(\bar{x}) + \frac{1}{2}h^2u''(\bar{x}) - \frac{1}{6}h^3u'''(\zeta_2), \end{aligned}$$

onde $\zeta_1 \in (\bar{x}, \bar{x} + h)$ e $\zeta_2 \in (\bar{x} - h, \bar{x})$; logo, obtemos a expressão

$$\begin{aligned} u'(\bar{x}) &= \frac{u(\bar{x} + h) - u(\bar{x} - h)}{2h} - \frac{1}{2h} \frac{h^3}{6} (u'''(\zeta_1) + u'''(\zeta_2)) \\ &= D_0u(\bar{x}) - \frac{h^2}{6} \frac{u'''(\zeta_1) + u'''(\zeta_2)}{2}. \end{aligned}$$

Neste caso, como o termo multiplicando $\frac{h^2}{6}$ é médio entre $u'''(\zeta_1)$ e $u'''(\zeta_2)$, e como $u \in C^3([a, b])$, vale pelo **Teorema do Valor Intermediário** que existe ζ entre ζ_1 e ζ_2

(logo, $\zeta \in (\bar{x} - h, \bar{x} + h)$) tal que

$$u'''(\zeta) = \frac{u'''(\zeta_1) + u'''(\zeta_2)}{2}.$$

Portanto, a aproximação aqui obtida é do tipo

$$u'(\bar{x}) = D_0 u(\bar{x}) - \frac{h^2}{6} u'''(\zeta) = D_0 u(\bar{x}) + O(h^2).$$

Lembrete!	Teorema do Valor Intermediário
O Teorema do Valor Intermediário pode ser enunciado como: Seja $f : [a, b] \rightarrow \mathbb{R}$ uma função contínua e tal que $f(a) < f(b)$ ($f(a) > f(b)$). Se $f(a) < k < f(b)$ ($f(a) > k > f(b)$), então existe $\bar{x} \in (a, b)$ tal que $f(\bar{x}) = k$.	

Exemplo 5 (Operador D_3). Finalmente, repetindo o raciocínio para o operador D_3 , pedimos que $u \in C^4([a, b])$, $x \in (a, b)$ e $0 < h \ll 1$, precisaremos expandir os valores que entram na aproximação, ou seja, $u(\bar{x} + h)$, $u(\bar{x} - h)$ e $u(\bar{x} - 2h)$, resultando nas expansões de Taylor

$$\begin{aligned} u(\bar{x} + h) &= u(\bar{x}) + hu'(\bar{x}) + \frac{1}{2}h^2u''(\bar{x}) + \frac{1}{6}h^3u'''(\zeta_1) + \frac{1}{4!}h^4u^{(4)}(\zeta_1) \\ u(\bar{x} - h) &= u(\bar{x}) - hu'(\bar{x}) + \frac{1}{2}h^2u''(\bar{x}) - \frac{1}{6}h^3u'''(\zeta_2) + \frac{1}{4!}h^4u^{(4)}(\zeta_2) \\ u(\bar{x} - 2h) &= u(\bar{x}) - 2hu'(\bar{x}) + \frac{1}{2}(2h)^2u''(\bar{x}) - \frac{1}{6}(2h)^3u'''(\zeta_3) + \frac{1}{4!}(2h)^4u^{(4)}(\zeta_3), \end{aligned}$$

onde $\zeta_1 \in (\bar{x}, \bar{x} + h)$, $\zeta_2 \in (\bar{x} - h, \bar{x})$ e $\zeta_3 \in (\bar{x} - 2h, \bar{x})$; logo, verifica-se que

$$\begin{aligned} u'(\bar{x}) &= \frac{1}{6h} \overbrace{\left[2u(\bar{x} + h) + 3u(\bar{x}) - 6u(\bar{x} - h) + u(\bar{x} - 2h) \right]}^{D_3 u(\bar{x})} \\ &\quad - \frac{1}{6h} \left[\frac{2}{4!}h^4u^{(4)}(\zeta_1) - \frac{6}{4!}h^4u^{(4)} + \frac{16}{4!}h^4u^{(4)}(\zeta_3) \right] \\ &= D_3 u(\bar{x}) - O(h^3). \end{aligned}$$

Nós vimos como essas aproximações se comportam, suas importâncias e algumas delas; porém, dado um certo conjunto de pontos onde queremos aproximar a derivada, gostaríamos de determinar qual é a aproximação. Para tanto, estudaremos, por meio do exemplo a seguir, o chamado **método dos coeficientes não determinados** – suponha que queremos achar a aproximação por diferenças finitas

de $u'(\bar{x})$, digamos

$$u'(\bar{x}) \approx D_2 u(\bar{x}) := au(\bar{x}) + bu(\bar{x} - h) + cu(\bar{x} - 2h),$$

onde queremos determinar exatamente quem são os coeficientes a , b e c .

Utilizando a expansão de Taylor para $u(\bar{x} - h)$ e $u(\bar{x} - 2h)$, chegamos à expressão

$$D_2 u(\bar{x}) = (a+b+c)u(\bar{x}) - (b+2c)hu'(\bar{x}) + \frac{1}{2}(b+4c)h^2u''(\bar{x}) - \frac{1}{6}(b+8c)h^3u'''(\bar{x}) + O(h^4);$$

aqui, lembre-se da expressão das diferenças finitas – precisamos que apareça, à direita do sinal de igual, o termo da derivada, e que os termos de ordem diferentes sumam, ou seja, queremos

$$\begin{cases} a + b + c = 0, & (\text{zera o termo com função normal}) \\ b + 2c = -\frac{1}{h}, & (\text{isola o termo } +u'(\bar{x})), \\ b + 4c = 0, & (\text{zera o termo com derivada de ordem dois, garantindo mais precisão}) \end{cases},$$

enquanto que o termo com a derivada em ordem 3 representa o erro que desejamos, que faz ele permanecer não zerado. Resolvendo esse sistema, obtemos:

$$a = \frac{3}{2h}, \quad b = -\frac{2}{h}, \quad \& \quad c = \frac{1}{2h},$$

e chegamos à expressão

$$D_2 u(\bar{x}) = \frac{1}{2h}[3u(\bar{x}) - 4u(\bar{x} - h) + u(\bar{x} - 2h)],$$

tal que

$$D_2 u(\bar{x}) - u'(\bar{x}) = -\frac{1}{6}(b + 8c)h^3u'''(\bar{x}) + O(h^4) = -\frac{1}{3}h^2u'''(\bar{x}) + O(h^3) = O(h^2).$$

Exercício 1. Replique as ideias feitas acima para encontrar as aproximações com derivadas de ordens maiores!

Existe um outro método que pode ser utilizado, conhecido como **Método da Interpolação**, onde consideramos que temos uma certa função $u(x)$ e valores $x_1 < x_2 < x_3$ com espaçamentos $h_1 = x_2 - x_1$ e $h_2 = x_3 - x_2$ de tamanhos diferentes; queremos obter a derivada de segunda ordem no ponto x_2 usando uma combinação de valores $u(x_1)$, $u(x_2)$ e $u(x_3)$.

Este método consiste em interpolar a função u e tomar as derivadas do po-

linômio aproximador ao invés dela. Um caso aqui é a forma de Newton para o polinômio interpolador, dada por

$$p(x) = U[x_1] + U[x_1, x_2](x - x_1) + U[x_1, x_2, x_3](x - x_1)(x - x_2),$$

onde $U[\cdot]$ representa as **diferenças divididas da função u** . Portanto, com este método,

$$u_2''(x_2) \approx p''(x_2) = 2 \underbrace{\frac{\frac{u(x_3)-u(x_2)}{h_2} - \frac{u(x_2)-u(x_1)}{h_1}}{h_1 + h_2}}_{=U[x_1, x_2, x_3]} = c_1 u(x_1) + c_2 u(x_2) + c_3 u(x_3),$$

onde

$$c_1 = \frac{2}{h_1(h_1 + h_2)}, \quad c_2 = -\frac{2}{h_1 h_2} \quad \& \quad c_3 = \frac{2}{h_2(h_1 + h_2)}.$$

Exercício 2. Compute o erro nessa aproximação expandindo $u(x_1)$ e $u(x_3)$ em séries de Taylor ao redor de x_2 . Além disso, pense no que acontece quando $h_1 = h_2$.

Como último tópico dessa primeira aula, vamos ver como aproximar a derivada de ordem k de uma função $u(\bar{x})$. A primeira coisa a se observar é que precisaremos de certa quantidade de pontos para fazer isso, especificamente um número suficiente para conseguirmos resolver as equações que irão surgir – quando aproximamos a derivada de ordem 2, se usássemos apenas dois pontos, conseguiríamos eliminar o termo u e o u' , mas não apareceria o ponto u'' , ou seja, precisamos de no mínimo três pontos. Em geral, precisamos de pelo menos $n \geq k + 1$ pontos, onde k é a ordem da derivada que desejamos aproximar; sendo assim, consideremos $x_1, \dots, x_n$ pontos distintos¹ e suponhamos que u seja suficientemente suave para que as séries de Taylor a seguir sejam válidas para cada $i = 1, \dots, n$:

$$\begin{aligned} u(x_1) &= u(\bar{x}) + (x_1 - \bar{x})u'(\bar{x}) + \dots + \frac{1}{k!}(x_1 - \bar{x})^k u^{(k)}(\bar{x}) + \dots \\ &\vdots \\ u(x_i) &= u(\bar{x}) + (x_i - \bar{x})u'(\bar{x}) + \dots + \frac{1}{k!}(x_i - \bar{x})^k u^{(k)}(\bar{x}) + \dots \\ &\vdots \\ u(x_n) &= u(\bar{x}) + (x_n - \bar{x})u'(\bar{x}) + \dots + \frac{1}{k!}(x_n - \bar{x})^k u^{(k)}(\bar{x}) + \dots \end{aligned}$$

Lembremos que nosso objetivo é encontrar uma combinação linear destes valores

¹O próprio $\bar{x}$ pode ser um desses pontos, ou não.

que aproxime a derivada $u^{(k)}(\bar{x})$, tal que

$$u^{(k)}(\bar{x}) + O(h^p) = c_1 u(x_1) + \dots + c_n u(x_n),$$

com p quão grande quanto possível! Portanto,

$$\frac{1}{(i-1)!} \sum_{j=1}^n c_j (x_j - \bar{x})^{(i-1)} = \begin{cases} 1, & i-1 = k \\ 0, & \text{c.c.} \end{cases},$$

onde $i = 1, \dots, n$. Esta expressão define um sistema linear que precisamos resolver para encontrar os coeficientes $c_1, c_2, \dots, c_n$, e dado que $x_1, x_2, \dots, x_n$ são todos distintos, garantimos que o sistema de equações lineares é não singular e possui uma solução única!

Observação

Se $n \leq k$, com uma falta de pontos em nosso arcabouço, então o lado direito da equação e a solução ambos serão vetores nulos, mas para $n > k$, os coeficientes fornecem uma aproximação de diferenças finitas adequada, como observado antes!

A ordem p está relacionado exatamente com o número de pontos que temos (n) e a ordem da derivada que queremos aproximar (k), de modo que $p \geq n - k$, mas não é uma igualdade: algumas situações de aproximações fazem com que o método tenha uma ordem maior que a esperada. Por exemplo, utilizando os pontos $\bar{x}$, $\bar{x} - h$, $\bar{x} - 2h$, obtemos uma aproximação do tipo $O(h)$ para u' ; outra que fizemos foi $\bar{x} - h$, $\bar{x} + h$ e $\bar{x}$, da qual obtemos $O(h^2)$. A diferença entre eles é que a segunda é simétrica, de forma que a expansão de Taylor dela cancela vários termos! Daí, a ordem acaba ficando maior que o esperado!

1.3 Calculando os Coeficientes

Utilizando o MATLAB, podemos fazer um programa simples para retornar os coeficientes de uma aproximação por diferenças finitas utilizando a técnica generalizada que vimos. O código está abaixo, com comentários explicando as partes.

```
1 function c = findcoeff(k, xbar, x) % essa função leva como argumentos
2 %a ordem da derivada (k), o ponto xbar onde ela será calculada,
3 % e um vetor x com n posições contendo os pontos de x_1 até x_n,
4 % e retorna o coeficiente c
5
```



```

6  n = length(x); % obtém o tamanho do vetor x
7
8  A = ones(n, n); % inicializa uma matriz n por n de 1s,
9  % pois não queremos que tenha entradas 0, todas serão preenchidas
10
11 xrow = (x-xbar); % um vetor resultando das diferenças entre
12 % as entradas x_j do vetor x e o escalar xbar.
13 % Cuidado com a orientação do vetor x: aqui, supomos que sempre
14 % entramos com um vetor linha.
15
16 % Precisamos percorrer a matriz A
17 % e determinar os valores que ela recebe em cada linha:
18 for i=2:n % como o resultado da operação abaixo para a linha
19 % 1 vai ser um monte de 1, podemos começar a partir da 2
20     A(i, :) = (xrow .^ (i-1)) ./ factorial(i-1);
21     % buscamos evitar um loop interno j,
22     % então faremos uma operação vetorial:
23     % na linha i, definiremos todas as colunas da matriz A,
24     % como indicado pelo ``:'' na segunda entrada.
25     % A expressão ``.^'' indica que a exponenciação fará com que
26     % cada entrada seja elevada a i-1,
27     % e a ``./'' faz com que todos os
28     % termos sejam divididos pelo fatorial de i-1.
29 end
30
31 % Agora, vamos definir o lado direito.
32
33 b = zeros(n, 1); % vetor de n linhas e 1 coluna com zeros.
34 b(k+1) = 1; % quando i for k+1, ou seja, em b(k+1), inserimos 1.
35
36 c = A \ b; % retorna c tal que (Ac)=b,
37 % e a barra invertida é o comando do MATLAB para resolver um
38 % sistema linear. Muito mais otimizado do que fazer inv(A)*b.
39
40 c = c'; % transpõe c para evitar problemas de compatibilidade.
41
42 end

```

Ao fazer os programas, evite fazer como fiz acima! Os comentários são puramente didáticos, isso deixa o código muito poluído como deu pra ver. Teste o programa depois de fazer ele! Por exemplo, rode $fdcoeff(1, 1, x)$, com $x(1)=1$ e $x(2)=1+h$, $h=0.05$, ou então $c = fdcoeff(1,1, \sin(x))$ e fazer $\mathbf{ad} = \mathbf{c} * \mathbf{u}'$.

2 Aula 02 - 04 de Março, 2026

2.1 Motivações

- Estados Estacionários;
- Problemas de Valor de Fronteira.

2.2 Problemas de Valor de Fronteira: Estados Estacionários

Primeiramente, precisamos entender o que exatamente estamos modelando. A equação do calor é derivada das leis de Fourier e da conservação de energia, descrita como

$$u_t = (k(x)u_x(x, t))_x + \psi(x, t), \quad a < x < b, \quad t > 0,$$

onde $u(x, t)$ é a temperatura no ponto x e tempo t , $k(x) > 0$ é um coeficiente de condução de calor (por exemplo, quanto certo material dissipa temperatura), sendo constante (independente de x) caso o material seja homogêneo, e $\psi(x, t)$ é a fonte do calor. Para resolver uma equação desse tipo, precisamos de uma condição inicial no momento $t = 0$, dada por

$$u(x, 0) = u_0(x)$$

dependente apenas de x , e as condições de contorno podem ser tanto do tipo *condições de Dirichlet*, correspondendo às temperaturas prescritas nos extremos, como

$$u(a, t) = \alpha(t) \quad \& \quad u(b, t) = \beta(t), \quad t \geq 0,$$

ou *condições de Neumann*, dizendo respeito ao fluxo de temperatura – sua variação em certo ponto, como

$$u_x(a, t) = 0 \quad \& \quad u_x(b, t) = 0,$$

sendo o exemplo acima correspondendo a um material isolado.

Porém, do jeito que foi posto aqui, essa é uma EDP! Não temos as ferramentas necessárias para resolver isso (por agora); o que estamos interessados aqui é um problema de estado estacionário: se imaginarmos um fio com certa temperatura no lado esquerdo, outra no direito e uma condição inicial, com o passar do tempo, como não estamos acrescentando nada ao sistema, a temperatura vai chegar a uma certa distribuição e parar de variar de acordo com o tempo! Isso constitui uma **solução estacionária**, na qual o tanto de temperatura entrando no sistema é o mesmo tanto

que o que está saindo, e elas são características de um modelo estacionário. No modelo anterior, para encaixá-lo nessa configuração, supomos que $\partial_t u = 0$, $k(x) \equiv k > 0$ e que $\psi(x, t)$, $\alpha(t)$, $\beta(t)$ são todas temporalmente independentes, passando a ser do tipo

$$-ku''(x) = \psi(x), \quad a < x < b$$

e passá-la para uma EDO usual do tipo

$$u''(x) = f(x), \quad f(x) := \frac{-\psi(x)}{k}, \quad a < x < b,$$

caracterizando uma EDO de segunda ordem em $u(x)$. Logo, adiante, vamos assumir que $a = 0$, $b = 1$ e que o problema de fronteira de Dirichlet² é da forma

$$u(0) = \alpha, \quad u(1) = \beta.$$

Observação

O sistema de estado estacionário acima poderia ser dado uma solução exata se integrarmos f duas vezes e usarmos as condições de fronteira para determinar as constante envolvidas. Um exemplo para o problema acima é considerando

$$u(0) = 20, \quad u(1) = 60, \quad f(x) = -100e^x,$$

cuja solução é

$$u(x) = -100e^x + (100e - 60)x + 120$$

Sem mais delongas, vamos nos concentrar no PVC de dois pontos que postulamos:

$$\begin{cases} u''(x) = f(x), & 0 < x < 1 \\ u(0) = \alpha \\ u(1) = \beta \end{cases}.$$

Definamos os pontos de grade $x_j = jh$, $0 \leq j \leq m+1$, do intervalo $[0, 1]$ (essencialmente, separamos o intervalo $[0, 1]$ em $m+1$ pontos), onde $h = \frac{1}{m+1}$ é o comprimento da grade/malha; coloque, também, $U_j \approx u(x_j)$ como a aproximação de $u(x_j)$. Assim, pelo valor de contorno, sabemos que $U_0 = \alpha$ e $U_{m+1} = \beta$, de forma que ganhamos m variáveis desconhecidas $U_1, U_2, \dots, U_m$, e seria bem legal se conseguíssemos calcular elas, até porque, quanto mais pontos usamos na divisão, melhor será a aproximação.

Pelo que vimos na aula passada, podemos aproximar a segunda derivada de

²A partir do momento que retiramos a dependência temporal, não faz sentido falar de condição inicial.

u em x pela fórmula

$$u''(x_j) \approx D^2 u(x_j) := \frac{1}{h^2}(u(x_{j-1}) - 2u(x_j) + u(x_{j+1})) + O(h^2),$$

Como não sabemos exatamente a forma de $O(h^2)$, devemos descartar esse tema, resultando numa mudança de notação, da qual obtemos o sistema algébrico de m equações lineares em U_j da forma

$$\frac{1}{h^2}(U_{j-1} - 2U_j + U_{j+1}) = f(x_j), \quad j = 1, 2, \dots, m,$$

onde $U_0 = \alpha$ e $U_{m+1} = \beta$, resultando no sistema de igualdades

$$\begin{aligned} \frac{1}{h^2}(\alpha - 2U_1 + U_2) &= f(x_1), \quad j = 1 \\ \frac{1}{h^2}(U_1 - 2U_2 + U_3) &= f(x_2), \quad j = 2 \\ &\vdots \\ \frac{1}{h^2}(U_{m-2} - 2U_{m-1} + U_m) &= f(x_{m-1}), \quad j = m-1 \\ \frac{1}{h^2}(U_{m-1} - 2U_m + \beta) &= f(x_m), \quad j = m, \end{aligned}$$

que tem uma representação em forma de

$$\frac{1}{h^2} \begin{bmatrix} -2 & 1 & 0 & \dots & & \\ 1 & -2 & 1 & 0 & \dots & \\ 0 & 1 & -2 & 1 & \dots & \\ \vdots & 0 & \ddots & \ddots & \ddots & \\ & \vdots & \vdots & 1 & -2 & 1 \\ & & & 1 & -2 & \end{bmatrix} \begin{bmatrix} U_1 \\ U_2 \\ U_3 \\ \vdots \\ U_{m-1} \\ U_m \end{bmatrix} = \begin{bmatrix} f(x_1) - \frac{\alpha}{h^2} \\ f(x_2) \\ f(x_3) \\ \vdots \\ f(x_{m-1}) \\ f(x_m) - \frac{\beta}{h^2} \end{bmatrix},$$

ou, equivalentemente, $AU = F$, onde A é uma *diagonalmente dominante de forma fraca* e não singular.

Lembrete!

Diagonalmente Dominante de Forma Fraca

Uma matriz diagonalmente dominante de forma fraca é aquela cuja diagonal, em módulo, é estritamente maior ou igual que a soma dos outros elementos da linha.

Dado um vetor de valores verdadeiros $\hat{U} = [u(x_1), \dots, u(x_m)]^T$, definimos o

vetor de erro por

$$E = U - \hat{U},$$

que contém os erros em cada ponto da malha. Para essa função, definimos algumas normas:

- 1) **Norma do Máximo/norma- ∞** : $\|E\|_{\infty} := \max_{1 \leq j \leq m} |E_j| = \max_{1 \leq j \leq m} |U_j - u(x_j)|$;
- 2) **norma-1/norma L^1 discreta**: $\|E_1\| := h \sum_{j=1}^m |E_j|$; e
- 3) **norma-2/norma L^2 discreta**: $\|E_1\| := \left(h \sum_{j=1}^m |E_j|^2 \right)^{\frac{1}{2}}$.

Observação

Essas normas **não são** as normas vetoriais canônicas, são apenas as versões delas restritas às funções discretas. No caso de uma matriz real $m \times m$ A , a norma matricial dela associada às normas vetoriais usuais é igual à norma matricial de A associada à norma das funções na malha definidas acima; nesse sentido, o “multiplicar por h ” corresponde exatamente à refinação dos intervalos até que elas se tornem as versões contínuas.

Definição. O **Erro de Truncamento Local (LTE)** é definido trocando U_j pelas soluções verdadeiras $u(x_j)$ na fórmula da diferença finita:

$$\begin{aligned} 0 &= \frac{1}{h^2}(U_{j-1} - 2U_j + U_{j+1}) - f(x_j) \\ \Rightarrow \tau_j &= \frac{1}{h^2}(u(x_{j-1}) - 2u(x_j) + u(x_{j+1})) - f(x_j), \quad j = 1, 2, \dots, m. \end{aligned}$$

Assim, pela expansão em série de Taylor e o problema de valor de contorno $u''(x_j) = f(x_j)$, obtemos

$$\begin{aligned} \tau_j &= \left(u''(x_j) + \frac{1}{12}h^2 u^{(4)}(x_j) + O(h^4) \right) - f(x_j) \\ &= \frac{1}{12}h^2 u^{(4)}(x_j) + O(h^4) \quad (\text{usamos a condição de contorno aqui}) \\ &= O(h^2), \quad 0 < h \ll 1, \end{aligned}$$

ou seja, o erro de truncamento local é da ordem de h^2 .

Indo mais adiante, podemos globalizar partes desse resultado como uma fun-

ção contínua: defina o vetor de erros de truncamento locais

$$\tau := \begin{bmatrix} \tau_1 \\ \tau_2 \\ \vdots \\ \tau_m \end{bmatrix},$$

tal que $\tau = A\hat{U} - F$ e

$$AE = A(U - \hat{U}) = F - (F + \tau) = -\tau;$$

reescreva o sistema de equações como

$$\frac{1}{h^2}(E_{j-1} - 2E_j + E_{j+1}) = -\tau(x_j), \quad j = 1, 2, \dots, m,$$

com condições de contorno dadas por $E_0 = E_{m+1} = 0$ – essa ideia pode ser entendida como a discretização da diferença centrada da EDO

$$e''(x) = -\tau(x), \quad 0 < x < 1,$$

com condições de contorno $e(0) = 0$ e $e(1) = 0$. Desta forma, com um certo abuso de notação, podemos usar o fato de que $\tau(x) \approx \frac{1}{12}h^2 u^{(4)}(x)$ e uma integração duas vezes para ver que

$$e(x) \approx -\frac{1}{12}h^2 u''(x) + \frac{1}{12}h^2 [u''(0) + (u''(1) - u''(0))x].$$

Logo, o **erro global**, uma função contínua, é também da ordem $\mathcal{O}(h^2)$ nas três normas!

Observação

e Não é só a aproximação da derivada que afeta no erro do truncamento, especialmente para o caso de equações não lineares!

Consequentemente, reescrevemos o sistema linear $AE = -\tau$ como

$$A^h E^h = -\tau^h,$$

tal que $E^h = (-A^h)^{-1} \tau^h$ e

$$\|E^h\| \leq \|(A^h)^{-1} \tau^h\| \leq \|(A^h)^{-1}\| \|\tau^h\|,$$

onde $\|\cdot\|$ representa qualquer uma das três normas de funções da malha; ao passar o limite de h tendendo a zero, o ideal é que A^h fique constante, pois sabemos que $\|\tau^h\| = O(h^2)$ e queremos o mesmo para $\|E^h\|$, requerendo

$$\|(A^h)^{-1}\| \leq C, \quad \forall 0 < h < 1.$$

Isso motiva a definição

Definição (Estabilidade). Suponha que temos um método de diferenças finitas para um sistema de valor de fronteiras linear que dê uma equação matricial da forma

$$A^h U^h = F^h,$$

onde h é o tamanho da malha. Diremos que o **método é estável** se:

- $(A^h)^{-1}$ existe para todo h suficientemente pequeno (por exemplo, a partir de certo h_0); e
- existe uma certa constante positiva C , independente de h , tal que

$$\|(A^h)^{-1}\| \leq C, \quad 0 < h < r_0. \quad \square$$

Definição (Consistência). Diremos que um método de diferenças finitas é **consistente com a equação diferencial e as condições de fronteira** se

$$\lim_{h \rightarrow 0} \|\tau^h\| = 0. \quad \square$$

Tipicamente, um método terá $\|\tau^h\| = O(h^p)$ para algum inteiro $p > 0$, caso no qual diremos que o **método é certamente consistente**.

Definição (Convergência). Um método de diferenças finitas é dito **convergente** se

$$\lim_{h \rightarrow 0} \|E^h\| = 0,$$

e a **ordem de convergência** do método é o inteiro p tal que $\|\tau^h\| = O(h^p)$, que já é o menor tal inteiro justamente por estarmos impondo $O(h^p)$. $\square$

Teorema (Teorema Fundamental do MDF). *Um método de diferenças finitas que é consistente e estável **deve** ser convergente. Em particular, um erro de truncamento local da ordem $O(h^p)$ e Estabilidade implicam na convergência de ordem $O(h^p)$.*

Prova. Se um método é estável, teremos

$$\|E^h\| \leq \|(A^h)^{-1}\tau^h\| \leq \|(A^h)^{-1}\|\|\tau^h\| \leq C\|\tau^h\|;$$

além disso, se o método for consistente,

$$\lim_{h \rightarrow 0} \|E^h\| \leq \lim_{h \rightarrow 0} C\|\tau^h\| = 0.$$

Portanto, o método é convergente. ■

Definição. Se A for uma matriz simétrica, a **norma-2 matricial** de A é seu raio espectral:

$$\|A\|_2 = \rho(A) = \max_{1 \leq p \leq m} |\lambda_p|. \quad \square$$

Note que, neste caso, a matriz A^{-1} também será simétrica, que permite a conclusão

$$\|A^{-1}\|_2 = \rho(A^{-1}) = \max_{1 \leq p \leq m} |\lambda_p^{-1}| = \left(\min_{1 \leq p \leq m} |\lambda_p|\right)^{-1}.$$

É possível provar que existe uma fórmula fechada para os autovalores de A , dados por

$$\lambda_p = \frac{2}{h^2}(\cos(p\pi h) - 1), \quad p = 1, 2, \dots, m,$$

com autovetores u^p correspondentes a λ_p tendo componentes u_j^p dados por

$$u_j^p = \sin(p\pi j h), \quad j = 1, 2, \dots, m.$$

Logo, em módulo, o menor autovalor de A é

$$\begin{aligned} \lambda_1 &= \frac{2}{h^2}(\cos(\pi h) - 1) \\ &= \frac{2}{h^2} \left(-\frac{1}{2}\pi^2 h^2 + \frac{1}{24}\pi^4 h^4 + O(h^6) \right) \\ &= -\pi^2 + O(h^2), \end{aligned}$$

onde usamos a expansão de Taylor do cosseno

$$\cos(x) = 1 - \frac{x^2}{2!} + \frac{x^4}{4!} - \dots;$$

assim, existe $h_0 > 0$ tal que

$$\|(A^h)^{-1}\|_2 = \left| \frac{1}{\pi^2 + \frac{1}{2}\pi^2 h^2 - \frac{1}{24}\pi^4 h^4 + O(h^6)} \right| \leq \frac{1}{\pi^2}, \quad \forall h \leq h_0,$$

mostrando a estabilidade do método na norma-2. Ademais, temos

$$\|E^h\|_2 \leq \|(A^h)^{-1}\|_2 \|\tau^h\|_2 \leq \frac{1}{\pi^2} \|\tau^h\|_2 = O(h^2),$$

que tende a zero conforme h tende a zero. Portanto, o método é convergente com ordem de precisão $O(h^2)$ na norma L^2 discreta.

Vale notar que, definindo $u_0^p = u_{m+1}^p = 0$, a j -ésima componente do vetor Au^p é

$$\begin{aligned} (Au^p)_j &= \frac{1}{h^2} (u_{j-1}^p - 2u_j^p + u_{j+1}^p) \\ &= \frac{1}{h^2} (\sin(p\pi(j-1)h) - 2\sin(p\pi jh) + \sin(p\pi(j+1)h)) \\ &= \frac{1}{h^2} (\sin(p\pi jh) \cos(p\pi h) - 2\sin(p\pi jh) + \sin(p\pi jh) \cos(p\pi h)) \\ &= \lambda_p u_j^p, \quad j = 1, 2, \dots, m, \end{aligned}$$

que é consistente com o fato de $Au^p = \lambda_p u^p$.

Observação

O autovetor

$$u^p = \begin{bmatrix} u_1^p \\ u_2^p \\ \vdots \\ u_m^p \end{bmatrix},$$

onde cada u_j tem a forma $u_j = \sin p\pi jh$, tem forte ligação com a autofunção do operador diferencial de grau dois $\frac{d^2}{dx^2}$; de fato, as funções $u^p(x) = \sin(p\pi x)$ para $p = 1, 2, \dots$ satisfazem a relação

$$\frac{d^2}{dx^2} u^p(x) = (-p^2 \pi^2) u^p(x) := \mu_p u^p(x)$$

com condições $u^p(0) = u^p(1) = 0$. Logo, as funções

$$u^p(x) = \sin(p\pi x), \quad p = 1, 2, \dots,$$

são autofunções do operador diferencial $\frac{d^2}{dx^2}$ em $[0, 1]$ com condições de fronteira homogêneas.

Note que os m autovalores de A são dados por

$$\lambda_p = \frac{2}{h^2}(\cos(p\pi h) - 1) = \frac{2}{h^2} \left(-\frac{1}{2}p^2\pi^2 h^2 + \frac{1}{24}p^4\pi^4 h^4 + \dots \right) \\ \stackrel{h \rightarrow 0^+}{=} -p^2\pi^2 + O(h^2).$$

Portanto, λ_p servem como boas aproximações dos autovalores exatos μ_p , que são justamente as autofunções usadas para analisar o operador diferencial de grau 2, permitindo usarmos λ_p para o serviço!

3 Aula 03 - 09 de Março, 2026

3.1 Motivações

- Sistemas Expandidos;
- Condições de Fronteira Mistas;
- Problemas Bem-Postos.

3.2 Sistemas Expandidos

Em algumas situações, o uso de sistemas aumentados ou expandidos pode tornar a implementação como programa mais fácil ao incorporar equações para as condições de fronteira de sistemas lineares $AU = F$ e incluir as variáveis desconhecidas das condições de fronteiras juntas! (“Adicionar os pontos 0 e $m + 1$ ”); por exemplo, para os problemas de fronteira do tipo de Dirichlet, teríamos $U_0 = \alpha$ e $U_{m+1} = \beta$, resultando no sistema linear expandido torna-se

$$A = \frac{1}{h^2} \begin{bmatrix} h^2 & 0 & \dots & & & \\ 1 & -2 & 1 & \dots & & \\ & 1 & -2 & 1 & \dots & \\ \vdots & \vdots & \ddots & \ddots & \ddots & \\ & & & 1 & -2 & 1 \\ & & & & 0 & h^2 \end{bmatrix}, \quad U = \begin{bmatrix} U_0 \\ U_1 \\ U_2 \\ \vdots \\ U_m \\ U_{m+1} \end{bmatrix}, \quad F = \begin{bmatrix} \alpha \\ f(x_1) \\ f(x_2) \\ \vdots \\ f(x_m) \\ \beta \end{bmatrix}.$$

No entanto, não são todos os casos em que vamos ter condições de Fronteira de Dirichlet, e isso requer modificações do sistema expandido.

Lembrete!**Condições de Contorno**

Alguns exemplos de condições de contorno com $\Omega = [0, L]$ e que garantem o requerimento acima são:

$$u(0) = u(L) = v(0) = v(L) = 0 \text{ (Dirichlet)}$$

$$u'(0) = u'(L) = v'(0) = v'(L) = 0 \text{ (Neumann)}$$

$$u(x, y) + \beta(\nabla u(x, y) \cdot n(x, y)) = g(x, y), \quad (x, y) \in \partial\Omega \text{ (Robin)}$$

$$u(0) = u(L), \quad u'(0) = u'(L), \quad v(0) = v(L), \quad v'(0) = v'(L) \text{ (Periódica)}.$$

Em geral, definimos as condições de contorno da seguinte forma:

$$Cu = 0 \iff \begin{cases} \alpha_1 u(0) + \tilde{\alpha}_1 u'(0) + \beta_1 u(L) + \tilde{\beta}_1 u'(L) = 0 \\ \alpha_2 v(0) + \tilde{\alpha}_2 v'(0) + \beta_2 v(L) + \tilde{\beta}_2 v'(L) = 0 \end{cases},$$

em que os coeficientes são reais e seus conjuntos como vetores, isto é,

$$(\alpha_1, \tilde{\alpha}_1, \beta_1, \tilde{\beta}_1) \quad \& \quad (\alpha_2, \tilde{\alpha}_2, \beta_2, \tilde{\beta}_2)$$

são linearmente independentes. Queremos que, se u e v forem funções de classe $C^2([0, L])$ satisfazem $Cu_1 = Cu_2 = 0$, então

$$u'(L)v(L) - u'(0)v'(0) - u(L)v'(L) + u(0)v'(0) = 0.$$

Vamos considerar a equação diferencial de segunda ordem dada por

$$u''(x) = f(x), \quad 0 < x < 1,$$

com condição de fronteira de Neumann na fronteira com 0, $u'(0) = \sigma$, e de Dirichlet na fronteira direita, $u(1) = \beta$. Nesta situação, $u(0)$ tornou-se uma incógnita, e a aproximação U_0 , consequentemente, também! Temos que dar um jeito de aproximar a condição $u'(0) = \sigma$ e de modificarmos, de acordo com ela, a primeira linha do sistema expandido.

Utilizando a aproximação da derivada unilateral

$$u'(0) \approx D_+ u(x_0) = \frac{u(x_1) - u(x_0)}{h},$$

obtemos a relação

$$\frac{U_1 - U_0}{h} = \sigma,$$

mas que tem uma aproximação apenas de ordem 1, já que, pelo erro de truncamento local,

$$\begin{aligned}\tau_0 &= \frac{1}{h}(u(x_1) - u(x_0)) - \sigma = \frac{1}{h}\left(u(x_0) + hu'(x_0) + \frac{1}{2}h^2u''(x_0) + O(h^3) - u(x_0)\right) - \sigma \\ &= u'(x_0) + \frac{1}{2}hu''(x_0) + O(h^2) - \sigma \\ &= \frac{1}{2}hu''(x_0) + O(h^2) \\ &= O(h).\end{aligned}$$

Com essa aproximação, ganhamos o sistema linear nas incógnitas $U_0, \dots, U_{m+1}$ com um erro global de ordem um e devido a $\tau_0 = O(h)$:

$$A = \frac{1}{h^2} \begin{bmatrix} -h & h & \dots & & & \\ 1 & -2 & 1 & \dots & & \\ & 1 & -2 & 1 & \dots & \\ \vdots & \vdots & \ddots & \ddots & \ddots & \\ & & & 1 & -2 & 1 \\ & & & & 0 & h^2 \end{bmatrix} \begin{bmatrix} U_0 \\ U_1 \\ U_2 \\ \vdots \\ U_m \\ U_{m+1} \end{bmatrix} = \begin{bmatrix} \sigma \\ f(x_1) \\ f(x_2) \\ \vdots \\ f(x_m) \\ \beta \end{bmatrix}.$$

De maneira parecida, mas usando uma precisão de segunda ordem, podemos aproximar $u'(0) = \sigma$ de forma centralizada ao introduzir mais uma incógnita, U_{-1} , junto à relação

$$\frac{1}{h^2}(U_{-1} - 2U_0 + U_1) = f(x_0), \quad \frac{1}{2h}(U_1 - U_{-1}) = \sigma,$$

resultando em um sistema linear de $m+3$ equações com $m+3$ incógnitas. Por um processo de eliminação de incógnitas, remove-se U_{-1} acima e obtém-se a relação

$$\frac{1}{h}(-U_0 + U_1) = \sigma + \frac{h}{2}f(x_0),$$

reduzindo o caso de $m+3$ equações com $m+3$ incógnitas para o original com $m+2$

de cada, escrito como

$$A = \frac{1}{h^2} \begin{bmatrix} -h & h & \dots & & \\ 1 & -2 & 1 & \dots & \\ & 1 & -2 & 1 & \dots \\ \vdots & \vdots & \ddots & \ddots & \ddots \\ & & & 1 & -2 & 1 \\ & & & & 0 & h^2 \end{bmatrix} \begin{bmatrix} U_0 \\ U_1 \\ U_2 \\ \vdots \\ U_m \\ U_{m+1} \end{bmatrix} = \begin{bmatrix} \sigma + \frac{h}{2}f(x_0) \\ f(x_1) \\ f(x_2) \\ \vdots \\ f(x_m) \\ \beta \end{bmatrix}.$$




Figura 3: A linha sólida é a solução real $u(x) = e^x - x + 4 + e$, o sinal $+$ indica a solução numa malha de 20 pontos para a primeira abordagem, e o símbolo $\circ$ é a segunda abordagem na mesma malha. Pelo gráfico log-log à direita, comparam-se os erros (na norma máxima).

Observação

A matriz A é exatamente a mesma que a obtida na aproximação com precisão de primeira ordem, mas o lado direito da equação muda de σ para $\sigma + \frac{h}{2}f(x_0)$.

Vale mencionar brevemente que teria como, ainda, fazer uma aproximação utilizando séries de Taylor:

$$\begin{aligned} \frac{u(x_1) - u(x_0)}{h} &\approx u'\left(x_0 + \frac{h}{2}\right) = u'(x_0) + \frac{h}{2}u''(x_0) + O(h^2) \\ &= \sigma + \frac{h}{2}f(x_0) + O(h^2), \end{aligned}$$

ou até fazer uma aproximação de precisão de segunda ordem unilateral baseada nas

três incógnitas U_0, U_1, U_2 :

$$\frac{1}{2h}(-3U_0 + 4U_1 - U_2) = \sigma \iff \frac{1}{h^2}\left(\frac{-3h}{2}U_0 + 2hU_1 - \frac{h}{2}U_2\right) = \sigma.$$

O problema é que o sistema linear resultante

$$A = \frac{1}{h^2} \begin{bmatrix} -\frac{3h}{2} & 2h & -\frac{h}{2} & \dots & & \\ 1 & -2 & 1 & \dots & & \\ & & 1 & -2 & 1 & \dots \\ \vdots & \vdots & \ddots & \ddots & \ddots & \ddots \\ & & & 1 & -2 & 1 \\ & & & & 0 & h^2 \end{bmatrix} \begin{bmatrix} U_0 \\ U_1 \\ U_2 \\ \vdots \\ U_m \\ U_{m+1} \end{bmatrix} = \begin{bmatrix} \sigma + \frac{h}{2}f(x_0) \\ f(x_1) \\ f(x_2) \\ \vdots \\ f(x_m) \\ \beta \end{bmatrix}$$

sofre uma perturbação na sua estrutura tridiagonalizada, aumentando o custo computacional de resolver esse sistema.

3.3 Problemas Bem-Postos

Utilizando a definição de Jacques Hadamard,

Definição. Uma modelagem matemática de um fenômeno físico é **bem-posta** (e deveria ser sempre que possível) se ela satisfaz:

- 1) Uma solução existe;
- 2) A solução é única; e
- 3) O comportamento da solução muda de forma contínua com os dados. $\square$

Exemplo 6. Até mesmo PVCs que parecem simples podem não ser bem-postos; basta considerar

$$\begin{cases} u''(x) = f(x), & 0 < x < 1 \\ u'(0) = \sigma_0 \\ u'(1) = \sigma_1 \end{cases}.$$

Utilizando a abordagem de diferenças centradas para discretizar a equação diferencial e a segunda abordagem para lidar com os problemas de contorno do tipo

Neumann, o sistema linear discreto resultante é da forma

$$\frac{1}{h^2} \begin{bmatrix} -h & h & \dots & & \\ 1 & -2 & 1 & \dots & \\ & 1 & -2 & 1 & \dots \\ \vdots & \vdots & \ddots & \ddots & \ddots \\ & & & 1 & -2 & 1 \\ & & & & 0 & h^2 \end{bmatrix} \begin{bmatrix} U_0 \\ U_1 \\ U_2 \\ \vdots \\ U_m \\ U_{m+1} \end{bmatrix} = \begin{bmatrix} \sigma_0 + \frac{h}{2}f(x_0) \\ f(x_1) \\ f(x_2) \\ \vdots \\ f(x_m) \\ -\sigma_1 + \frac{h}{2}f(x_{m+1}) \end{bmatrix},$$

que é uma matriz singular e, em geral, ou ele não tem solução, ou ele tem infinitas soluções!

A falha obtida na matriz do problema não é por conta do método numérico, mas sim porque ele em si não é bem-posto, e a equação diferencial definindo ele também terá nenhuma ou infinitas soluções! Tanto é que

$$A[1, 1, \dots, 1]^T = A \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

A chave para a questão das soluções está em observar que alguns PVCs têm soluções únicas, enquanto que outros terão apenas se certas condições de solubilidade forem impostas, e isso dá dicas a um princípio geral importante conhecido como *Alternativas de Fredholm*:

Teorema (Alternativas de Fredholm). *Suponha que $Ax = b$ é um sistema linear de m incógnitas e m equações. Então, vale exclusivamente uma das alternativas abaixo:*

- 1) *Existe exatamente uma solução para cada b arbitrário (A é não-singular); Ou*
- 2) *Existe uma solução não nula $z \neq 0$ para $Az = 0$ (A é singular).*

Armados com essa ferramenta, vamos ver alguns casos de condições de fronteiras e equações diferenciais, junto à situação de suas soluções.

Caso 1: o primeiro caso é uma barra isolada nas pontas, sem fluxo de calor nelas e sem fonte de calor por perto, ou seja,

$$\sigma_0 = \sigma_1 = 0 \quad \& \quad f \equiv 0.$$

Lembre-se que esse PVC é uma equação simplificada para encontrar as soluções de

estado estacionário da equação

$$u_t(x, t) = \kappa u_{xx}(x, t) + \psi(x, t), \quad u(x, 0) = u_0(x);$$

sendo assim, como que $u(x, t)$ muda com o passar do tempo?

Sabemos que a energia calórica total do sistema deve ser conservada ao longo do tempo, e que a difusão do calor tende a redistribuí-la até estar uniformemente distribuída pela barra, ou seja, esperamos uma solução de estado estacionário do tipo $u(x) = c$. Logo, pela conservação de energia,

$$c = \int_0^1 u_0(x) dx.$$

Porém, qualquer $u(x) = c$ irá resolver esse sistema! Caímos no caso de infinitas soluções!

Nesse caso, o sistema físico tinha apenas uma solução, mas em nossa tentativa de simplificar ele resolvendo apenas na situação do estado estacionário, acabamos descartando uma informação essencial do sistema: quanto de calor estava disponível no início, ou seja, descartamos o dado inicial da equação de calor.

Caso 2: a barra está com as pontas isoladas, sem fluxo de calor nelas, mas existe uma fonte de calor:

$$\sigma_0 = \sigma_1 = 0 \quad \& \quad f \neq 0.$$

Se pedirmos que o calor esteja sendo constantemente adicionado à barra, ou seja, que $f(x) < 0$ em toda a parte. Já que nenhum calor está fugindo pelas pontas isoladas, o esperado é que a temperatura aumente indefinidamente – nunca atingimos um estado estacionário, resultando numa falta de soluções para o PVC.

Por outro lado, se a fonte de calor for descrita por uma função positiva em parte do intervalo e negativa no restante, o efeito resultante da fonte fornecedora e do escape do fluxo de calor se cancelam! Daí, é possível que existe um estado estacionário. Nesse caso, integrando o PVC, observa-se que a solução existe somente se

$$\begin{aligned} 0 = \sigma_1 - \sigma_0 &= u'(1) - u'(0) \\ &= \int_0^1 u''(x) dx \\ &= \int_0^1 f(x) dx, \end{aligned}$$

ou seja, caímos novamente no caso de infinitas soluções. Na verdade, o estado inicial $u(0)$ pode até mesmo ser arbitrário, pois:

$$\begin{aligned}\int_0^y u''(s)ds &= \int_0^y f(s)ds \Rightarrow u'(y) - u'(0) = \int_0^y f(s)ds \\ \int_0^x u'(y)dy &= \int_0^x \int_0^y f(s)dsdy \Rightarrow u(x) - u(0) = \int_0^x \int_0^y f(s)dsdy\end{aligned}$$

para qualquer $u(0)$.

Caso 3: as pontas **não** estão isoladas, ou seja, há fluxo de calor:

$$\sigma_0 \neq 0 \text{ e/ ou } \sigma_1 \neq 0.$$

Aqui, por conta da existência do fluxo de calor na fronteira, o calor da fonte deve cancelar o fluxo nas fronteiras; como

$$u'(1) - u'(0) = \int_0^1 u''(x)dx = \int_0^1 f(x)dx,$$

devemos ter

$$\int_0^1 f(x)dx = \sigma_1 - \sigma_0,$$

fornecendo infinitas soluções, porque, novamente, $u(0)$ pode ser qualquer coisa:

$$\begin{aligned}\int_0^y u''(s)ds &= \int_0^y f(s)ds \Rightarrow u'(y) - u'(0) = \int_0^y f(s)ds \\ \Rightarrow u'(y) &= \sigma_0 + \int_0^y f(s)ds \\ \Rightarrow \int_0^x u'(y)dy &= \sigma_0 x + \int_0^x \int_0^y f(s)dsdy \\ \Rightarrow u(x) &= u(0) + \sigma_0 x + \int_0^x \int_0^y f(s)dsdy.\end{aligned}$$

Similarmente aos casos, o sistema singular expandido

$$\frac{1}{h^2} \begin{bmatrix} -h & h & \dots & & \\ 1 & -2 & 1 & \dots & \\ & 1 & -2 & 1 & \dots \\ \vdots & \vdots & \ddots & \ddots & \ddots \\ & & & 1 & -2 & 1 \\ & & & & 0 & h^2 \end{bmatrix} \begin{bmatrix} U_0 \\ U_1 \\ U_2 \\ \vdots \\ U_m \\ U_{m+1} \end{bmatrix} = \begin{bmatrix} \sigma_0 + \frac{h}{2}f(x_0) \\ f(x_1) \\ f(x_2) \\ \vdots \\ f(x_m) \\ -\sigma_1 + \frac{h}{2}f(x_{m+1}) \end{bmatrix}$$

terá uma solução (na verdade, infinitas) somente se F é ortogonal ao espaço anulador de A^T . Com efeito, supondo que temos uma solução U e que $A^T V = 0$, então

$$\langle F, V \rangle = \langle AU, V \rangle = \langle U, A^T V \rangle = \langle U, 0 \rangle = 0.$$

Observação

Observe aqui que temos

$$A^T \begin{bmatrix} 1 \\ h \\ \vdots \\ h \\ 1 \end{bmatrix} = 0,$$

fornecendo a condição

$$\langle F, V \rangle = 0 \Rightarrow \frac{h}{2} \left(f(x_0) + 2 \sum_{i=1}^m f(x_i) + f(x_{m+1}) \right) = \sigma_1 - \sigma_0,$$

que é exatamente a regra do trapezoide para a aproximação de

$$\int_0^1 f(x) dx = \sigma_1 - \sigma_0.$$

Consideremos, agora, a equação diferencial mais parecida com uma linear

$$a(x)u''(x) + b(x)u'(x) + c(x)u(x) = f(x), \quad a < x < b$$

e condições de contorno de Dirichlet

$$u(a) = \alpha \quad \& \quad u(b) = \beta.$$

Podemos discretizar esta equação utilizando a aproximação por diferenças centradas, colocando $a_j := a(x_j)$, $b_j := b(x_j)$, $c_j := c(x_j)$ e $f_j := f(x_j)$:

$$a_j \frac{U_{j-1} - 2U_j + U_{j+1}}{h^2} + b_j \frac{U_{j+1} - U_{j-1}}{2h} + c_j U_j = f_j,$$

colocando $U_0 = \alpha$ e $U_{m+1} = \beta$. Como consequência, obtemos uma equação da forma

$AU = F$, mas onde, dessa vez,

$$A = \frac{1}{h^2} \begin{bmatrix} (h^2 c_1 - 2a_1) & (a_1 + \frac{hb_1}{2}) & \dots & \dots & \dots \\ (a_2 - \frac{hb_2}{2}) & (h^2 c_2 - 2a_2) & (a_2 + \frac{hb_2}{2}) & \dots & \dots \\ \vdots & \ddots & \ddots & \ddots & \dots \\ \dots & \dots & (a_m - \frac{hb_m}{2}) & (h^2 c_m - 2a_m) & \dots \end{bmatrix}$$

e

$$U = \begin{bmatrix} U_1 \\ U_2 \\ \vdots \\ U_{m-1} \\ U_m \end{bmatrix}, \quad F = \begin{bmatrix} f(x_1) - \alpha(\frac{a_1}{h^2} - \frac{b_1}{2h}) \\ f(x_2) \\ \vdots \\ f(x_m) - \beta(\frac{a_m}{h^2} - \frac{b_m}{2h}) \end{bmatrix}.$$

Vale mencionar que essa discretização pode não ser a melhor para certos tipos de problemas físicos, mesmo quando há acurácia de segunda ordem; muitas vezes, os problemas físicos possuirão certas propriedades que gostaríamos de preservar quando fazemos a discretização, e é importante entender o problema sendo modelado, além de ter sempre em mente as propriedades matemáticas dele antes de sair aplicando um método numérico. Por exemplo, considere a condução de calor em um barra com propriedades de condução que variam dependendo do pedaço considerado, ou seja, $\kappa(x)$ varia com cada x e $\kappa(x) > 0$ para todo ponto x entre os extremos a e b da barra, resultando na equação

$$(\kappa(x)u'(x))' = f(x), \quad a < x < b,$$

com duas condições de contorno $u(a) = \alpha$ e $u(b) = \beta$. Aplicando a regra do produto, obtemos a equação

$$\kappa(x)u''(x) + \alpha'(x)u'(x) = f(x), \quad a < x < b,$$

a partir da qual podemos aplicar a discretização; porém, essa abordagem não é a melhor! Afinal, o sistema linear resultante pode não ser simétrico!! O melhor seria discretizar o problema física diretamente

$$\kappa(x_{j+1/2})u'(x_{j+1/2}) = \kappa_{j+1/2} \left(\frac{U_{j+1} - U_j}{h} \right),$$

junto à aproximação em $x_{j-1/2}$ de maneira análoga; assim, fazendo a diferença entre

eles, obtemos uma aproximação centrada em x_j para $(\kappa u')'$:

$$\begin{aligned} (\kappa u')' &\approx \frac{1}{h} \left[\kappa(x_{j+1/2}) u'(x_{j+1/2}) - \kappa(x_{j-1/2}) u'(x_{j-1/2}) \right] \\ &\approx \frac{1}{h} \left[\kappa_{j+1/2} \left(\frac{U_{j+1} - U_j}{h} \right) - \kappa_{j-1/2} \left(\frac{U_j - U_{j-1}}{h} \right) \right] \\ &= \frac{1}{h^2} (\kappa_{j-1/2} U_{j-1} - (\kappa_{j-1/2} + \kappa_{j+1/2}) U_j + \kappa_{j+1/2} U_{j+1}), \end{aligned}$$

que leva à matriz simétrica

$$A = \frac{1}{h^2} \begin{bmatrix} -(\kappa_{1/2} + \kappa_{3/2}) & \kappa_{3/2} & \dots & & \\ \kappa_{3/2} & -(\kappa_{3/2} + \kappa_{5/2}) & \kappa_{5/2} & & \dots \\ \vdots & \ddots & \ddots & & \dots \\ & \kappa_{m-3/2} & -(\kappa_{m-3/2} + \kappa_{m-1/2}) & \kappa_{m-1/2} & \\ & & \kappa_{m-1/2} & -(\kappa_{m-1/2} + \kappa_{m+1/2}) & \end{bmatrix}$$

A grande vantagem da matriz fornecida por esse método é que ela é simétrica, afinal a equação diferencial que dá origem a ela é autoadjunta; além disso, como $\kappa > 0$, a matriz obtida será não singular e definida negativa!

Quando resolvemos sistemas lineares por métodos iterativos, costuma ser desejável que a matriz resultante tenha propriedades como as mencionadas acima, já que alguns deles, tal qual o método do gradiente conjugado, dependem destas propriedades

4 Aula 04 - 11 de Março, 2026

4.1 Motivações

- Equações não lineares;
- Discretização de Problemas não Lineares;
- Método de Newton.

4.2 Equações não lineares

O primeiro exemplo de uma equação não linear, e um dos mais famosos, é o movimento de um pêndulo: considere o movimento de um pêndulo com uma partícula de massa m presa ao final de uma haste de comprimento L , considerada aqui sem massa, e seja $\theta(t)$ o ângulo do pêndulo verticalmente no momento t . Ignorando a massa da barra, forças de atrito e a resistência do ar, o movimento deste pêndulo pode ser descrito como

$$\theta''(t) = -\frac{g}{L} \sin(\theta(t)),$$

sendo g a constante gravitacional. Aplicando a segunda lei de Newton às forças atuando na partícula presa à ponta, obtemos a relação

$$F = ma = -mg \sin(\theta) \Rightarrow a = -g \sin(\theta).$$

Como o comprimento de arco traçado quando o ângulo vale θ é dado por $s = L\theta$, observamos também que

$$v = \frac{ds}{dt} = L \frac{d\theta}{dt},$$

e conseqüentemente

$$a = \frac{d^2s}{dt^2} = L \frac{d^2\theta}{dt^2}.$$

Portanto, a descrição analítica do problema é que

$$\frac{d^2\theta}{dt^2} = -\frac{g}{L} \sin(\theta).$$

Nosso objetivo é encontrar uma forma da solução desse sistema na qual possamos testar nossos métodos numéricos, porque o caso aqui vai ser bem diferente do que vimos anteriormente. Sendo assim, começando pela resolução do sistema,

vamos supor que $\frac{g}{L} = 1$ para simplificar; com isso, temos

$$\begin{aligned}\theta''(t) &= -\sin(\theta(t)), \quad 0 < t < T \\ \theta(0) &= \alpha \\ \theta(T) &= \beta,\end{aligned}$$

mas vale observar que fornecer um valor da velocidade angular $\theta'(0)$ é mais natural em contextos reais. Para amplitudes pequenas do ângulo θ , é costume utilizar a aproximação $\sin(\theta(t)) \approx \theta(t)$, tornando o problema acima em

$$\begin{aligned}\theta''(t) &= \theta(t), \quad 0 < t < T \\ \theta(0) &= \alpha \\ \theta(T) &= \beta,\end{aligned}$$

que sabemos resolver com soluções gerais da forma

$$\theta(t) = A \cos(t) + B \sin(t).$$

Seguindo a abordagem dos problemas lineares, podemos aproximar os valores das soluções por

$$\frac{1}{h^2}(\theta_{j-1} - 2\theta_j + \theta_{j+1}) + \sin(\theta_j) = 0, \quad j = 1, 2, \dots, m,$$

onde

$$h := \frac{T}{(m+1)}, \quad \theta_0 := \alpha \quad \& \quad \theta_{m+1} := \beta.$$

Transformamos o problema em um sistema de equações não lineares da forma

$$G(\theta) = 0,$$

onde $G : \mathbb{R}^m \rightarrow \mathbb{R}^m$ e $\theta = (\theta_1, \theta_2, \dots, \theta_m)^T$, que tem um problema grande de não poder ser resolvido utilizando sistemas lineares tridiagonais: ao invés de usarmos métodos diretos, é necessário explorarmos métodos iterativos, tal qual o *Método de Newton*.

A forma como o método de Newton funciona é que, se $\theta^{[k]}$ denota a aproximação para θ no k -ésimo passo, então o método de Newton consiste em utilizar a

expansão de Taylor

$$G(\theta^{[k+1]}) = G(\theta^{[k]}) + \frac{\partial}{\partial \theta} G(\theta^{[k]})(\theta^{[k+1]} - \theta^{[k]}) + \dots,$$

colocar $G(\theta^{[k+1]}) = 0$ como desejado, e abandonar os termos de ordens maiores, resultando em

$$0 \approx G(\theta^{[k]}) + \frac{\partial}{\partial \theta} G(\theta^{[k]})(\theta^{[k+1]} - \theta^{[k]}).$$

Disso, podemos fazer uma etapa do método conhecida como atualização, colocando

$$\theta^{[k+1]} := \theta^{[k]} + \delta^{[k]},$$

onde $\delta^{[k]}$ é a solução da equação com Jacobiana

$$J(\theta^{[k]})\delta^{[k]} = -G(\theta^{[k]}),$$

onde

$$J(\theta) := \frac{\partial}{\partial \theta} G(\theta) \in \mathbb{R}^{m \times m}, \quad J_{ij}(\theta) = \frac{\partial}{\partial \theta_j} G_i(\theta), \quad i, j = 1, 2, \dots, m.$$

Em nosso exemplo do pêndulo,

$$G_i(\theta) = G_i(\theta_1, \theta_2, \dots, \theta_m) = \frac{1}{h^2}(\theta_{i-1} - 2\theta_i + \theta_{i+1}) + \sin(\theta_i),$$

tal que

$$J_{ij}(\theta) = \begin{cases} \frac{1}{h^2}, & j = i - 1 \text{ ou } j = i + 1, \\ -\frac{2}{h^2} + \cos(\theta_i), & j = i, \\ 0, & \text{caso contrário} \end{cases},$$

resultando na matriz

$$A = \frac{1}{h^2} \begin{bmatrix} -\frac{2}{h^2} + \cos(\theta_1) & 1 & \dots & & \\ 1 & -\frac{2}{h^2} + \cos(\theta_2) & 1 & \dots & \\ \vdots & \ddots & \ddots & \ddots & \\ & & & 1 & -\frac{2}{h^2} + \cos(\theta_m) \end{bmatrix}.$$

Observação

O método de Newton requer uma ressalva: o chute inicial deve ser perto o suficiente do valor real, e ele converge de forma quadrática se isso ocorrer!

A solução do problema não linear acima é uma *solução isolada*, no sentido

que não há outras soluções em uma vizinhança dela: ela é *localmente única*, mas essa *não* é a única solução ao problema de valor de contorno.

É importante manter em mente que há uma diferença entre a convergência do Método de Newton aplicado à solução de uma equação de diferença finitas e da convergência da aproximação de diferença finita da solução: inserindo a solução verdadeira à equação de diferenças finitas,

$$\begin{aligned}\tau_i &:= \frac{1}{h^2}(\theta(t_{i-1}) - 2\theta(t_i)) + \sin(\theta(t_i)) - 0 \\ &= \left[\theta''(t_i) + \sin\left(\theta(t_i) + \frac{1}{12}h^2\theta^{(4)}(t_i)\right) \right] + O(h^4) \\ &= \frac{1}{12}h^2\theta^{(4)}(t_i) + O(h^4), \quad i = 1, 2, \dots, m.\end{aligned}$$

Concluimos, então, que o erro de truncamento local para a aproximação é da ordem de h^2 .

Seja $\hat{\theta}$ o vetor de valores reais numa malha de pontos, e $\tau = (\tau_1, \tau_2, \dots, \tau_m)^T$. Então, se $G(\theta) = \tau$ e $E := \theta - \hat{\theta}$ é o erro global, temos

$$G(\theta) - G(\hat{\theta}) = 0 - \tau = -\tau.$$

No caso linear, onde $G(\theta) = A\theta - F$, segue que

$$G(\theta) - G(\hat{\theta}) = A\theta - A\hat{\theta} = -\tau \Rightarrow \dots \Rightarrow E^h = (A^h)^{-1}(-\tau^h);$$

com uma expansão de séries de Taylor, podemos escrever

$$G(\theta) = G(\hat{\theta}) + J(\hat{\theta})E + O(\|E\|^2) \Rightarrow J(\hat{\theta})E = -\tau + O(\|E\|^2),$$

e ignorando os termos de ordem maior, então novamente temos um relação linear entre os erros locais e globais! Adotaremos a notação

$$\hat{J}^h := J(\hat{\theta})$$

em uma malha com espaçamento h .

Definição. O método de diferenças não lineares $G(\theta) = 0$ é **estável em uma norma** $\|\cdot\|$ se as matrizes $(\hat{J}^h)$ forem uniformemente limitadas nela, conforme h tende a zero; noutras palavras, se existe $C > 0$ e $h_0 > 0$ tais que

$$\left\| (\hat{J}^h)^{-1} \right\| \leq C, \quad 0 < h < h_0. \quad \square$$

Pode-se mostrar que, se o método é estável nesse sentido e consistente no sentido de que $\|\tau^h\|$ tende a zero conforme h tende também, então o método converge ($\|E^h\| \rightarrow 0$ conforme $h \rightarrow 0^+$).

5 Aula 05 - 16 de Março, 2026

5.1 Motivações

- Métodos de Ordem Quatro;
- Método da Extrapolação;
- Correção Adiada;
- Equações Elípticas.

5.2 Métodos de Ordens Maiores para o Caso Não Linear

Por agora, consideramos métodos de ordem no máxima segunda para resolver os PVC's, mas existem métodos que obtêm precisões de ordens maiores. Daremos uma passada por três abordagens que resultam em ordens polinomiais maiores, tais como:

- Diferenciação de quarta ordem;
- Método da Extrapolação;
- Correção Adiada.

A primeira abordagem é meio óbvia – basta utilizar uma aproximação melhor ao operador derivada ao invés da diferença de segunda ordem usada em

$$\frac{1}{h^2}(U_{j-1} - 2U_j + U_{j+1}) = f(x_j), \quad j = 1, 2, \dots, m,$$

por exemplo a aproximação de diferença finita

$$\frac{1}{12h^2}(-U_{j-2} + 16U_{j-1} - 30U_j + 16U_{j+1} - U_{j+2}) = f(x_j), \quad j = 1, 2, \dots, m,$$

que fornece uma aproximação de quarta ordem precisa para $u''(x_j)$.

Para o PVC $u''(x) = f(x)$ em uma malha com m pontos interiores, essa aproximação pode ser usada nos pontos $j = 2, 3, \dots, m-1$, mas não nos casos $j = 1$ e $j = m$, pois neles, precisamos usar métodos com somente um ponto no estêncil, à esquerda ou à direita, respectivamente. Daí, poderíamos obter algumas fórmulas adequadas, por exemplo a aproximação com acurácia de ordem três para $u'''(x_1)$ dada por

$$u'''(x_1) = \frac{1}{12h^2}(11U_0 - 20U_1 + 6U_2 + 4U_3 - U_4) + O(h^3),$$

ou mesmo a de acurácia de quarta ordem:

$$u''(x_1) = \frac{1}{12h^2}(10U_0 - 15U_1 - 4U_2 + 14U_3 - 6U_4 + U_5) + O(h^4).$$

Quanto aos métodos de extrapolação, utiliza-se o método de precisão de segunda ordem em duas malhas separadas, uma com espaçamento h , chamada de **malha grossa**, e outra com espaçamento $h/2$, conhecida por **malha fina**; em seguida, extrapola-se em h para obter uma aproximação melhor na malha grossa, resultando em erros de ordem $O(h^4)$. Partindo dessa ideia geral, denote a solução na malha grossa por

$$U_j \approx u(jh), \quad j = 1, 2, \dots, m,$$

e por

$$V_j \approx u\left(\frac{jh}{2}\right), \quad j = 1, 2, \dots, 2m + 1$$

a solução na grade fina (observe que tanto U_j quanto V_{2j} aproximam $u(jh)$). Como esse método é um centrado com acurácia de segunda ordem, podemos provar que o erro tem a forma de uma expansão com potência par em expoentes de h :

$$U_j - u(jh) = C_2h^2 + C_4h^4 + C_6h^6 + \dots,$$

onde $u(x)$ tem que ser suficientemente suave, e os coeficientes $C_2, C_4, \dots$ dependem de derivadas de ordens maiores de u , mas não dependem de h em cada ponto fixo jh . Por outro lado, na malha fina, o erro tem forma

$$\begin{aligned} V_{2j} - u(jh) &= C_2\left(\frac{h}{2}\right)^2 + C_4\left(\frac{h}{2}\right)^4 + C_6\left(\frac{h}{2}\right)^6 + \dots \\ &= \frac{1}{4}C_2h^2 + \frac{1}{16}C_4h^4 + \frac{1}{64}C_6h^6 + \dots \end{aligned}$$

Assim, o valor extrapolado é dado por

$$\bar{U}_j = \frac{1}{3}(4V_{2j} - U_j),$$

que é escolhido desta forma para que os erros de ordem h^2 se cancelem, resultando em

$$\bar{U}_j - u(jh) = \frac{1}{3}\left(\frac{1}{4} - 1\right)C_4h^4 + O(h^6),$$

tal que o resultado final tem precisão de ordem quatro conforme h é reduzida, e um erro consideravelmente menor que aqueles de U_j ou V_{2j} é obtido (afinal, C_4h^2 é pelo

menos não maior que C_2 , normalmente sendo bem menor).

O terceiro método, das *correções atrasadas/defasadas*, tem uma vantagem de resolver os dois problemas na mesma malha ao invés de refinar ela como no anterior. Para entender como ele funciona, vamos considerar um exemplo de resolução do sistema

$$\frac{1}{h^2} \begin{bmatrix} -2 & 1 & \dots & & \\ 1 & -2 & 1 & \dots & \\ \vdots & 1 & -2 & 1 & \dots \\ & & \ddots & \ddots & \ddots & \dots \\ & & & 1 & -2 & 1 \\ & & & & 1 & -2 \end{bmatrix} \begin{bmatrix} U_1 \\ U_2 \\ U_3 \\ \vdots \\ U_{m-1} \\ U_m \end{bmatrix} = \begin{bmatrix} f(x_1) - \frac{\alpha}{h^2} \\ f(x_2) \\ f(x_3) \\ \vdots \\ f(x_{m-1}) \\ f(x_m) - \frac{\beta}{h^2} \end{bmatrix},$$

e resolvendo-o, conseguimos uma aproximação com precisão de ordem 2 para aproximar U . Com isto, o erro global $E = U - \hat{U}$ satisfaz a equação de diferenças $AE = -\tau$, onde τ é o erro de truncamento local, o qual, caso conhecido, fornece uma possibilidade de obter o erro global e, conseqüentemente, obter uma solução exata $\hat{U}$ simplesmente isolando ele na equação do erro. Como nem tudo são flores, isso permanece um pensamento teórico, porque, na prática, o erro de truncamento local tem a forma

$$\tau_j = \frac{1}{12} h^2 u^{(4)}(x_j) + O(h^4),$$

dependente da solução exata, que não conhecemos. No entanto, pela solução aproximada para U , podemos estimar τ aproximando a quarta derivada de U .

No caso do problema simples $u''(x) = f(x)$, temos $u''''(x) = f''(x)$, tal que o erro de truncamento local pode ser estimado diretamente a partir da forma de $f(x)$ ao colocarmos

$$F_j = f(x_j) + \frac{1}{12} h^2 u^{(4)}(x) = f(x_j) + \frac{1}{12} h^2 f''(x_j),$$

com termos de fronteira adicionados nos pontos $j = 1$ e $j = m$; daí, basta resolver $AU = F$ para obter uma solução de acurácia de quarta ordem diretamente. Resumidamente: utilizamos a solução aproximada para estimar o erro de truncamento local, depois resolvemos um problema auxiliar para sair do erro local para o global, e com ele, podemos melhorar a solução aproximada! Not eque

$$\lim_{h \rightarrow 0} F_j = f(x),$$

de modo que

$$\frac{1}{h^2} \left\{ U_{j-1} - 2U_j + U_{j+1} \right\} = F_j$$

resulta numa solução consistente com $u''(x) = f(x)$ e de quarta ordem. De fato, basta observar o erro de truncamento local do método:

$$\begin{aligned} \tau_j &= \frac{1}{h^2} \left\{ u(x_{j-1}) - 2u(x_j) + u(x_{j+1}) \right\} - g(x_j) \\ &= u''(x_j) + \frac{h^2}{12} u^{(4)}(x) + O(h^4) - f(x_j) - \frac{h^2}{12} f''(x_j) \\ &= O(h^4), \end{aligned}$$

já que $u'' = f$ e $u^{(4)} = f''$.

Às vezes, pode acontecer de não termos uma expressão algébrica para a função f , o que dificulta bastante calcular a derivada de ordem 2 dela; nestas situações, ao invés de somarmos da forma

$$F_j = f(x_j) + \frac{1}{12} h^2 f''(x_j),$$

somamos a aproximação de diferenças finitas da própria função:

$$F_j = f(x_j) + \frac{h^2}{12} \left(\frac{f(x_{j-1}) - 2f(x_j) + f(x_{j+1}))}{h^2} + O(h^2) \right).$$

Pode parecer estranho introduzir um erro de ordem 2 quando tentamos refinar tudo para obter um de ordem 4, mas note que tal erro de ordem 2 está sendo multiplicado de ordem 2; daí, no fim das contas, temos outro erro de ordem 4! A expressão disso é

$$F_j = f(x_j) + \frac{h^2}{12} \left(\frac{f(x_{j-1}) - 2f(x_j) + f(x_{j+1}))}{h^2} \right) + O(h^4).$$

5.3 Equações e Problemas Elípticos

Em um contexto bidimensional, uma EDP elíptica com coeficientes constantes em um domínio aberto e limitado $\Omega \subseteq \mathbb{R}^2$ tem a forma

$$a_1 u_{xx}(x, y) + a_2 u_{xy}(x, y) + a_3 u_{yy}(x, y) + a_4 u_x(x, y) + a_5 u_y(x, y) + a_6 u(x, y) = f(x, y), \quad (x, y) \in \Omega,$$

onde os coeficientes a_1, a_2, a_3 satisfazem

$$a_2^2 - 4a_1 a_3 < 0.$$

Usualmente, complementamos a equação com alguma condição de fronteira na fronteira $\partial\Omega$. Essa definição não é geral, mas é válida para todas as equações de segunda ordem apresentadas na forma vista.

Observação

As notações aqui fazem uso das derivadas parciais:

$$u_{xx} = \frac{\partial^2 u}{\partial x^2}, \quad u_{xy} = \frac{\partial}{\partial x} \left(\frac{\partial u}{\partial y} \right) = \frac{\partial^2 u}{\partial x \partial y}, \dots$$

O problema da condução de calor transiente em um espaço bidimensional pode ser escrita como (a menos de condições iniciais e de contornos)

$$u_t = (\kappa u_x)_x + (\kappa u_y)_y + \psi, \quad t \in (0, T), \quad (x, y) \in \Omega,$$

onde $\kappa(x, y) > 0$ é o coeficiente de difusividade térmica e $\psi(x, y, t)$ é uma função-fonte. Se as condições e função fonte forem independentes do tempo t , então esperamos que existe um estado estacionário, que pode ser modelado como


$$(\kappa u_x)_x + (\kappa u_y)_y = -\psi, \quad (x, y) \in \Omega,$$

novamente a menos de condições de contorno. Podemos simplificar ainda mais supondo que o coeficiente κ é constante em Ω e escrevendo

$$f = -\frac{\psi}{\kappa}, \quad \kappa(x, y) \equiv \kappa > 0, \quad (x, y) \in \Omega.$$

A terminologia das soluções segue por:

- Equação Harmônica/de Laplace: $u_{xx} + u_{yy} = 0$
- Equação de Poisson: $u_{xx} + u_{yy} = f$



Lembrete!

Notação de Gradiente

A notação de gradiente tem essencialmente três grandes partes, a partir do símbolo $\nabla := \left[\frac{\partial}{\partial x}, \frac{\partial}{\partial y} \right]^T$:

- **Gradiente**: o gradiente é simplesmente

$$\nabla u = \begin{bmatrix} u_x \\ u_y \end{bmatrix};$$

- **Divergente**: o divergente, por sua vez, age como um produto escalar:

$$\nabla \cdot \begin{bmatrix} u \\ v \end{bmatrix} = u_x + v_y; \text{ \&}$$

- **Laplaciano**: o laplaciano é o divergente do gradiente:

$$\nabla^2 u := \nabla \cdot \nabla u = \nabla \cdot \begin{bmatrix} u_x \\ u_y \end{bmatrix} = u_{xx} + u_{yy}.$$

Vale lembrar também as *condições de contorno* mais comuns.

Considere a equação de Poisson em um domínio quadriculado com condição de contorno de Dirichlet:

$$\left. \begin{array}{ll} \nabla^2 u = f, & \Omega := [0, 1] \times [0, 1] \\ u = g, & \partial\Omega \end{array} \right\}.$$

Iremos discretizar o domínio usando uma malha cartesiana uniforme, isto é, uma coleção de pontos (x_j, y_j) , onde $x_i = i\Delta x$, $y_i = j\Delta y$, e Δx e Δy são os tamanhos da malha³ nas direções x e y. Assim, buscaremos nossas aproximações para $u(x_i, y_j)$ e denotaremos essa solução aproximada por U_{ij} ; note que temos $n \times m$ como total, sendo m o tamanho da discretização em x e n da discretização em y.

Já sabemos aproximar derivadas, e podemos usar isso como ponto de partida: tendo em vista que desejamos encontrar U_{ij} , considere também $f_{ij} := f(x_i, y_j)$ e apliquemos o método de diferenças centrais à EDP:

$$\begin{aligned} u_{xx}(x_i, y_j) + u_{yy}(x_i, y_j) &= f(x_i, y_j) \\ \Rightarrow \frac{1}{(\Delta x)^2} [u(x_{i-1}, y_j) - 2u(x_i, y_j) + u(x_{i+1}, y_j)] \\ &+ \frac{1}{(\Delta y)^2} [u(x_i, y_{j-1}) - 2u(x_i, y_j) + u(x_i, y_{j+1})] + O(\Delta x^2 + \Delta y^2) = f(x_i, y_j) \\ \Rightarrow \frac{1}{(\Delta x)^2} (U_{i-1,j} - 2U_{ij} + U_{i+1,j}) + \frac{1}{(\Delta y)^2} (U_{i,j-1} - 2U_{ij} + U_{i,j+1}) &= f_{ij}, \end{aligned}$$

onde $i = 1, 2, \dots, m$ e $j = 1, 2, \dots, n$. Por simplicidade, denotar $\Delta x = \Delta y = h$, resultando em uma aproximação centrada com 5 pontos da forma

$$\nabla_5^2 U_{ij} := \frac{1}{h^2} (U_{i-1,j} + U_{i+1,j} - 4U_{ij} + U_{i,j-1} + U_{i,j+1}) = f_{ij}.$$

Consideremos as partições cartesianas $0 = x_0 < x_1 < \dots < x_m < x_{m+1} = 1$ e $0 = y_0 < y_1 < \dots < y_m < y_{m+1} = 1$, tal que $h = \frac{1}{m+1}$. Pelas equações acima, ganhamos um sistema linear de tamanho $m^2 \times m^2$ e forma $AU = F$, com $1 \leq i \leq m$, $1 \leq j \leq m$, onde A é uma matriz esparsa.

³É por isso que chama malha!

6 Aula 06 - 18 de Março, 2026

6.1 Motivações

- Esquema de diferenças centrais;
- Número de condições.

6.2 Esquema de Diferenças Centrais e Acurácia

Para dar procedência, precisamos lembrar o que fizemos na última aula: discretizamos o domínio usando uma malha cartesiana uniforme (uma coleção de pontos (x_j, y_j) , onde $x_i = i\Delta x$, $y_i = j\Delta y$, e Δx e Δy são os tamanhos da malha nas direções x e y) e começamos a buscar nossas aproximações para $u(x_i, y_j)$, denotadas por U_{ij} ; note que temos $n \times m$ como total, sendo m o tamanho da discretização em x e n da discretização em y .

Com o conhecimento de aproximação das derivadas e tendo em vista que desejamos encontrar U_{ij} , consideramos também $f_{ij} := f(x_i, y_j)$, a partir dos quais aplicamos o método de diferenças centrais à EDP:

$$\begin{aligned} u_{xx}(x_i, y_j) + u_{yy}(x_i, y_j) &= f(x_i, y_j) \\ \Rightarrow \frac{1}{(\Delta x)^2} [u(x_{i-1}, y_j) - 2u(x_i, y_j) + u(x_{i+1}, y_j)] \\ &+ \frac{1}{(\Delta y)^2} [u(x_i, y_{j-1}) - 2u(x_i, y_j) + u(x_i, y_{j+1})] + O(\Delta x^2 + \Delta y^2) = f(x_i, y_j) \\ \Rightarrow \frac{1}{(\Delta x)^2} (U_{i-1,j} - 2U_{ij} + U_{i+1,j}) + \frac{1}{(\Delta y)^2} (U_{i,j-1} - 2U_{ij} + U_{i,j+1}) &= f_{ij}, \end{aligned}$$

onde $i = 1, 2, \dots, m$ e $j = 1, 2, \dots, n$. Por simplicidade, supusemos $\Delta x = \Delta y = h$, resultando em uma aproximação centrada com 5 pontos da forma

$$\nabla_5^2 U_{ij} := \frac{1}{h^2} (U_{i-1,j} + U_{i+1,j} - 4U_{ij} + U_{i,j-1} + U_{i,j+1}) = f_{ij}.$$

Consideremos as partições cartesianas $0 = x_0 < x_1 < \dots < x_m < x_{m+1} = 1$ e $0 = y_0 < y_1 < \dots < y_m < y_{m+1} = 1$, tais que $h = \frac{1}{m+1}$. Pelas equações acima, ganhamos um sistema linear de tamanho $m^2 \times m^2$ e forma $AU = F$, com $1 \leq i \leq m$, $1 \leq j \leq m$, onde A é uma matriz esparsa:




Figura 4: porção da malha computacional para a equação elíptica em duas dimensões. No exemplo, temos um estêncil de cinco pontos para o Laplaciano em torno de (x_i, y_j) com os pesos indicados.

Para a equação acima, podemos seguir um sentido de linhas para a escrita de cada termo da equação, com o auxílio visual da cruz, resultando nos termos

$$\begin{aligned}
 U^{[j]} &= \begin{bmatrix} U_{1j} \\ U_{2j} \\ \vdots \\ U_{mj} \end{bmatrix}, \quad U = \begin{bmatrix} U^{[1]} \\ U^{[2]} \\ \vdots \\ U^{[m]} \end{bmatrix}, \\
 f^{[j]} &= \begin{bmatrix} f_{1j} \\ f_{2j} \\ \vdots \\ f_{mj} \end{bmatrix} + BV, \quad F = \begin{bmatrix} f^{[1]} \\ f^{[2]} \\ \vdots \\ f^{[m]} \end{bmatrix} \\
 T &= \begin{bmatrix} -4 & 1 & \dots & & \\ 1 & -4 & 1 & \dots & \\ \vdots & \ddots & \ddots & \ddots & \dots \\ & & 1 & -4 & 1 \\ & & & 1 & -4 \end{bmatrix}_{m \times m}, \quad A = \frac{1}{h^2} \begin{bmatrix} T & I & \dots & & \\ I & T & I & \dots & \\ \vdots & \ddots & \ddots & \ddots & \dots \\ & & I & T & I \\ & & & I & T \end{bmatrix}_{m^2 \times m^2}
 \end{aligned}$$

onde $I \in \mathbb{R}^{m \times m}$ é uma matriz identidade. Note que, ao construir a matriz T , os lugares onde os índices são i e j , correspondentes exatamente à diagonal, ficaram com 4 (o termo $-4U_{ij}$ tem coeficiente -4, com entradas ij), e nos termos onde i ou j diferem por ± 1 , as entradas foram 1 (analogamente, $U_{i-1,j}$, $U_{i+1,j}$, $U_{i,j-1}$ e $U_{i,j+1}$ são todos acompanhados por coeficiente 1); caso contrário, como todo o resto foi zerado na aproximação, é tudo 0. Tendo montado a matriz T , a A segue basicamente da montagem em blocos.

Exercício 3. Generalize a definição de A utilizando uma malha $m \times n$ para discretizar o domínio Ω , e utilize o *produto matricial de Kronecker* para construir a matriz A (no MATLAB, é o comando `kron`). Uma dica é que a forma final será

$$T \otimes I + I \otimes \begin{bmatrix} 0 & 1 & \dots \\ 1 & 0 & 1 & \dots \\ \vdots & \ddots & \ddots & \dots \\ & & 1 & 0 \end{bmatrix}$$

. Por fim, escreva a forma final de BV na definição de F.




Figura 5: a ordem natural de incógnitas no sentido das linhas em uma grade 4x4; os nós externos podem ser vistos como fronteiras de Dirichlet!

Lembrete!**Produto Matricial de Kronecker**

O **produto matricial de Fornecer** entre matrizes A , de tamanho $m \times n$, e B , de tamanho $p \times q$, é uma matriz de tamanho $pm \times qn$ em blocos, dado por

$$A \otimes B = \begin{bmatrix} a_{11}B & \dots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \dots & a_{mn}B \end{bmatrix}$$

$$= \begin{bmatrix} a_{11}b_{11} & a_{11}b_{12} & \dots & a_{11}b_{1q} & \dots & \dots & a_{1n}b_{11} & a_{1n}b_{12} & \dots & a_{1n}b_{1q} \\ a_{11}b_{21} & a_{11}b_{22} & \dots & a_{11}b_{2q} & \dots & \dots & a_{1n}b_{21} & a_{1n}b_{22} & \dots & a_{1n}b_{2q} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \ddots & \ddots & \vdots & \ddots & \vdots \\ a_{11}b_{p1} & a_{11}b_{p2} & \dots & a_{11}b_{pq} & \dots & \dots & a_{1n}b_{p1} & a_{1n}b_{p2} & \dots & a_{1n}b_{pq} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \ddots & \ddots & \vdots & \ddots & \vdots \\ \vdots & \vdots & \ddots & \vdots & \ddots & \ddots & \ddots & \vdots & \ddots & \vdots \\ a_{m1}b_{11} & a_{m1}b_{12} & \dots & a_{m1}b_{1q} & \dots & \dots & a_{mn}b_{11} & a_{mn}b_{12} & \dots & a_{mn}b_{1q} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \ddots & \ddots & \ddots & \vdots & \vdots \\ a_{m1}b_{p1} & a_{m1}b_{p2} & \dots & a_{m1}b_{pq} & \dots & \dots & a_{mn}b_{p1} & a_{mn}b_{p2} & \dots & a_{mn}b_{pq} \end{bmatrix}$$

Esse produto é bilinear, associativo, não comutativo e satisfaz

$$(A \otimes B)(C \otimes D) = (AC) \otimes (BD), \quad (A \otimes B)^T = A^T \otimes B^T.$$

O erro de truncamento local τ_{ij} em um ponto (i, j) da malha é dado por

$$\tau_{ij} := \frac{1}{h^2}(u(x_{i-1}, y_j) + u(x_{i+1}, y_j) + u(x_i, y_{j-1}) + u(x_i, y_{j+1}) - 4u(x_i, y_j)) - f(x_i, y_j),$$

que podemos expandir em Taylor para obter

$$\tau_{ij} := \frac{1}{12}h^2(\partial_x^{(4)}u(x_i, y_j) + \partial_y^{(4)}u(x_i, y_j)) + O(h^4),$$

tal que, colocando $\hat{U} = (u(x_1, y_1), \dots, u(x_m, y_m))^T \in \mathbb{R}^{m^2}$, obtemos

$$A\hat{U} = F + \tau,$$

onde A é a matriz de discretização segundo a ordenação com respeito às linhas.

Denotando por $E_{ij} := U_{ij} - u(x_i, y_j)$ o erro global e observando que $AU = F$, temos a relação

$$AE = -\tau \Rightarrow E = A^{-1}(-\tau) \Rightarrow \|E\| \leq \|A^{-1}\| \|\tau\|.$$

Logo, caso $\|A^{-1}\|$ seja uniformemente limitada⁴ conforme h tende a zero, segue que esse método garante um erro global com acurácia de segunda ordem para algumas normas de funções em malhas.

É importante destacar que as definições de consistência, estabilidade e convergência continuam todas válidas no contexto da análise de métodos numéricos para equações elípticas.

Assim como antes, vamos ver a questão dos autovalores, autovetores e auto-funções: consideremos uma 2-norma para a matriz de discretização A ; fazendo umas contas, é possível mostrar que, para cada $p, q = 1, 2, \dots, m$, o autovetor $u^{p,q}$ tem m^2 entradas, dadas por

$$u_{ij}^{p,q} = \sin(p\pi ih) \sin(q\pi jh),$$

com autovalores correspondentes

$$\lambda_{p,q} = \frac{2}{h^2} (\cos(p\pi h) - 1 + \cos(q\pi h) - 1) < 0, \quad h = \frac{1}{m+1}.$$

Assim, o autovalor mais próximo à origem é $\lambda_{1,1} = -2\pi^2 + O(h^2)$ por meio das expansões de Taylor. Quanto às características resultantes disso, o raio espectral de A^{-1} é dado por

$$\pi(A^{-1}) = \frac{1}{|\lambda_{1,1}|} \leq \frac{1}{2\pi^2}, \quad h \rightarrow 0^+,$$

de modo que sua 2-norma tenha também um limite uniforme conforme $h \rightarrow 0^+$:

$$\begin{aligned} \|A^{-1}\|_2 &= \sqrt{\rho(A^{-T}A^{-1})} = \sqrt{\rho((A^{-1})^2)} \\ &= \sqrt{\rho((A^{-1})^2)} \\ &= \rho(A^{-1}) \\ &\leq \frac{1}{2\pi^2}. \end{aligned}$$

Observação

A numeração que fizemos foi por linha, como já dito; caso fosse feita por coluna, seria necessário inverter o papel do m e do n para todos os raciocínios!

Note que a definição de estabilidade garante, também, a estabilidade de sistemas lineares que originem da discretização! De fato, considere o sistema discreto

$$AU = F,$$

⁴Lembrando que o tamanho de A é uma função do tamanho h da grade.

todos dependendo do tamanho h da malha. Suponha que causamos uma perturbação por um vetor pequeno p ($\|p\|_2 < \delta$ para algum $\delta > 0$ pequeno) ao lado direito da equação, e que a solução correspondente ao sistema perturbado é $\hat{U}$. Então, neste contexto, temos

$$A\hat{U} = F + p, AU = F \Rightarrow A(\hat{U} - U) = F + p - F = p,$$

tal que

$$\hat{U} - U = A^{-1}p \Rightarrow \|\hat{U} - U\|_2 \leq \|A^{-1}\|_2 \|p\|_2.$$

Porém, por hipótese, a perturbação foi menor que certo $\delta > 0$ pequeno, permitindo relacionarmos

$$\|\hat{U} - U\|_2 \leq \|A^{-1}\|_2 \|p\|_2 < \|A^{-1}\|_2 \delta < C\delta,$$

garantindo a estabilidade para pequenas perturbações! (Tenha em mente que $\|\hat{U} - U\|$ e $\|p\|_2$ são ambas normas de funções nas malhas).

Nessa perspectiva de estimarmos a norma de A , tem uma definição útil:

Definição. O **número de condição** da matriz A com respeito a uma norma matricial $\|\cdot\|$ é definido como

$$\kappa(A) := \|A\| \|A^{-1}\|. \quad \square$$

O número de condição é uma medida do quanto o valor final da matriz mudará para pequenas perturbações, ou seja, ele dá uma noção de limite da imprecisão do resultado após uma aproximação. Por exemplo, vamos considerar a norma $\|\cdot\|_2$; note que, conforme $h \rightarrow 0^+$, temos

$$\begin{aligned} \|A\|_2 = \rho(A) &= \max_{1 \leq p, q \leq m} |\lambda_{p,q}| \\ &= |\lambda_{m,m}| \\ &= \frac{4}{h^2} \left| \cos \left(\frac{m}{m+1} \pi \right) - 1 \right| \\ &\approx \frac{4}{h^2} | -2 | \\ &= \frac{8}{h^2}. \end{aligned}$$

Portanto, tendo em vista que determinamos anteriormente a aproximação $\|A^{-1}\| \approx \frac{1}{2\pi^2}$, vale que

$$\kappa(A) \approx \frac{8}{h^2} \frac{1}{2\pi^2} = \frac{4}{\pi^2 h^2} = O(h^{-2}),$$

e podemos concluir que a matriz de discretização A é mal-comportada cada vez que refinamos a malha, já que $\kappa(A)$ cresce quadraticamente ao infinito conforme h diminui.

Na próxima aula, vamos brincar com a reordenação do que fizemos hoje e discutir um pouco das condições de Neumann: imagine que o contorno passa a ser um contorno de Neumann ao invés de Dirichlet, condicionando não apenas em u , mas também no gradiente de u !

onde

$$D = \frac{1}{h^2} \begin{bmatrix} -4 & & & \\ & -4 & & \\ & & \ddots & \\ & & & -4 \end{bmatrix}$$

e H é uma matriz com zeros e uns, multiplicados por $\frac{1}{h^2}$, cuja estrutura depende na geometria da malha.

Essa técnica tira vantagem do fato de que computar D^{-1} ser computacionalmente bem barato; note que, pelo sistema resultante, obtemos as equações

$$\begin{aligned} D\mathbf{U}_r + H\mathbf{U}_b &= \mathbf{f}_r \\ H^T \mathbf{U}_r + D\mathbf{U}_b &= \mathbf{f}_b, \end{aligned}$$

de forma que, ao isolarmos o termo $\mathbf{U}_r$, obtemos a relação

$$\mathbf{U}_r = -D^{-1}H\mathbf{U}_b + D^{-1}\mathbf{f}_r.$$

Com a relação acima, podemos substituir os termos nas equações obtidas da matriz, obtendo:

$$H^T(-D^{-1}H\mathbf{U}_b + D^{-1}\mathbf{f}_r) + D\mathbf{U}_b = \mathbf{f}_b \Rightarrow (D - H^T D^{-1}H)\mathbf{U}_b = \mathbf{f}_b - H^T D^{-1}\mathbf{f}_r,$$

o qual pode ser reescrito como $B\mathbf{U}_b = \mathbf{g}$, tendo metade das equações do sistema original, mas sendo fácil de construir B e $\mathbf{g}$. Assim, basta resolver esse sistema e as variáveis vermelhas poderão ser obtidas muito mais facilmente, sem resolver sistemas lineares! Logo, caso ele possa ser implementado, o peso computacional economiza o tempo computacional para resolver o sistema pela metade!!

O próximo passo é aplicar esse método à equação elíptica. Pela expansão de

Taylor, segue que

$$\begin{aligned}
\nabla_5^2 u(x_i, y_j) &= \nabla^2 u(x_i, y_j) + \frac{1}{12} h^2 \frac{\partial^4 u}{\partial x^4}(x_i, y_j) + \frac{1}{12} h^2 \frac{\partial^4 u}{\partial y^4}(x_i, y_j) + O(h^4) \\
&\Rightarrow \nabla_5^2 u(x_i, y_j) + \frac{2}{12} h^2 \frac{\partial^4 u}{\partial y^2 \partial x^2}(x_i, y_j) \\
&= \nabla^2 u(x_i, y_j) + \frac{1}{12} h^2 \underbrace{\left[\frac{\partial^4 u}{\partial x^4}(x_i, y_j) + 2 \frac{\partial^4 u}{\partial x^2 \partial y^2}(x_i, y_j) + \frac{\partial^4 u}{\partial y^4}(x_i, y_j) \right]}_{\nabla^4 u(x_i, y_j)} \\
&= \nabla^2 u(x_i, y_j) + \frac{1}{12} h^2 \nabla^2 \nabla^2 f(x_i, y_j) + O(h^4) \\
&\Rightarrow \nabla_5^2 u(x_i, y_j) + \frac{2}{12} h^2 \frac{\partial^4 u}{\partial y^2 \partial x^2}(x_i, y_j) - \frac{1}{12} h^2 \nabla^2 f(x_i, y_j) \\
&= \nabla^2 u(x_i, y_j) + O(h^4).
\end{aligned}$$

Podemos proceder ainda mais nesse raciocínio e obter uma aproximação com 9 pontos:

$$\begin{aligned}
\nabla_5^2 u(x_i, y_j) + \frac{2}{12} h^2 \frac{\partial^4 u}{\partial y^2 \partial x^2}(x_i, y_j) - \frac{1}{12} h^2 \nabla^2 f(x_i, y_j) &= \nabla^2 u(x_i, y_j) + O(h^4) \\
\Rightarrow \nabla_5^2 u(x_i, y_j) + \frac{h^2}{6h^4} \left[u(x_{i-1}, y_{j-1}) - 2u(x_{i-1}, y_j) + u(x_{i-1}, y_{j+1}) - 2u(x_i, y_{j-1}) \right. \\
&\quad \left. + 4u(x_i, y_j) - 2u(x_i, y_{j+1}) + u(x_{i+1}, y_{j-1}) - 2u(x_{i+1}, y_j) + u(x_{i+1}, y_{j+1}) \right] + O(h^4) \\
&\quad - \frac{1}{12} h^2 \nabla^2 f(x_i, y_j) = \nabla^2 u(x_i, y_j) + O(h^4).
\end{aligned}$$

Portanto, a aproximação

$$\begin{aligned}
\nabla_9^2 U_{ij} &:= \frac{1}{6h^2} [4U_{i-1,j} + 4U_{i+1,j} + 4U_{i,j-1} + 4U_{i,j+1} + U_{i-1,j} + U_{i-1,j+1} + U_{i+1,j-1} \\
&\quad + 4U_{i+1,j+1} - 20U_{ij}] = f_{ij} + \frac{1}{12} h^2 \nabla^2 f(x_i, y_j)
\end{aligned}$$

constitui um esquema de diferenças finitas para o problema de Poisson com erro de truncamento local $O(h^4)$, e o termo $\frac{1}{12} h^2 \nabla^2 f(x_i, y_j)$ pode ser computado de forma exata, ou aproximado por $\frac{1}{12} h^2 \nabla_5^2 f(x_i, y_j)$.




Figura 7: estêncil de 9 pontos para o Laplaciano em torno do ponto (x_i, y_j) com pesos indicados.

7.3 Estimativas por Diferentes Fontes

Suponha que temos o desejo de obter uma solução verdadeira, denote por $E(h)$ a função erro em uma malha de tamanho h , por $U(h)$ o vetor da solução numérica, e $\hat{U}(h)$ a solução verdadeira avaliada na mesma grade, tais que

$$E(h) = \|U(h) - \hat{U}(h)\|.$$

Se o método tem precisão de ordem p , ou seja, se conforme $h \rightarrow 0$,

$$E(h) = Ch^p + O(h^{p+1}),$$

então para $0 < h_2 < h_1$ suficientemente pequenos, espera-se que

$$E(h_1) \approx Ch_1^p \quad \& \quad E(h_2) \approx Ch_2^p.$$

Assim, a ordem de convergência pode ser estimada, tal qual fora feito no início do curso, pela expressão

$$p \approx \frac{\log \left(\frac{E(h_1)}{E(h_2)} \right)}{\log \left(\frac{h_1}{h_2} \right)},$$

pois

$$\log \left(\frac{E(h_1)}{E(h_2)} \right) \approx \log \left(\frac{Ch_1^p}{Ch_2^p} \right) = \log \left(\frac{h_1}{h_2} \right)^p = p \log \left(\frac{h_1}{h_2} \right).$$

Esse tipo de estimativa é conhecida como **estimativa a partir da solução verdadeira**, mas não a única fonte: podemos obter, também, uma **estimativa**

pela solução com malha fina, por exemplo, na qual não sabemos a solução exata, mas podemos rodar o problema por uma malha fina, digamos $\bar{h}$, e usar a solução numérica obtida $U(\bar{h})$ como referência. Neste contexto, seja $U(h)$ a solução numérica em uma malha mais grossa, com tamanho h , e $\bar{U}(h)$ ser a restrição de $U(\bar{h})$ à h -malha; observe como

$$U(h) - \bar{U}(h) = (U(h) - \hat{U}(h)) + (\hat{U}(h) - \bar{U}(h))$$

leva à estimativa

$$\|U(h) - \bar{U}(h)\| \leq \underbrace{\|U(h) - \hat{U}(h)\|}_{E(h)} + \underbrace{\|\hat{U}(h) - \bar{U}(h)\|}_{\bar{E}(h)}.$$

Além disso, como $(\bar{h})^p \ll h^p$, necessariamente deve ocorrer

$$\bar{E}(h) = \|\hat{U}(h) - \bar{U}(h)\| \approx \|U(\bar{h}) - \hat{U}(\bar{h})\| = E(\bar{h}) \ll E(h),$$

ou seja, podemos assumir sem grandes receios que $\|U(h) - \bar{U}(h)\|$ é uma boa aproximação do erro verdadeiro $E(h)$!

Para as funções de grades, temos as seguintes normas L^p :

- **Norma L^p :** dado que $U(x)$ é uma aproximação da solução $u(x)$ no fechado $\bar{\Omega} = [a, b]$, denotemos por $e(x) := U(x) - u(x)$, onde $U(x)$ e $u(x)$ são suficientemente suaves, a diferença da aproximação para a solução real. Então, definimos:

$$\|e\|_{L^\infty(\Omega)} := \max_{a \leq x \leq b} |e(x)| \quad \& \quad \|e\|_{L^p(\Omega)} = \left(\int_a^b |e(x)|^p dx \right)^{\frac{1}{p}}, \quad p \geq 1;$$

- **Norma L^p Discreta para Função Grade Unidimensional:** sejam $U_i \approx u(x_i)$ e $e_i = U_i - u(x_i)$, onde $1 \leq i \leq n$. Definimos

$$\|e\|_\infty := \max_{1 \leq i \leq N} |e_i| \quad \& \quad \|e\|_p := \left(h \sum_{i=1}^N |e_i|^p dx \right)^{\frac{1}{p}}, \quad p \geq 1;$$

- **Norma L^p Discreta para Função Grade Bidimensional:** sejam $U_{ij} \approx u(x_i, y_j)$ e $e_{ij} = U_{ij} - u(x_i, y_j)$, com $1 \leq i \leq M$ e $1 \leq j \leq N$; então, definimos

$$\|e\|_\infty := \max_{\substack{1 \leq i \leq M \\ 1 \leq j \leq N}} |e_{ij}| \quad \& \quad \|e\|_p := \left(\Delta x \Delta y \sum_{i=1}^M \sum_{j=1}^N |e_{ij}|^p dx \right)^{\frac{1}{p}}, \quad p \geq 1.$$


Estamos suficientemente equipados para lidar com métodos iterativos sem matrizes! A ideia, aqui, é isolar $U_{i,j}$ em termos de outras variáveis:

$$U_{i,j} = \frac{1}{4}(U_{i-1,j} + U_{i+1,j} + U_{i,j-1} + U_{i,j+1}) - \frac{h^2}{4}f_{i,j},$$

permitindo criarmos um novo processo iterativo para produzir uma nova estimativa, denotada por $U_{i,j}^{[k+1]}$, baseada em valores já conhecidos $U_{i,j}^{[k]}$, que pode ser resumido na expressão

$$U_{i,j}^{[k+1]} = \frac{1}{4}(U_{i-1,j}^{[k]} + U_{i+1,j}^{[k]} + U_{i,j-1}^{[k]} + U_{i,j+1}^{[k]}) - \frac{h^2}{4}f_{i,j},$$

conhecido como **Iteração de Jacobi para o Problema de Poisson**. O primeiro detalhe observável é que não há a necessidade de armazenar uma matriz esparsa, mas sim dar um palpite inicial $U_{i,j}^{[0]}$; por isso, esse método iterativo converge **muito devagar** para uma solução discreta do problema de Poisson, independente do chute inicial dado! Além disso, ela pode ser modificada para incorporar condições de fronteira de Neumann ou de Robin sem dar vontade de chorar em posição fetal por horas.



Outro método sem matrizes que vale a pena mencionar é o **Método Iterativo de Gauss-Seidel para Problemas de Poisson**; nele, utiliza-se os valores computados disponíveis mais recentemente obtidos durante a iteração na malha, resultando em

$$U_{i,j}^{[k+1]} = \frac{1}{4}(U_{i-1,j}^{[k+1]} + U_{i+1,j}^{[k]} + U_{i,j-1}^{[k+1]} + U_{i,j+1}^{[k]}) - \frac{h^2}{4}f_{i,j},$$

sendo que as mesmas considerações do método anterior permanecem ativas aqui.




Figura 8:

Tanto o método de Gauss-Seidel, quanto o de Jacobi, são facilmente implementáveis, com custo de armazenamento ótimos; porém, eles são conhecidos justamente por sua lentidão para convergir durante o processo iterativo, no sentido de levar muitas e muitas iterações, às vezes mais de milhares, para conseguir uma aproximação razoável, além de ser mais difícil de vetorizar as computações (talvez o Matlab leve vantagem sobre o Python por conta disso para esses métodos).

8 Aula 08 - 08 de Abril, 2026

8.1 Motivações

- Problemas de Valor Inicial.

8.2 Problemas de Valores Iniciais: método de Euler

Vários fenômenos físicos são modelados por equações diferenciais ordinárias, ou sistemas delas. Assim, temos um grande interesse em resolver problemas de valores iniciais (doravante PVIs), que costumam modelar fenômenos físicos de evolução ao longo do tempo. Mais exatamente, seja $f : \Omega \times [0, T] \rightarrow \mathbb{R}^m$, com $\Omega \subseteq \mathbb{R}^m$, $m \geq 1$ e $[0, T] \subseteq \mathbb{R}$; procuramos uma função $u : [0, T] \rightarrow \mathbb{R}^m$ tal que

$$\frac{d}{dt}u(t) =: u'(t) = f(u(t), t), \quad \forall t \in [0, T]$$

e $u(0) = u_0$ é a condição inicial conhecida.

Exemplo 7 (Equação Escalar). Um exemplo de equação escalar é

$$y' = x^2 + y^2, \quad y(0) = 0.5,$$

que está na forma $y'(x) = f(y(x), x)$, onde

$$f(y(x), x) = x^2 + y^2.$$

Exemplo 8 (Modelo Presa-Predador de Lotka-Volterra). Este modelo descreve a dinâmica entre duas populações, uma denominada predador (u) e outra denominada presa:

$$\begin{cases} u'(t) = -2u + uv \\ v'(t) = v - uv \\ u(0) = u_0 \\ v(0) = v_0 \end{cases},$$

resultando nas expressões

$$\begin{aligned} \bullet \mathbf{u}(t) &= \begin{bmatrix} u_1(t) \\ u_2(t) \end{bmatrix} = \begin{bmatrix} u(t) \\ v(t) \end{bmatrix}; \\ \bullet \mathbf{u}_0 &= \begin{bmatrix} u_0 \\ v_0 \end{bmatrix}; \\ \bullet \mathbf{f}(\mathbf{u}(t), t) &= \begin{bmatrix} -2u_1(t) + u_1(t)u_2(t) \\ u_2(t) - u_1(t)u_2(t) \end{bmatrix}, \end{aligned}$$

tais que podemos escrever

$$\begin{cases} \mathbf{u}'(t) = \mathbf{f}(\mathbf{u}(t), t) \\ \mathbf{u}(0) = \mathbf{u}_0 \end{cases}$$

Exemplo 9 (Pêndulo). A dinâmica de um pêndulo ideal sob ação da gravidade é modelado por um sistema de equações diferenciais de ordem 2:

$$\begin{cases} q'' = -\sin q \\ q(0) = q_0 \\ q'(0) = p_0 \end{cases} \Rightarrow \begin{cases} q' = p \\ p' = -\sin q \\ q(0) = q_0 \\ p(0) = p_0 \end{cases},$$

que leva às expressões para a forma usual dadas por:

$$\begin{aligned} \bullet \mathbf{u}(t) &= \begin{bmatrix} u_1(t) \\ u_2(t) \end{bmatrix} = \begin{bmatrix} q(t) \\ p(t) \end{bmatrix}; \\ \bullet \mathbf{u}_0 &= \begin{bmatrix} q_0 \\ p_0 \end{bmatrix}; \\ \bullet \mathbf{f}(\mathbf{u}(t), t) &= \begin{bmatrix} u_2(t) \\ -\sin u_1(t) \end{bmatrix}. \end{aligned}$$

Exemplo 10 (Gravitação). A dinâmica de um objeto de massa desprezível girando em torno do sol é dada pelo sistema de ordem 4 abaixo:

$$\begin{cases} \frac{d^2x}{dt^2} = -\frac{x}{(x^2+y^2)^{\frac{3}{2}}} \\ \frac{d^2y}{dt^2} = -\frac{y}{(x^2+y^2)^{\frac{3}{2}}} \\ x(0) = x_0, y(0) = y_0 \\ x'(0) = u_0, y'(0) = v_0 \end{cases} \Rightarrow \begin{cases} \frac{dx}{dt} = u \\ \frac{du}{dt} = -\frac{x}{(x^2+y^2)^{\frac{3}{2}}} \\ \frac{dy}{dt} = v \\ \frac{dv}{dt} = -\frac{y}{(x^2+y^2)^{\frac{3}{2}}} \\ x(0) = x_0, y(0) = y_0 \\ x'(0) = u_0, y'(0) = v_0 \end{cases},$$

com expressões usuais

$$\begin{aligned}\bullet \mathbf{u}(t) &= \begin{bmatrix} u_1(t) \\ u_2(t) \\ u_3(t) \\ u_4(t) \end{bmatrix} = \begin{bmatrix} x(t) \\ u(t) \\ y(t) \\ v(t) \end{bmatrix}; \\ \bullet \mathbf{u}_0 &= \begin{bmatrix} x_0 \\ u_0 \\ y_0 \\ v_0 \end{bmatrix}; \\ \bullet \mathbf{f}(\mathbf{u}(t), t) &= \begin{bmatrix} u_2(t) \\ -\frac{u_1}{(u_1^2+u_3^2)^{\frac{3}{2}}} \\ u_4(t) \\ -\frac{u_3}{(u_1^2+u_3^2)^{\frac{3}{2}}} \end{bmatrix}.\end{aligned}$$

Exemplo 11 (Sistema Autônomo). Considere o seguinte PVI de ordem 3:

$$\begin{cases} v'''(t) = v'(t)v(t) - 2t(v''(t))^2 \\ v_0 = \eta_1 \\ v'(0) = \eta_2 \\ v''(0) = \eta_3 \end{cases},$$

o qual pode ser transformado em um sistema de ordem 1 com $m = 3$, ou em um sistema autônomo, ou seja, com a f escrita apenas em termos de $\mathbf{u}$, com $m = 4$:

$$\begin{aligned}\bullet \mathbf{u}(t) &= \begin{bmatrix} u_1(t) \\ u_2(t) \\ u_3(t) \\ u_4(t) \end{bmatrix} = \begin{bmatrix} v(t) \\ v'(t) \\ v''(t) \\ t \end{bmatrix}; \\ \bullet \mathbf{f}(\mathbf{u}(t), t) &= \begin{bmatrix} u_2(t) \\ u_3(t) \\ u_1 u_2 - 2u_4 u_3^2 \\ 1 \end{bmatrix}.\end{aligned}$$

A existência e unicidade de soluções é dada pelo [teorema de Picard-Lindelöf](#):

Teorema (Picard-Lindelöf). *Sejam $\mathbf{f} : \Omega \times [0, T] \rightarrow \mathbb{R}^m$ e $\mathcal{D} = \{(\mathbf{u}, t) : \|\mathbf{u} - \mathbf{u}_0\| <$*

$a, t \in [0, T]\}$. Se existir um $L > 0$ tal que, para quaisquer $(\mathbf{v}, t)$ e $(\mathbf{w}, t)$ em $\mathcal{D}$,

$$\|\mathbf{f}(\mathbf{v}, t) - \mathbf{f}(\mathbf{w}, t)\| \leq L\|\mathbf{v} - \mathbf{w}\|,$$

então existe uma única solução $\mathbf{u}(t)$ de classe C^1 para o problema


$$\begin{cases} \mathbf{u}'(t) = \mathbf{f}(\mathbf{u}(t), t) \\ \mathbf{u}(0) = \mathbf{u}_0 \end{cases}$$

para qualquer condição inicial $\mathbf{u}_0 \in \Omega$, pelo menos até um tempo

$$\mathcal{T}^* = \min\left(\mathcal{T}, \frac{a}{\max_{(\mathbf{u}, t) \in \mathcal{D}} \|\mathbf{f}(\mathbf{u}, t)\|}\right).$$

Sabendo disso, nosso objetivo é obter um conjunto de valores $\{\mathbf{U}^n\}_{n=0}^N$ que aproxima os valores da solução exata $\mathbf{u}(t_0), \mathbf{u}(t_1), \dots, \mathbf{u}(t_N)$ em um conjunto finito de pontos $t_0, t_1, \dots, t_N$: teremos um **intervalo de solução** $[t_0, t_N]$, uma **condição inicial** $\mathbf{U}^0 = \mathbf{u}(t_0)$ e um **passo da solução** h , que geralmente se relacionam por

$$t_n = t_0 + n \underbrace{\left(\frac{t_N - t_0}{N}\right)}_{:=h}$$



Para obter este método, consideraremos a expansão em série de Taylor em

torno de t_n para u :

$$u(t_n + h) = u(t_n) + hu'(t_n) + \underbrace{\frac{h^2}{2}u''(t_n) + \dots + \frac{h^q}{q!}u^{(q)}(t_n) + \dots}_{=O(h^2)}.$$

Definição. Dizemos que $g(h)$ é da **ordem de h^p** , ou seja, é $O(h^p)$, se existe uma constante $C > 0$ independente de h , tal que, para todo h suficientemente pequeno,

$$\left\| \frac{g(h)}{h^p} \right\| \leq C. \quad \square$$

Note que tanto a função $u(t)$ quanto as suas derivadas não são conhecidas, mas podemos usar a condição $u'(t) = f(u(t), t)$ para obter

$$u(t_n + h) = u(t_n) + hu'(t_n) + O(h^2) = u(t_n) + hf(u(t_n), t_n) + O(h^2).$$

Assim, podemos gerar uma aproximação para a solução do PVI original ao descartarmos os termos $O(h^2)$, resultando no **método de Euler**

$$\boxed{U^{n+1} = U^n + hf(U^n, t_n)}.$$

Como o último termo que sobrevive corresponde a $q = 1$ na expansão, este método também é conhecido como **método de Taylor de ordem $q = 1$** .

Exemplo 12. Para aproximar o PVI

$$\begin{cases} y'(x) = x + y, & x \in [0, 1] \\ y(0) = \frac{1}{2} \end{cases}$$

usando o método de Euler com $h = \frac{1}{10}$, começamos observando que a forma da função, aqui, é

$$f(y(x), x) = x + y;$$

como $h = \frac{1}{10}$, temos $x_0 = 0$, $x_1 = \frac{1}{10}$, $x_2 = \frac{2}{10} = \frac{1}{5}, \dots, x_{10} = \frac{10}{10} = 1$, de forma que

$$\begin{aligned} Y^0 &= y(0) = \frac{1}{2} \\ Y^1 &= Y^0 + hf(Y^0, x_0) = \frac{1}{2} + hf\left(\frac{1}{2}, 0\right) = \frac{1}{2} + \frac{1}{10} \frac{1}{2} = \frac{11}{20} = 0.55 \\ Y^2 &= Y^1 + hf(Y^1, x_1) = \frac{11}{20} + hf\left(\frac{11}{20}, \frac{1}{10}\right) = \frac{123}{200} = 0.615 \\ &\vdots \end{aligned}$$

resultando na tabela

Tabela 2: Método de Euler com 10 pontos

x	Y^n	E^n
0.0	0.500000	0.0
0.1	0.550000	0.007756
0.2	0.615000	0.017104
0.3	0.696500	0.028288
0.4	0.796150	0.041587
0.5	0.915765	0.057316
0.6	1.057341	0.075836
0.7	1.223075	0.097553
0.8	1.415383	0.122928
0.9	1.636921	0.152483
1.0	1.890613	0.186809

A solução exata é

$$y(x) = \frac{3}{2}e^x - x - 1,$$

e o erro é

$$E^n = y(x_n) - Y^n$$

Exemplo 13 (Pêndulo, parte 2). Vamos escrever o método de Euler para aproximar o problema do pêndulo: primeiramente, lembre-se da forma final do problema do pêndulo:

$$\begin{cases} \mathbf{u}'(t) = \mathbf{f}(\mathbf{u}(t), t) \\ \mathbf{u}(0) = \mathbf{u}_0, \end{cases}$$

onde

$$\begin{aligned}\mathbf{u}(t) &= \begin{bmatrix} u_1(t) \\ u_2(t) \end{bmatrix}, \\ \mathbf{f}(\mathbf{u}(t), t) &= \begin{bmatrix} u_2(t) \\ -\sin u_1(t) \end{bmatrix}, \\ \mathbf{u}^0 &= \begin{bmatrix} q^0 \\ p^0 \end{bmatrix},\end{aligned}$$

tal que

$$\mathbf{U}^{n+1} = \mathbf{U}^n + h\mathbf{f}(\mathbf{U}^n, t_n) \Rightarrow \begin{bmatrix} U_1^{n+1} \\ U_2^{n+1} \end{bmatrix} = \begin{bmatrix} U_1^n \\ U_2^n \end{bmatrix} + h \begin{bmatrix} U_2^n \\ -\sin(U_1^n) \end{bmatrix}$$

Em outras situações, será desejável obter uma aproximação de Taylor de ordem $q = 2$; para isso, olhamos para mesma expansão de antes:

$$\mathbf{u}(t_n + h) = \mathbf{u}(t_n) + h\mathbf{u}'(t_n) + \frac{h^2}{2}\mathbf{u}''(t_n) + \dots + \underbrace{\frac{h^q}{q!}\mathbf{u}^{(q)}(t_n)}_{=O(h^3)} + \dots,$$

e substituímos nela as derivadas de $\mathbf{u}$ em termos de $\mathbf{f}$:

$$\mathbf{u}'(t_n) = \mathbf{f}(\mathbf{u}(t_n), t_n)$$

e

$$\begin{aligned}\mathbf{u}''(t_n) &= \frac{d}{dt}\mathbf{f}(\mathbf{u}(t_n), t) = \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \Big|_{(\mathbf{u}(t_n), t_n)} \frac{d\mathbf{u}}{dt} \Big|_{t_n} + \frac{\partial \mathbf{f}}{\partial t} \Big|_{(\mathbf{u}(t_n), t_n)} \frac{dt}{dt} \Big|_{t_n} \\ &= \left(\frac{\partial \mathbf{f}}{\partial \mathbf{u}} \mathbf{f} + \frac{\partial \mathbf{f}}{\partial t} \right) \Big|_{(\mathbf{u}(t_n), t_n)},\end{aligned}$$

onde o termo $\frac{\partial \mathbf{f}}{\partial \mathbf{u}}$ é uma notação para a matriz Jacobiana de $\mathbf{f}$, dada por

$$\frac{\partial \mathbf{f}}{\partial \mathbf{u}} = \begin{bmatrix} \frac{\partial f_1}{\partial u_1} & \frac{\partial f_1}{\partial u_2} & \cdots & \frac{\partial f_1}{\partial u_m} \\ \frac{\partial f_2}{\partial u_1} & \frac{\partial f_2}{\partial u_2} & \cdots & \frac{\partial f_2}{\partial u_m} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial u_1} & \frac{\partial f_m}{\partial u_2} & \cdots & \frac{\partial f_m}{\partial u_m} \end{bmatrix} = \left(\frac{\partial f_i}{\partial u_j} \right)_{ij}.$$

Dáí, destacando os termos $O(h^3)$ da série de Taylor, chega-se na fórmula discreta

do método:

$$\mathbf{U}^{n+1} = \mathbf{U}^n + h\mathbf{f}(\mathbf{U}^n, t_n) + \frac{h^2}{2} \left(\frac{\partial \mathbf{f}}{\partial \mathbf{u}} \mathbf{f} + \frac{\partial \mathbf{f}}{\partial t} \right) \Big|_{(\mathbf{U}^n, t_n)}$$

Exemplo 14. Vamos revisitar o exemplo

$$\begin{cases} y'(x) = x + y, & x \in [0, 1] \\ y(0) = \frac{1}{2} \end{cases},$$

mas com o método de Taylor de ordem $q = 2$ – no método escalar, com $m = 1$, ela se reduz a

$$U^{m+1} = U^m + hf(U^n, t_n) + \frac{h^2}{2} \left(\frac{\partial f}{\partial u} f + \frac{\partial f}{\partial t} \right) \Big|_{(U^n, t_n)},$$

e, adequando-se à notação utilizada, temos

$$f(y(x), x) = x + y, \quad \frac{\partial f}{\partial y}(y(x), x) = 1, \quad \frac{\partial f}{\partial x} = 1,$$

de modo que, para este exemplo,

$$Y^{n+1} = Y^n + hf(Y^n, x_n) + \frac{h^2}{2} (f(Y^n, x_n) + 1),$$

e podemos comparar as tabelas com ordens distintas:

Tabela 3: Método de Euler com 10 pontos

x	Taylor q = 1		Taylor q = 2	
	Y^n	E^n	Y^n	E^n
0.0	0.500000	0.000000	0.500000	0.000000
0.1	0.550000	0.007756	0.557500	0.000256
0.2	0.615000	0.017104	0.631537	0.000566
0.3	0.696500	0.028288	0.723848	0.000939
0.4	0.796150	0.041587	0.836353	0.001383
0.5	0.915765	0.057316	0.971170	0.001911
0.6	1.057341	0.075836	1.130643	0.002535
0.7	1.223075	0.097553	1.317360	0.003268
0.8	1.415383	0.122928	1.534183	0.004128
0.9	1.636921	0.152483	1.784272	0.005132
1.0	1.890613	0.186809	2.071121	0.006301

Exemplo 15 (Pêndulo, parte 3). Agora, para resolver o problema do pêndulo do

exemplo 2 usando o método de Taylor de ordem $q = 2$, consideramos

$$\mathbf{f}(\mathbf{u}(t), t) = \begin{bmatrix} u_2(t) \\ -\sin u_1(t) \end{bmatrix}$$

e calculamos

$$\frac{\partial \mathbf{f}}{\partial t} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad \frac{\partial \mathbf{f}}{\partial \mathbf{u}} = \begin{bmatrix} \frac{\partial f_1}{\partial u_1} & \frac{\partial f_1}{\partial u_2} \\ \frac{\partial f_2}{\partial u_1} & \frac{\partial f_2}{\partial u_2} \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -\cos(u_1) & 0 \end{bmatrix}.$$


Portanto, o método fica

$$\begin{bmatrix} U_1^{n+1} \\ U_2^{n+1} \end{bmatrix} = \begin{bmatrix} U_1^n \\ U_2^n \end{bmatrix} + h \begin{bmatrix} U_2^n \\ -\sin(U_1^n) \end{bmatrix} + \frac{h^2}{2} \begin{bmatrix} 0 & 1 \\ -\cos(U_1^n) & 0 \end{bmatrix} \begin{bmatrix} U_2^n \\ -\sin(U_1^n) \end{bmatrix},$$

ou ainda, em forma de sistemas,

$$\begin{cases} U_1^{n+1} = U_1^n + hU_2^n - \frac{h^2}{2} \sin(U_1^n) \\ U_2^{n+1} = U_2^n - h \sin(U_1^n) - \frac{h^2}{2} U_2^n \cos(U_1^n) \end{cases}.$$

Como se comparam as aproximações? Basta olhar as tabelas de antes e as imagens a seguir:



Vamos nos restringir ao caso escalar e obter aproximações de Taylor de ordens superiores:

$$u(t_n + h) = u(t_n) + hu'(t_n) + \frac{h^2}{2}u''(t_n) + \frac{h^3}{6}u'''(t_n) + O(h^4),$$

tal que, derivando,

$$\begin{aligned}
 \bullet u'(t_n) &= f(u(t_n), t_n) \\
 \bullet (f_u f + f_t) &\Big|_{(u(t_n), t_n)} \\
 \bullet u'''(t_n) &= \frac{d}{dt} u''(t_n) = \frac{d}{dt} (f_u f + f_t) \Big|_{(u(t_n), t_n)} \\
 &= [(f_{uu} f + f_{ut}) + (f_u f + f_t) f_u + (f_{tu} f + f_{tt})] \Big|_{u(t_n), t_n} \\
 &= [(f_{uu} f + f_{ut}) + (f_u f + f_t) f_u + (f_{tu} f + f_{tt})] \Big|_{u(t_n), t_n}
 \end{aligned}$$

Observação

É importante fazer algumas observações referentes ao método de Taylor – a precisão do método aumenta com q , mas a complexidade dos cálculos aumenta *bastante* para q maior que 3; apesar disso, é possível implementar métodos de Taylor de ordens superiores, inclusive para sistemas, fazendo diferenciações “espertas” diretamente no código.

A maior desvantagem disso é que ele exige diferenciabilidade de $\mathbf{f}$, que não é uma condição para a existência de uma solução e, conseqüentemente, o método não pode ser aplicado para problemas onde $\mathbf{f}$ perde suavidade.

Listing 1: Implementação de Taylor de ordem q para o pêndulo

```
1  function fd = fandd(t, y)
2
3  % linhas - ordem da derivada + 1
4  % colunas - numero da equacao
5
6  fd(1, 1) = y(2);
7  fd(1, 2) = -sin(y(1));
8
9  fd(2, 1) = fd(1, 2);
10 fd(2, 2) = -cos(y(1))*fd(1, 1);
11
12 fd(3, 1) = fd(2, 2);
13 fd(3, 2) = fd(1, 1)*sin(y(1))*fd(1, 1) - cos(y(1))*fd(2, 1)
```

9 Aula 09 - 13 de Abril, 2026

9.1 Motivações

- Método Geral de 1 passo;
- Método de Euler Explícito e Implícito;
- Aproximações não lineares;
- Método do Trapézio.

9.2 Método Geral de 1-passo

O método geral de 1-passo é dado pela expressão

$$\frac{\mathbf{U}^{n+1} - \mathbf{U}^n}{h} = \varphi(\mathbf{U}^{n+1}, \mathbf{U}^n, t_n, h).$$

Nele, se $\varphi = \varphi(\mathbf{U}^n, t_n, h)$, ou seja, se a função φ não depende de $\mathbf{U}^{n+1}$, ele é chamado **método explícito**, e caso dependa de $\mathbf{U}^{n+1}$, será chamado de **método implícito**.

Exemplo 16 (Métodos de 1-passo Explícitos). Alguns métodos que já vimos se enquadram nos métodos de 1-passo explícitos; dentre eles,

- Euler: nele, $\varphi(\mathbf{U}^n, t_n, h) = \mathbf{f}(\mathbf{U}^n, t_n)$;
- Taylor de ordem q : aqui, para $q = 2$, o método é do tipo

$$\varphi(\mathbf{U}^n, t_n, h) = \mathbf{f}(\mathbf{U}^n, t_n) + \frac{h}{2} \left(\frac{\partial \mathbf{f}}{\partial \mathbf{u}} \mathbf{f} + \frac{\partial \mathbf{f}}{\partial t} \right) \Big|_{(\mathbf{U}^n, t_n)}.$$

Definição. O erro de um passo é dado pela expressão

$$\mathcal{L}^n = \mathbf{u}(t_{n+1}) - \mathbf{u}(t_n) - h\varphi(\mathbf{u}(t_{n+1}), \mathbf{u}(t_n), t_n, h). \quad \square$$

Observe que, caso $\tilde{\mathbf{U}}^{n+1}$ é outra aproximação para a solução $\mathbf{u}(t_{n+1})$ calculada no tempo t_{n+1} , considerando-se que todos os passos anteriores foram resolvidos de maneira exata, ou seja, que

$$\tilde{\mathbf{U}}^{n+1} = \mathbf{u}(t_n) + h\varphi(\mathbf{u}(t_{n+1}), \mathbf{u}(t_n), t_n, h),$$

teremos

$$\begin{aligned}\tilde{\mathcal{E}}^{n+1} &= \mathbf{u}(t_{n+1}) - \tilde{\mathbf{U}}^{n+1} = \mathbf{u}(t_{n+1}) - \mathbf{u}(t_n) - h\varphi(\mathbf{u}(t_{n+1}), \mathbf{u}(t_n), t_n, h) \\ &= \mathcal{L}^n,\end{aligned}$$

ou seja, $\mathcal{L}^n$ é o erro cometido em um passo, considerando que todos os outros foram resolvidos exatamente.

Definição. O erro de truncamento do método de 1-passo é dado por

$$\tau^n = \frac{\mathbf{u}(t_{n+1}) - \mathbf{u}(t_n)}{h} - \varphi(\mathbf{u}(t_{n+1}), \mathbf{u}(t_n), t_n, h). \quad \square$$

Definição. Um método de um passo é dito **consistente com a equação diferencial** se

$$\lim_{h \rightarrow 0} \|\tau^n\| = 0.$$

Em particular, se $\|\tau^n\| = O(h^p)$ para algum inteiro $p \geq 1$, diremos que o método é **consistente de ordem p**. $\square$

Observe que

$$\|\tau^n\| = O(h^p) \iff \|\mathcal{L}^n\| = O(h^{p+1});$$

logo, não se deve confundir erro de um passo com erro de truncamento!!

Exemplo 17 (Erro de Truncamento do Método de Euler). Pela definição do erro de truncamento, temos

$$\begin{aligned}\tau^n &= \frac{1}{h}(\mathbf{u}(t_{n+1}) - \mathbf{u}(t_n)) - \varphi(\mathbf{u}(t_{n+1}), \mathbf{u}(t_n), t_n, h) \\ &= \frac{1}{h}(\mathbf{u}(t_{n+1}) - \mathbf{u}(t_n)) - \mathbf{f}(\mathbf{u}(t_n), t_n) \\ &= \frac{1}{h} \left(\mathbf{u}(t_n) + h\mathbf{u}'(t_n) + \frac{h^2}{2}\mathbf{u}''(t_n) + \dots - \mathbf{u}(t_n) \right) - \mathbf{f}(\mathbf{u}(t_n), t_n) \\ &= \frac{h}{2}\mathbf{u}''(t_n) + \dots \\ &= O(h).\end{aligned}$$

Portanto, o método de Euler é consistente de ordem $O(h)$; note ainda que $\mathcal{L}^n = h\tau^n = O(h^2)$.

Teorema. Um método geral de um passo é consistente com a equação diferencial

$$\mathbf{u}'(t) = \mathbf{f}(\mathbf{u}(t), t) \text{ se}$$

$$\lim_{h \rightarrow 0} \varphi(\mathbf{u}(t+h), \mathbf{u}(t), t, h) = \mathbf{f}(\mathbf{u}(t), t).$$

Prova. Segue da definição de erro de truncamento, passando o limite, que

$$\begin{aligned} \lim_{h \rightarrow 0} \tau^n &= \lim_{h \rightarrow 0} \frac{\mathbf{u}(t_n + h) - \mathbf{u}(t_n)}{h} - \lim_{h \rightarrow 0} \varphi(\mathbf{u}(t_n + h), \mathbf{u}(t_n), t_n, h) \\ &= \mathbf{u}'(t_n) - \lim_{h \rightarrow 0} \varphi(\mathbf{u}(t_n + h), \mathbf{u}(t_n), t_n, h) \\ &= \mathbf{f}(\mathbf{u}(t_n), t_n) - \lim_{h \rightarrow 0} \varphi(\mathbf{u}(t_n + h), \mathbf{u}(t_n), t_n, h) \\ &= 0. \blacksquare \end{aligned}$$

Exemplo 18 (Consistência do Método de Taylor de $q = 2$). O método é consistente pois (verifique!)

$$\lim_{h \rightarrow 0} \varphi(\mathbf{u}(t_n + h), \mathbf{u}(t_n), t_n, h) = \mathbf{f}(\mathbf{u}(t_n), t_n).$$

Quanto à ordem de consistência, segue que

$$\begin{aligned} \tau^n &= \frac{1}{h}(\mathbf{u}(t_n + h) - \mathbf{u}(t_n)) - \mathbf{f}(\mathbf{u}(t_n), t_n) - \frac{h}{2} \left(\frac{\partial \mathbf{f}}{\partial \mathbf{u}} \mathbf{f} + \frac{\partial \mathbf{f}}{\partial t} \right) \Big|_{(\mathbf{u}(t_n), t_n)} \\ &= \frac{1}{h} \left(\mathbf{u}(t_n) + h\mathbf{u}'(t_n) + \frac{h^2}{2}\mathbf{u}''(t_n) + \dots - \mathbf{u}(t_n) \right) - \mathbf{u}'(t_n) - \frac{h}{2}\mathbf{u}''(t_n) \\ &= \frac{h^2}{6}\mathbf{u}'''(t_n) + \dots \\ &= \mathcal{O}(h^2). \end{aligned}$$

Portanto, o método de Taylor $q = 2$ é consistente de ordem $\mathcal{O}(h^2)$.

Definição. Dizemos que um método geral de um passo na forma

$$\mathbf{U}^{n+1} = \mathbf{U}^n + h\varphi(\mathbf{U}^{n+1}, \mathbf{U}^n, t_n, h)$$

converge para a solução exata do PVI

$$\begin{cases} \mathbf{u}'(t) = \mathbf{f}(\mathbf{u}(t), t) \\ \mathbf{u}(0) = \mathbf{u}^0 \end{cases}$$

se, para qualquer tempo T considerado dentro do intervalo de solução, tem-se

$$\lim_{\substack{h \rightarrow 0 \\ Nh=T}} \mathbf{U}^N = \mathbf{u}(T) \text{ ou } \lim_{\substack{h \rightarrow 0 \\ Nh=T}} \|\mathbf{U}^N - \mathbf{u}(T)\| = 0,$$

para qualquer condição inicial $\mathbf{U}^0$ satisfazendo $\lim_{h \rightarrow 0} \mathbf{U}^0 = \mathbf{u}^0$. $\square$

Definição. Um método geral de um passo é dito **convergente de ordem p** se existe $C > 0$ tal que, para qualquer $T = Nh$,

$$\|\mathbf{U}^N - \mathbf{u}(T)\| \leq Ch^p. \square$$

Existe uma versão do [Teorema de Picard-Lindelöf](#) para os métodos de um passo:

Teorema (Convergência de Métodos de 1-Passo). *Um método geral de um passo que seja consistente de ordem p será convergente de ordem p se, existir um valor L positivo tal que*

$$\|\varphi(\mathbf{v}, \mathbf{y}, t, h) - \varphi(\mathbf{w}, \mathbf{z}, t, h)\| \leq L(\|\mathbf{v} - \mathbf{w}\| + \|\mathbf{y} - \mathbf{z}\|)$$

para todo $(\mathbf{v}, \mathbf{y}, t, h)$ e $(\mathbf{w}, \mathbf{z}, t, h)$, ou seja, se $\varphi(\cdot, \cdot, t, h)$ for Lipschitz contínua com constante de Lipschitz L .

No caso dos métodos explícitos, podemos derrubar uma das coordenadas, escrevendo no lugar:

$$\|\varphi(\mathbf{v}, t, h) - \varphi(\mathbf{w}, t, h)\| \leq L\|\mathbf{v} - \mathbf{w}\|, \quad \forall (\mathbf{v}, t, h), (\mathbf{w}, t, h).$$

Note que a consistência de ordem p **não implica** na convergência de ordem p : a condição para que isso acabe ocorrendo é que a função $\varphi(\cdot, \cdot, t, h)$ que define o método seja Lipschitz contínua. Apesar disso, na maioria dos métodos, essa propriedade decorre diretamente do fato da própria $\mathbf{f}(\cdot, t)$ ser Lipschitz contínua.

Exemplo 19 (Convergência do Método de Taylor $q = 2$). Como já vimos alguns resultados, a convergência decorrerá ao amostrarmos que $\varphi(\cdot, t, h)$ é Lipschitz contínua.

Sem perda de generalidade, consideremos um sistema autônomo da forma $\mathbf{u}'(t) = \mathbf{f}(\mathbf{u}(t))$; note que, sendo a própria $\mathbf{f}(\cdot)$ Lipschitz contínua com constante $L > 0$, obtemos

$$\left| \frac{\partial f_i}{\partial u_j} \right| = \lim_{\varepsilon \rightarrow 0} \left| \frac{f_i(\mathbf{u} + \varepsilon \mathbf{e}_j) - f_i(\mathbf{u})}{\varepsilon} \right| \leq \lim_{\varepsilon \rightarrow 0} L \left\| \frac{\mathbf{u} + \varepsilon \mathbf{e}_j - \mathbf{u}}{\varepsilon} \right\| = L,$$

tal que existe $C > 0$ satisfazendo

$$\left\| \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \right\| \leq CL,$$

a depender da norma escolhida para a matriz Jacobiana.

Por definição, temos

$$\begin{aligned}\|\varphi(\mathbf{v}, t, h) - \varphi(\mathbf{w}, t, h)\| &= \left\| \mathbf{f}(\mathbf{v}) + \frac{h}{2} \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \mathbf{f}(\mathbf{v}) - \mathbf{f}(\mathbf{w}) - \frac{h}{2} \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \mathbf{f}(\mathbf{w}) \right\| \\ &\leq \|\mathbf{f}(\mathbf{v}) - \mathbf{f}(\mathbf{w})\| + \frac{h}{2} \left\| \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \right\| \|\mathbf{f}(\mathbf{v}) - \mathbf{f}(\mathbf{w})\| \\ &\leq \left(L + \frac{h}{2} C L^2 \right) \|\mathbf{v} - \mathbf{w}\|.\end{aligned}$$

Portanto, $\varphi(\cdot, t, h)$ é Lipschitz contínua e o método de Taylor $q = 2$ é convergente de ordem $\mathcal{O}(h^2)$.

Podemos começar a explorar os métodos implícitos, e assim como o início foi marcado pelo método de Euler explícito, veremos sua versão alternativa. O primeiro passo é expandir $\mathbf{u}(t_n) = \mathbf{u}(t_{n+1} - h)$ em Taylor ao redor de t_{n+1} , obtendo

$$\mathbf{u}(t_n) = \mathbf{u}(t_{n+1} - h) = \mathbf{u}(t_{n+1}) - h\mathbf{u}'(t_{n+1}) + \underbrace{\frac{h^2}{2}\mathbf{u}''(t_{n+1}) + \dots}_{\mathcal{O}(h^2)},$$

seguido da substituição $\mathbf{u}'(t_{n+1}) = \mathbf{f}(\mathbf{u}(t_{n+1}), t_{n+1})$ e do descarte dos termos $\mathcal{O}(h^2)$, resultando no **Método de Euler Implícito**:

$$\boxed{\mathbf{U}^{n+1} = \mathbf{U}^n + h\mathbf{f}(\mathbf{U}^{n+1}, t_{n+1})},$$

de modo que a solução $\mathbf{U}^{n+1}$ passa a ser descrita implicitamente.

Vale observar que, caso $\mathbf{f}$ for, ainda por cima, uma função não linear de $\mathbf{u}$, então $\mathbf{U}^{n+1}$ só pode ser obtida resolvendo-se o problema não linear resultante, que obviamente vai dar mais trabalho, mas aumenta a gama de problemas que podem ser modelados.

Consideremos, agora, a equação diferencial $\mathbf{u}'(t) = \mathbf{f}(\mathbf{u}(t), t)$; integrando ambos os lados, obtemos a equação

$$\int_{t_n}^{t_{n+1}} \mathbf{u}'(t) dt = \int_{t_n}^{t_{n+1}} \mathbf{f}(\mathbf{u}(t), t) dt,$$

sendo que a integral à esquerda pode ser resolvida pelo teorema fundamental do cálculo, mas o lado direito requer uma aproximação por uma fórmula de quadratura;

utilizando a regra do trapézio, temos:

$$\mathbf{u}(t_{n+1}) - \mathbf{u}(t_n) \approx \frac{h}{2}(\mathbf{f}(\mathbf{u}(t_{n+1}), t_{n+1}) + \mathbf{f}(\mathbf{u}(t_n), t_n)),$$

da qual tiramos o método implícito conhecido como **método do trapézio**:

$$\boxed{\mathbf{U}^{n+1} = \mathbf{U}^n + \frac{h}{2}(\mathbf{f}(\mathbf{U}^{n+1}, t_{n+1}) + \mathbf{f}(\mathbf{U}^n, t_n))}$$

Exemplo 20 (Trapézio para Lotka-Volterra). A função do modelo da presa-predador que vimos era da forma

$$\mathbf{f}(\mathbf{u}(t), t) = \begin{bmatrix} -2u_1(t) + u_1(t)u_2(t) \\ u_2(t) - u_1(t)u_2(t) \end{bmatrix},$$

tal que a aplicação do método do trapézio torna-se

$$\begin{bmatrix} U_1^{n+1} \\ U_2^{n+1} \end{bmatrix} = \begin{bmatrix} U_1^n \\ U_2^n \end{bmatrix} + \frac{h}{2} \left(\begin{bmatrix} -2U_1^{n+1} + U_1^{n+1}U_2^{n+1} \\ U_2^{n+1} - U_1^{n+1}U_2^{n+1} \end{bmatrix} + \begin{bmatrix} -2U_1^n + U_1^nU_2^n \\ U_2^n - U_1^nU_2^n \end{bmatrix} \right),$$

ou ainda

$$\begin{bmatrix} U_1^{n+1} \\ U_2^{n+1} \end{bmatrix} - \frac{h}{2} \begin{bmatrix} -2U_1^{n+1} + U_1^{n+1}U_2^{n+1} \\ U_2^{n+1} - U_1^{n+1}U_2^{n+1} \end{bmatrix} - \begin{bmatrix} U_1^n \\ U_2^n \end{bmatrix} - \frac{h}{2} \begin{bmatrix} -2U_1^n + U_1^nU_2^n \\ U_2^n - U_1^nU_2^n \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix},$$

caracterizando um sistema não linear da forma $\mathbf{G}(\mathbf{x}_{n+1}) = \mathbf{0}$.

Assim sendo, para encontrar $\mathbf{x}_{n+1}$, utilizamos o método de Newton, consistindo em iterar aproximações sucessivas $\mathbf{x}^k$ utilizando

$$\mathbf{x}^{k+1} = \mathbf{x}^k - J(\mathbf{x}^k)^{-1} \mathbf{G}(\mathbf{x}^k)$$

para $k = 0, 1, 2, \dots$, conforme vimos anteriormente, e que, no fim, equivale a resolver

$$\begin{aligned} J(\mathbf{x}^k) \boldsymbol{\delta}^k &= -\mathbf{G}(\mathbf{x}^k) \\ \mathbf{x}^{k+1} &= \mathbf{x}^k + \boldsymbol{\delta}^k \end{aligned}$$

até que haja convergência, por exemplo pedindo um valor mínimo de delta como $\|\boldsymbol{\delta}^k\| < \varepsilon$; para iniciar este processo iterativo, devemos dar um chute inicial

$$\mathbf{x}_0 = \begin{bmatrix} U_1^n \\ U_2^n \end{bmatrix},$$

calcular a matriz jacobiana

$$J(\mathbf{x}^k) = \begin{bmatrix} 1 + h - \frac{h}{2}\mathbf{x}_2^k & -\frac{h}{2}\mathbf{x}_1^k \\ \frac{h}{2}\mathbf{x}_2^k & 1 - \frac{h}{2} + \frac{h}{2}\mathbf{x}_1^k \end{bmatrix}$$

e, ao final do processo iterativo, as componentes do $\mathbf{x}^{k+1}$ mais atual possuirão aproximações para a solução no tempo t_{n+1}

$$\mathbf{x} = \begin{bmatrix} U_1^{n+1} \\ U_2^{n+1} \end{bmatrix}.$$

Posteriormente, deve-se avançar ao passo seguinte e repetir o procedimento.

Uma implementação desse código em Matlab seria

```

1  function G = G_pp(u, un, h)
2
3      G(1)=u(1)-0.5*h*(-2*u(1)+u(1)*u(2))-un(1)-0.5*h*(-2*un(1)+un(1)*un(2));
4
5      G(2)=u(2)-0.5*h*(u(2)-u(1)*u(2))-un(2)-0.5*h*(un(2)-un(1)*un(2));
6
7  function J = Jac_pp(u, h)
8
9      J(1,1)= 1.0+h - 0.5*h*u(2);
10     J(1,2)=-0.5 * h * u(1);
11     J(2,1)=1.0-0.5*h+0.5*h*u(1);
12     J(2,2)=0.5*h*u(2);
13
14     ...
15     while tn < tfim
16         x = un;
17         for i=1:M
18             J = Jac_pp(x, h);
19             G = G_pp(x, un, h);
20             delta = J\(-G);
21             x = x + delta;
22         end
23         uni=x;
24         tn=tn+h;
25         un=un1;
26     end
27     ...

```

Neste ponto, vale a pena introduzir a família θ de métodos, que trata-se de uma família metodológica dependente em um parâmetro $0 \leq \theta \leq 1$, cujos membros são dados por

$$U^{n+1} = U^n + h(\theta f(U^{n+1}, t_{n+1}) + (1 - \theta)f(U^n, t_n)),$$

e qual a importância deles? Ora, basta observar que os métodos vistos até agora são todos parte dela:

-
- $\theta = 0$: método de Euler explícito;
 - $\theta = 1$: método de Euler implícito;
 - $\theta = 1/2$: método do trapézio.

Exercício 4. Mostre que o método θ é convergente e calcule sua ordem de convergência dependendo do parâmetro θ ; daí, conclua a convergência para os casos $\theta = 1$ e $\theta = \frac{1}{2}$.

10 Aula 10 - 15 de Abril, 2026

10.1 Motivações

- Métodos Preditor-Corretor

10.2 Métodos do tipo Preditor-Corretor

Esse tipo de método é uma estratégia para utilizar métodos implícitos sem recorrer ao método de Newton. Por isso, considere o seguinte método implícito:

$$\mathbf{U}^{n+1} = \mathbf{U}^n + h\varphi_c(\mathbf{U}^{n+1}, \mathbf{U}, t_n, h);$$

pode-se definir um processo iterativo para determinar $\mathbf{U}^{n+1}$, como por exemplo

$$\mathbf{U}^{n+1,[s+1]} = \mathbf{U}^n + h\varphi_c(\mathbf{U}^{n+1,[s]}, \mathbf{U}^n, t_n, h), \quad s = 0, 1, 2, \dots, m-1.$$

O valor inicial desse processo iterativo pode ser obtido por um método explícito da forma

$$\mathbf{U}^{n+1,[0]} = \mathbf{U}^n + h\varphi_p(\mathbf{U}^n, t_n, h).$$

Neste contexto, o método definido por φ_p é chamado **preditor**, e o método definido por φ_c é o **corretor**, e o processo total é conhecido como **método preditor-corretor**, especificamente PC^m .

Exemplo 21 (Euler-Trapézio). Considere o método preditor φ_p como sendo, por exemplo, o método de Euler, e o corretor como sendo o método do trapézio; neste caso, o método preditor-corretor PC^m é dado por

$$\mathbf{U}^{n+1,[0]} = \mathbf{U}^n + hf(\mathbf{U}^n, t_n)$$

$$\mathbf{U}^{n+1,[s+1]} = \mathbf{U}^n + \frac{h}{2}(f(\mathbf{U}^{n+1,[s]}, t_{n+1}) + f(\mathbf{U}^n, t_n)), \quad s = 0, \dots, m-1.$$

A convergência desse método ocorre se existe uma jacobiana J_G com norma $\|J_G\| \leq \mathcal{J} < 1$, pois, neste caso,

$$\|\mathbf{x}^{k+1} - \mathbf{x}^k\| \leq \mathcal{J}\|\mathbf{x}^k - \mathbf{x}^k\|.$$

Existe um teorema nos dá uma estimativa do número de iterações necessárias para atingir a ordem máxima de convergência, e qual ela é:

Teorema. *Seja p a ordem de consistência do método preditor e q a ordem do mé-*

todo corretor; então, o método preditor-corretor PC^m tem ordem de consistência $O(h^{\min(q,p+m)})$.

Em termos de precisão, ele não diz muita coisa, mas não adiantam muitas iterações, pois o erro geral do método é limitado pelo erro de truncamento, que, por sua vez, depende de potências de h ; o mesmo vale quando se utiliza diretamente do método de Newton para o problema não linear! Uma boa coisa desse método é para fazer previsões temporais!

Exemplo 22 (Preditor-Corretor para Lotka-Volterra). O preditor aqui é o método de Euler explícito, dado por

$$\begin{bmatrix} U_1^{n+1,[0]} \\ U_2^{n+1,[0]} \end{bmatrix} = \begin{bmatrix} U_1^n \\ U_2^n \end{bmatrix} + h \begin{bmatrix} -2U_1^n + U_1^n U_2^n \\ U_2^n - U_1^n U_2^n \end{bmatrix},$$

e o corretor seria o trapézio

$$\begin{bmatrix} U_1^{n+1,[s+1]} \\ U_2^{n+1,[s+1]} \end{bmatrix} = \begin{bmatrix} U_1^n + \frac{h}{2} \left(\begin{bmatrix} -2U_1^{n+1,[s]} + U_1^{n+1,[s]} U_2^{n+1,[s]} \\ U_2^{n+1,[s]} - U_1^{n+1,[s]} U_2^{n+1,[s]} \end{bmatrix} + \begin{bmatrix} -2U_1^n + U_1^n U_2^n \\ U_2^n - U_1^n U_2^n \end{bmatrix} \right) \end{bmatrix}.$$

Implementado como código, temos

Listing 2: Implementação Preditor-Corretor de Lotka-Volterra

```
1  function fd = f_pp ( u)
2
3  fd (1 ,1) = -2* u (1) + u (1) *u (2) ;
4  fd (1 ,2) = u (2) - u (1) * u (2) ;
5
6  ...
7  while tn < tfim
8
9      fn = f_pp ( un ) ;
10
11     % Preditor Euler explicito
12     un1 = un + h * fn (1 ,:) ;
13
14     % Corretor trapezio
15     for i =1: M
16         fn1 = f_pp ( un1 );
17         un1 = un + 0.5* h *( fn (1 ,:) + fn1 (1 ,:) ) ;
18     end
19
20     tn = tn + h;
21     un = un1 ;
22
23 end
24 ...
```

O gráfico resultante é






Figura 9: comparação da população da presa com a do predador


As imagens de cada um dos métodos ajudam bem a ver como eles se comparam:

Figura 10: erros de diferentes métodos nas próximas imagens





E é interessante comparar os erros do método de Newton com o PC^m para lidar com implícitos.



No fim, fica a pergunta: por que usar os métodos implícitos, se eles são mais difíceis de serem calculados? Vamos ver um exemplo que responda isso.

Considere um problema linear da forma

$$u'(t) = -\lambda u(t), \quad u(0) = 1$$

com $\lambda > 0$, cuja solução exata é $u(t) = e^{-\lambda t}$, de modo que

$$\lim_{t \rightarrow \infty} u(t) = 0.$$

O método de Euler explícito para esse caso simples fica

$$\begin{aligned} U^{n+1} &= U^n - h\lambda U^n = (1 - h\lambda)U^n = (1 - h\lambda)^2 U^{n-1} \\ &\vdots \\ &= (1 - h\lambda)^n U^0, \end{aligned}$$

tal que a solução aproximada satisfaz

$$\lim_{n \rightarrow \infty} U^n = 0 \iff |1 - h\lambda| < 1.$$

O problema disso é que acaba impondo uma restrição sobre a escolha do passo h , que, caso não seja satisfeita, pode produzir soluções desastrosas nas quais U^n diverge ao infinito! No caso do método de Euler explícito, a restrição é

$$h < \frac{2}{\lambda}.$$

Por outro lado, vamos replicar as ideias acima para um método implícito, digamos o trapézio; nele, tem-se

$$U^{n+1} = U^n - \frac{h}{2}(\lambda U^n + \lambda U^{n+1}) \Rightarrow U^{n+1} = \left(\frac{1 - \frac{h\lambda}{2}}{1 + \frac{\lambda h}{2}} \right)^n U^0,$$

donde concluímos que, independente da escolha de h , teremos $\lim_{n \rightarrow \infty} U^n = 0$ – métodos implícitos são mais robustos! O mesmo acontece até para o método de Euler implícito.

10.3 Estabilidade Absoluta

Consideremos um problema escalar linear da forma

$$u'(t) = \lambda u(t), \quad u(0) = \lambda, \quad \lambda \in \mathbb{C},$$

cujas soluções são da forma

$$u(t) = \lambda e^{\lambda t} = \lambda e^{(\operatorname{Re}(\lambda) + i\operatorname{Im}(\lambda))t} \Rightarrow |u(t)| = \lambda e^{\operatorname{Re}(\lambda)t},$$

onde $\text{Re}(\cdot)$ e $\text{Im}(\cdot)$ denotam, respectivamente, as partes reais e imaginárias da expressão. Com isso, temos alguns casos relacionados ao crescimento da solução:

$\text{Re}(\lambda) > 0$: aqui, a solução $|u(t)|$ cresce exponencialmente com t , tornando-se *instável*;

$\text{Re}(\lambda) = 0$: neste caso, a solução é $|u(t)| = \lambda$, e ela fica oscilando;

$\text{Re}(\lambda) < 0$: finalmente, $|u(t)|$ decai exponencialmente com t , sendo *estável*.

O caso que mais nos interessa inicialmente é a estabilidade do método numérico, então analisaremos este último caso.

Definição. Um método geral de um passo é dito **absolutamente estável** se, ao aplicarmos ele ao problema linear

$$u'(t) = \lambda u(t), \quad u(0) = \lambda, \quad \lambda \in \mathbb{C}, \quad \text{Re}(\lambda) < 0,$$

a solução é tal que

$$\lim_{n \rightarrow \infty} U^n = 0$$

para qualquer escolha de h . Caso haja uma condição sobre h para que o limite seja zero, diremos que o método é **condicionalmente estável**. $\square$

Observação

Em geral, métodos implícitos são mais estáveis que os métodos explícitos, permitindo a escolha de passos h maiores para garantir uma solução aceitável.

Definição. A **região de estabilidade absoluta** associada a um método numérico utilizado para aproximar o PVI

$$u'(t) = \lambda u(t), \quad u(0) = \lambda, \quad \lambda \in \mathbb{C}, \quad \text{Re}(\lambda) < 0$$

é o conjunto $S \subseteq \mathbb{C}$ dado por

$$S = \{z = \lambda h, \quad h \in \mathbb{R}_+ : \lim_{n \rightarrow \infty} U^n = 0\}. \quad \square$$


A análise de região de estabilidade absoluta é uma das mais interessantes nas aplicações do mundo real!

Exemplo 23 (Estabilidade do Método de Euler Explícito). Para o método de Euler explícito, temos

$$\lim_{n \rightarrow \infty} U^n = 0 \iff |1 + z| < 1,$$

com $z = h\lambda$, $\lambda \in \mathbb{C}$.

Logo, o conjunto S consiste no interior do disco no plano complexo, centrado em -1 e com raio 1 :



11 Aula 11 - 20 de Abril, 2026

11.1 Motivações

- Métodos de Runge-Kutta


Exemplo 24 (Estabilidade do Método de Euler Implícito). ATENÇÃO: a notação vetorial pode ser indicada por um *vetor* *underline*!

Para o método implícito, temos

$$\lim_{n \rightarrow \infty} U^n = 0 \iff |1 - z| > 1,$$

onde $z = h\lambda, \lambda \in \mathbb{C}$.

Logo, em contraste ao explícito, a região de estabilidade do método de Euler implícito é a região exterior ao disco de centro em 1 e raio 1:




Exemplo 25 (Estabilidade do Método do Trapézio). Sendo $\lambda \in \mathbb{C}$, temos

$$\lim_{n \rightarrow \infty} U^n = 0 \iff \left| \frac{1 + \frac{z}{2}}{1 - \frac{z}{2}} \right| < 1,$$

que acontece apenas quando $\text{Re}(z) < 0$.

Desse modo, a região de estabilidade do método do trapézio é todo o lado esquerdo do plano complexo:



Considere agora um sistema linear de EDO's dado por

$$\mathbf{u}'(t) = \mathbf{A}\mathbf{u}(t), \quad \mathbf{u}(0) = \underline{\lambda},$$

onde $\mathbf{A} \in \mathbb{R}^{m \times m}$ é constante e diagonalizável.

Como ela é diagonalizável, existem m autovetores linearmente independentes para a matriz $\mathbf{A}$; denotando-os por $\mathbf{v}^i$, eles são associados a m autovalores $\lambda_i \in \mathbb{C}$, tal que

$$\mathbf{A}\mathbf{v}^i = \lambda_i\mathbf{v}^i, \quad i = 1, \dots, m.$$

Seja, também, $\mathbf{R} = [\mathbf{v}^1, \mathbf{v}^2, \dots, \mathbf{v}^m]$ a matriz cujas colunas são os autovetores $\mathbf{v}^i$, e $\mathbf{\Lambda}$ uma matriz diagonal com os autovalores λ_i , de forma que a diagonalizabilidade de $\mathbf{A}$ permite escrevermos

$$\mathbf{A} = \mathbf{R}\mathbf{\Lambda}\mathbf{R}^{-1}$$

e, assim,

$$\mathbf{\Lambda} = \mathbf{R}^{-1}\mathbf{A}\mathbf{R}.$$

Portanto, faz sentido definir a transformação linear

$$\mathbf{v}(t) = \mathbf{R}^{-1}\mathbf{u}(t) \Rightarrow \mathbf{v}'(t) = \mathbf{R}^{-1}\mathbf{u}'(t),$$

tal que

$$\begin{aligned} \mathbf{u}'(t) &= \mathbf{A}\mathbf{u}(t) \\ \Rightarrow \mathbf{R}^{-1}\mathbf{u}'(t) &= \mathbf{R}^{-1}\mathbf{A}\mathbf{R}\mathbf{R}^{-1}\mathbf{u}(t) \\ \Rightarrow \mathbf{v}'(t) &= \mathbf{R}^{-1}\mathbf{A}\mathbf{R}\mathbf{v}(t) \\ \Rightarrow \mathbf{v}'(t) &= \mathbf{\Lambda}\mathbf{v}(t), \end{aligned}$$

transformando o sistema de EDO's no sistema desacoplado

$$v_j'(t) = \lambda_j v_j(t), \quad j = 1, 2, \dots, m.$$

Definição. Um método geral de um passo é dito **absolutamente estável** para um sistema linear da forma

$$u'(t) = Au(t), \quad u(0) = \underline{\lambda},$$

onde A é uma matriz m por m real e diagonalizável, se $z_j = h\lambda_j \in \mathcal{S}$ para todos os autovalores λ_j da matriz A , qualquer que seja a escolha de $h > 0$.

Caso haja uma condição sobre h para que essa condição seja satisfeita, o método é dito **condicionalmente estável**. $\square$

Exemplo 26. Considere o sistema de EDOs rígidas

$$\begin{aligned} u_1' &= -5u_1 + 3u_2 \\ u_2' &= 100u_1 - 301u_2, \end{aligned}$$

que pode ser reescrito como

$$u'(t) = \begin{bmatrix} -5 & 3 \\ 100 & -301 \end{bmatrix} u(t)$$

Quando decompomos o espectro, é como se saíssemos de um problema de um monte de ondas acopladas para suas componentes individuais! Os autovalores λ_1, λ_2 dessa matriz serão usados, então, para determinar a região de estabilidade absoluta por meio de

$$|1 + \lambda_1 h| < 1 \quad \& \quad |1 + \lambda_2 h| < 1.$$

Para sistemas não lineares, como $u' = f(u)$, a análise de estabilidade vista até agora falha em ser aplicada; no entanto, se a solução variar lentamente em relação aos passos temporais, então podemos linearizar ele de forma aproximada dentro do intervalo para ter uma noção decente do que está acontecendo:

$$u'(t) = f(u(t)) = f(v(t) + \bar{u}),$$

onde a linearização foi do tipo $u(t) = v(t) + \bar{u}$, $u'(t) = v'(t)$.

Daí, expandindo em Taylor em torno de $v(t)$ à ordem 2,

$$v'(t) = f(\bar{u}) + f'(\bar{u})v(t) + O(\|v\|^2),$$

tal que, derrubando o termo do erro, obtemos o sistema linear

$$\mathbf{v}'(t) = \mathbf{A}\mathbf{v}(t) + \mathbf{b},$$

sendo $\mathbf{A} = \mathbf{f}'(\bar{\mathbf{u}})$ a matriz Jacobiana avaliada em $\bar{\mathbf{u}}$, e $\mathbf{b} = \mathbf{f}(\bar{\mathbf{u}})$.

Desta forma, examinar como esse método numérico se comporta para esse sistema linear em cada valor relevante de $\bar{\mathbf{u}}$ fornece uma boa ideia de como ele se comportará no caso do sistema não linear também! O problema é que, se houver uma região de não linearidade muito súbita ou intensa, esse método de linearização falha!

Exemplo 27. Vamos considerar o exemplo do pêndulo

$$\begin{cases} u_1'(t) = u_2(t) \\ u_2'(t) = -\sin(u_1(t)) \end{cases}.$$

Pelo que vimos, precisamos calcular a matriz jacobiana associada à função $\mathbf{f}(\mathbf{u}(t)) = (u_2(t), -\sin(u_1(t)))$ desse sistema:

$$\mathbf{A} = \frac{\partial \mathbf{f}}{\partial \mathbf{u}} = \begin{pmatrix} \frac{\partial f_1}{\partial u_1} & \frac{\partial f_1}{\partial u_2} \\ \frac{\partial f_2}{\partial u_1} & \frac{\partial f_2}{\partial u_2} \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ -\cos(u_1(t)) & 0 \end{pmatrix}$$

Queremos saber se o problema, com a matriz jacobiana, é estável; quanto aos autovalores, temos

$$\begin{aligned} \det(\mathbf{A} - \lambda \mathbf{I}) = 0 &\Rightarrow \det \begin{bmatrix} -\lambda & 1 \\ -\cos(u_1(t)) & -\lambda \end{bmatrix} = 0 \\ &\Rightarrow \lambda^2 + \cos(u_1(t)) = 0 \\ &\Rightarrow \lambda = \pm \sqrt{-\cos(u_1(t))} \end{aligned}$$

Fixando no intervalo $\left[-\frac{\pi}{2}, \frac{\pi}{2}\right]$ por sua utilidade física, o cosseno é sempre positivo e os autovalores serão sempre da forma

$$\lambda = \pm i\sqrt{\cos(u_1(t))},$$

ou seja, se quiséssemos resolver o pêndulo com o método de Euler para a solução não explodir catastróficamente, precisaríamos de um h tal que $|1 + \lambda_i h| < 1 \dots$ O problema é que não existe h que satisfaça isso! O método de Euler não funciona!!

Portanto, a conclusão é: **não use o método de Euler.**


Observação

Quando vimos a aproximação com o método de Euler, não foi o caso dela explodir catastroficamente, e o motivo para essa “inconsistência” com a análise acima é que o termo de erro pode sim incluir alguns pontos onde o método não irá explodir; porém, visando sempre *reduzir os erros*, a escolha menos errada é não utilizar o método de Euler para não depender dessa sorte!

11.2 Métodos Runge-Kutta Explícitos

Até o momento, estivemos usando o método de Taylor para as nossas aproximações, e já vimos alguns dos problemas que ele tem. Será que existem métodos diferentes para aproximar nossas equações? A ideia é que sim, existem outros, e veremos um deles a seguir: o método de Runge-Kutta, que também tem suas versões explícita e implícita, mas focaremos apenas na primeira.

Quando utilizamos o método de Euler explícito, existe uma ideia geométrica que faz uso de retas conectando os valores por trás dos panos:




Porém, e se utilizarmos um monte de inclinações intermediárias para chegar à final? O custo certamente aumentará, mas ganharemos um tanto de precisão! Para isso, utilizamos

$$U^{n+1} = U^n + h\varphi(U^n, t_n, h),$$

com

$$\varphi(U^n, t_n, h) = \sum_j b_j f(Z^j, t_{k_j}),$$

onde t_k são os passos intermediários entre t_{j-1} e t_j : aumentamos a ordem de precisão calculando inclinações em passos intermediários, e é essa a ideia dos *métodos tipo Runge-Kutta*



A forma geral dos **Métodos Runge-Kutta Explícitos de R Estágios** é:

$$\begin{aligned} \mathbf{K}^1 &= \mathbf{f}(\mathbf{U}^n, t_n) \\ \mathbf{K}^2 &= \mathbf{f}(\mathbf{U}^n + h\mathbf{a}_{21}\mathbf{K}^1, t_n + hc_2) \\ \mathbf{K}^3 &= \mathbf{f}(\mathbf{U}^n + h\mathbf{a}_{31}\mathbf{K}^1 + h\mathbf{a}_{32}\mathbf{K}^2, t_n + hc_3) \\ &\vdots \\ \mathbf{K}^R &= \mathbf{f}\left(\mathbf{U}^n + h \sum_{j=1}^{R-1} \mathbf{a}_{Rj}\mathbf{K}^j, t_n + hc_R\right) \\ \mathbf{U}^{n+1} &= \mathbf{U}^n + h \sum_{j=1}^R b_j \mathbf{K}^j, \end{aligned}$$

de forma que o método é completamente determinado pelo coeficientes $\mathbf{a}_{ij}$, b_j e c_j , que não são determinadas exatamente e precisam ser determinadas ao longo do método!

Como foi deixado bem aparente, dá para fazer uma representação dessa classe de métodos com matrizes:

$$\begin{array}{c|ccccc}
0 & 0 & & & & \\
c_2 & a_{21} & 0 & & & \\
c_3 & a_{31} & a_{32} & 0 & & \\
\vdots & \vdots & \vdots & \ddots & \ddots & \\
c_R & a_{R1} & a_{R2} & \dots & a_{R,R-1} & 0 \\
\hline
& b_1 & b_2 & \dots & b_{R_1} & b_R
\end{array}$$

Ou, de forma mais curta,

$$\begin{array}{c|c}
\mathbf{c} & \mathbf{A} \\
\hline
& \mathbf{b}^t
\end{array}$$

onde $\mathbf{A}$ é uma matriz triangular inferior com diagonal nula e $c_1 = 0$.

Um **método RK de 1 estágio** é simplificado da forma geral e dado por

$$\boxed{\mathbf{U}^{n+1} = \mathbf{U}^n + hb_1\mathbf{f}(\mathbf{U}^n, t_n)}$$

É basicamente um método de Euler.

Observação

Nesse ponto, já deu pra perceber que o método de Euler é basicamente um elemento neutro dos métodos numéricos :p

Quanto ao seu erro de truncamento,

$$\begin{aligned}
\tau^n &= \frac{1}{h}(\mathbf{u}(t_{n+1}) - \mathbf{u}(t_n)) - b_1\mathbf{f}(\mathbf{u}(t_n), t_n) \\
&= \frac{1}{h}\left(\mathbf{u}(t_n) + h\mathbf{u}'(t_n) + \frac{h^2}{2}\mathbf{u}''(t_n) + \dots - \mathbf{u}(t_n)\right) - b_1\mathbf{f}(\mathbf{u}(t_n), t_n) \\
&= (1 - b_1)\mathbf{u}'(t_n) + \frac{h}{2}\mathbf{u}''(t_n) + \dots
\end{aligned}$$

Logo, para que o método seja consistente de ordem $\mathcal{O}(h)$, devemos ter $b_1 = 1$.

A forma geral dos **métodos RK de 2 estágios** é

$$\begin{aligned}
\mathbf{K}^1 &= \mathbf{f}(\mathbf{U}^n, t_n) \\
\mathbf{K}^2 &= \mathbf{f}(\mathbf{U}^n + ha_{21}\mathbf{K}^1, t_n + hc_2) \\
\mathbf{U}^{n+1} &= \mathbf{U}^n + h(b_1\mathbf{K}^1 + b_2\mathbf{K}^2),
\end{aligned}$$

tal que, substituindo $\mathbf{K}^1$ e $\mathbf{K}^2$, obtemos

$$\boxed{\mathbf{U}^{n+1} = \mathbf{U}^n + h \underbrace{\{b_1 \mathbf{f}(\mathbf{U}^n, t_n) + b_2 \mathbf{f}(\mathbf{U}^n + h a_{21} \mathbf{f}(\mathbf{U}^n, t_n), t_n + h c_2)\}}_{\varphi(\mathbf{U}^n, t_n, h)}}$$

Calculando o erro de truncamento,

$$\begin{aligned} \tau^n &= \frac{1}{h}(\mathbf{u}(t_{n+1}) - \mathbf{u}(t_n)) - b_1 \mathbf{f}(\mathbf{u}(t_n), t_n) \\ &\quad - b_2 \mathbf{f}\left(\frac{\mathbf{u}(t_n) + h a_{21} \mathbf{f}(\mathbf{u}(t_n), t_n), t_n + h c_2}{2}\right) \\ &= \frac{1}{h} \left(\mathbf{u}(t_n) + h \mathbf{u}'(t_n) + \frac{h^2}{2} \mathbf{u}''(t_n) + \dots - \mathbf{u}(t_n) \right) - b_1 \mathbf{u}'(t_n) \\ &\quad - b_2 \left\{ \mathbf{f}(\mathbf{u}(t_n), t_n) + h a_{21} \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \bigg|_{(\mathbf{u}(t_n), t_n)} + h c_2 \frac{\partial \mathbf{f}}{\partial t} \bigg|_{(\mathbf{u}(t_n), t_n)} + \dots \right\} \\ &= (1 - b_1 - b_2) \mathbf{u}'(t_n) + h \left(\frac{1}{2} \mathbf{u}''(t_n) - b_2 a_{21} \frac{\partial \mathbf{f}}{\partial \mathbf{u}} \bigg|_{(\mathbf{u}(t_n), t_n)} - b_2 c_2 \frac{\partial \mathbf{f}}{\partial t} \bigg|_{(\mathbf{u}(t_n), t_n)} \right) + O(h^2). \end{aligned}$$

Portanto, o método de 2 estágios será consistente apenas se

$$\begin{cases} b_1 + b_2 = 1 \\ a_{21} = c_2 \\ b_2 c_2 = \frac{1}{2} \end{cases},$$

que é um sistema não linear com 3 equações e 4 incógnitas, ou seja, com infinitas soluções. Desta forma, existem infinitos métodos Runge-Kutta explícitos de dois estágios que são consistentes e de ordem $O(h^2)$.

Exemplo 28 (Modificando o Método de Euler). O método de Euler modificado é dado pelos coeficientes de Runge-Kutta da forma

$$\begin{array}{c|cc} 0 & 0 & \\ \frac{1}{2} & \frac{1}{2} & 0 \\ \hline & 0 & 1 \end{array}$$

, que leva ao sistema

$$\begin{cases} \mathbf{K}^1 = \mathbf{f}(\mathbf{U}^n, t_n) \\ \mathbf{K}^2 = \mathbf{f}(\mathbf{U}^n + \frac{h}{2} \mathbf{K}^1, t_n + \frac{h}{2}) \\ \mathbf{U}^{n+1} = \mathbf{U}^n + h \mathbf{K}^2 \end{cases}.$$

Além desse, o **método de Euler melhorado** tem a forma

$$\begin{array}{c|cc} 0 & 0 & \\ 1 & 1 & 0 \\ \hline & \frac{1}{2} & \frac{1}{2} \end{array},$$

que leva ao sistema

$$\begin{cases} \mathbf{K}^1 = \mathbf{f}(\mathbf{U}^n, t_n) \\ \mathbf{K}^2 = \mathbf{f}(\mathbf{U}^n + h\mathbf{K}^1, t_n + h) \\ \mathbf{U}^{n+1} = \mathbf{U}^n + \frac{h}{2}(\mathbf{K}^1 + \mathbf{K}^2) \end{cases}.$$

Conforme o número de estágios aumenta, a ordem também aumenta:

- 3 Passos (R=3): sistema de 4 equações e 6 incógnitas, resultando em $\mathcal{O}(h^3)$;
- 4 Passos (R=4): sistema de 11 equações e 13 incógnitas, resultando em $\mathcal{O}(h^4)$;
- ...

De fato, é possível mostrar que a ordem p em função de R satisfaz a relação:

$$\begin{array}{c|cccccccccc} R & 1 & 2 & 3 & 4 & 5 & 6 & 7 & 8 & 9 \\ \hline p(R) & 1 & 2 & 3 & 4 & 4 & 5 & 6 & 6 & 7 \end{array},$$

e, do estágio 10 adiante, temos a relação $p(R) \leq R - 2$.

Disso, tiramos que ele é um método explícito muito preciso, comparável aos métodos de Taylor e, mais importante, **não depende da diferenciabilidade de $\mathbf{f}$** . Porém, ele tem um custo elevado, associado às sucessivas avaliações de $\mathbf{f}$.

Exemplo 29 (Alguns Métodos de Runge-Kutta). Um exemplo para 3 estágios é o **Método RK3 de Heun**:

$$\begin{array}{c|ccc} 0 & 0 & & \\ \frac{1}{3} & \frac{1}{3} & 0 & \\ \frac{2}{3} & 0 & \frac{2}{3} & 0 \\ \hline & \frac{1}{4} & 0 & \frac{3}{4} \end{array},$$

com sistema

$$\begin{cases} \mathbf{K}^1 = \mathbf{f}(\mathbf{U}^n, t_n) \\ \mathbf{K}^2 = \mathbf{f}(\mathbf{U}^n + \frac{h}{3}\mathbf{K}^1, t_n + \frac{h}{3}) \\ \mathbf{K}^3 = \mathbf{f}(\mathbf{U}^n + \frac{2h}{3}\mathbf{K}^2, t_n + \frac{2h}{3}) \\ \mathbf{U}^{n+1} = \mathbf{U}^n + \frac{h}{4}(\mathbf{K}^1 + 3\mathbf{K}^3) \end{cases}.$$

Um exemplo para 4 estágios é o **Método RK4 Clássico**/“O Método Runge-Kutta”:

$$\begin{array}{c|cccc}
 0 & 0 & & & \\
 \frac{1}{2} & \frac{1}{2} & 0 & & \\
 \frac{1}{2} & 0 & \frac{1}{2} & 0 & \\
 1 & 0 & 0 & 1 & 0 \\
 \hline
 & \frac{1}{6} & \frac{1}{3} & \frac{1}{3} & \frac{1}{6}
 \end{array},$$

com sistema

$$\left\{ \begin{array}{l}
 \mathbf{K}^1 = \mathbf{f}(\mathbf{U}^n, t_n) \\
 \mathbf{K}^2 = \mathbf{f}\left(\mathbf{U}^n + \frac{h}{2}\mathbf{K}^1, t_n + \frac{h}{2}\right) \\
 \mathbf{K}^3 = \mathbf{f}\left(\mathbf{U}^n + \frac{h}{2}\mathbf{K}^2, t_n + \frac{h}{2}\right) \\
 \mathbf{K}^4 = \mathbf{f}(\mathbf{U}^n + \mathbf{K}^2, t_n + h) \\
 \mathbf{U}^{n+1} = \mathbf{U}^n + \frac{h}{6}(\mathbf{K}^1 + 2\mathbf{K}^2 + 2\mathbf{K}^3 + \mathbf{K}^4)
 \end{array} \right. .$$

Listing 3: Implementação do RK4 para Presa-Predador

```
1  function fd = f_pp ( u)
2
3  fd (1 ,1) = -2* u (1) + u (1) *u (2) ;
4  fd (1 ,2) = u (2) - u (1) * u (2) ;
5
6  ...
7  while tn < tfim
8
9      k1 = f_pp ( un ) ;
10     k2 = f_pp ( un + h /2 * k1 );
11     k3 = f_pp ( un + h /2 * k2 );
12     k4 = f_pp ( un + k3 );
13
14     un1 = un + h /6 * ( k1 + 2* k2 + 2* k3 + k4 );
15
16     tn = tn + h;
17     un = un1 ;
18
19 end
20 ...
```

12 Aula 12 - 11 de Maio, 2026

12.1 Motivações


- Métodos Multipasso Linear.

12.2 Métodos Multipasso

Definição. Um método multipasso linear de k-passos é descrito por

$$\sum_{j=0}^k \alpha_j U^{n+j} = h \sum_{j=0}^k \beta_j f^{n+j},$$

onde $f^{n+j} = f(U^{n+j}, t_{n+j})$. Adicionalmente, $\alpha_k \neq 0$ e deve-se ter ou $\alpha_0 \neq 0$, ou $\beta_0 \neq 0$. $\square$



A dedução da maioria dos métodos baseia-se na integração direta do PVI em qualquer subintervalo entre t_n e t_{n+k} :

$$\begin{aligned} \mathbf{u}'(t) &= \mathbf{f}(\mathbf{u}(t), t) \\ \int_{t_{n+r}}^{t_{n+s}} \mathbf{u}'(t) dt &= \int_{t_{n+r}}^{t_{n+s}} \mathbf{f}(\mathbf{u}(t), t) dt \\ \mathbf{u}(t_{n+s}) - \mathbf{u}(t_{n+r}) &= \int_{t_{n+r}}^{t_{n+s}} \mathbf{f}(\mathbf{u}(t), t) dt. \end{aligned}$$

Daí, no lado direito, pode-se aplicar uma regra de quadratura.

Exemplo 30 (Métodos Mutlipassos Linear). Alguns métodos multipassos lineares incluem:

- Regra do Ponto Médio: $U^{n+2} - U^n = 2hf^{n+1}$;
- Método de Simpson: $U^{n+2} - U^n = \frac{h}{3}(f^n + 4f^{n+1} + f^{n+2})$;
- Adams-Moulton de 2-passos: $U^{n+2} - U^{n+1} = \frac{h}{12}(-f^n + 8f^{n+1} + 5f^{n+2})$;
- Adams-Bashforth de 2-passos: $U^{n+2} - U^{n+1} = \frac{h}{2}(-f^n + 3f^{n+1})$; e
- Métodos *Backwards Differentiation Formula* (BDF): baseiam-se em fórmulas de diferenças finitas regressivas BDF3: $11U^{n+3} - 18U^{n+2} + 9U^{n+1} - 2U^n = 6hf^{n+3}$.

Exercício 5. Determine as constantes k , α_j e β_j para cada um dos métodos acima!

Observação

Note que, quando $\beta_k \neq 0$, a solução U^{n+k} depende de $f(U^{n+k}, t_{n+k})$, e consequentemente trata-se de um método implícito! Porém, caso $\beta_k = 0$, o método será explícito, pois U^{n+k} dependerá apenas de valores calculados previamente.

A questão dos diferentes métodos de integração numérica possíveis resulta em diferentes métodos numéricos de resolução do PVI!

Exemplo 31 (Diferentes métodos de Integração). Tomando $r = 0$, $s = 1$, a regra de integração numérica do trapézio, encontramos o método do trapézio que discutimos anteriormente.

Por outro lado, se escolhermos $r = k - 1$ e $s = k$, junto à regra de quadratura interpolatória em $t_n, t_{n+1}, \dots, t_{n+k-1}$ resulta nos *métodos da família Adams-Bashforth*.

Nem tudo são flores: agora, há um problema que não existia no caso dos métodos de passo único – nem sempre é possível calcular a aproximação U^1 com o mesmo método! Considere o caso do método de Adams-Bashforth de 2 passos:

$$U^{n+2} - U^{n+1} = \frac{h}{2}(-f^n + 3f^{n+1}),$$

e o primeiro valor possível de se obter uma aproximação com esse método é $U^2 \approx u(t_2)$, não sendo possível, portanto, calcular a aproximação U^1 com este método.

Quando isso acontece, o que costuma-se fazer é usar outro método, preferencialmente de passo único, para estimar os valores iniciais $\mathbf{U}^0, \mathbf{U}^1, \dots, \mathbf{U}^{k-1}$, pois em um método de k-passos, o primeiro valor a ser calculado pelo método é $\mathbf{U}^k$, podendo usar um método de até uma ordem inferior ao erro de truncamento (ordem do método que está utilizando) para não estragar a convergência.

Caso haja convergência, como o número de passos iniciais é sempre fixo e determinado pelo número de passos k do método, devemos necessariamente ter

$$\lim_{h \rightarrow 0} \mathbf{U}^\nu(h) = \underline{\eta}, \quad \nu = 0, 1, \dots, k-1,$$

onde $\mathbf{u}(0) = \underline{\eta}$ é a condição inicial do PVI.

Definição. O erro de truncamento de um método multipassos é calculado com

$$\tau^{n+j} = \frac{1}{h} \sum_{j=0}^k \alpha_j \mathbf{u}(t_{n+j}) - \sum_{j=0}^k \beta_j \mathbf{f}(\mathbf{u}(t_{n+j}), t_{n+j}). \quad \square$$

Mais ainda, podemos estudar a consistência do Método multipasso linear usando a definição acima:

$$\begin{aligned} \tau^{n+j} = & \overbrace{\frac{1}{h} \left(\sum_{j=0}^k \alpha_j \right)}^{C_0} \mathbf{u}(t_n) + \overbrace{\left(\sum_{j=0}^k (j\alpha_j - \beta_j) \right)}^{C_1} \mathbf{u}'(t_n) + h \overbrace{\left(\sum_{j=0}^k \left(\frac{1}{2} j^2 \alpha_j - j\beta_j \right) \right)}^{C_2} \mathbf{u}''(t_n) \\ & + \dots + h^{q-1} \underbrace{\left(\sum_{j=0}^k \left(\frac{1}{q!} j^q \alpha_j - \frac{1}{(q-1)!} j^{q-1} \beta_j \right) \right)}_{C_q} \mathbf{u}^{(q)}(t_n) + \dots \end{aligned}$$

Logo, o método será consistente apenas se $C_0 = 0$ e $C_1 = 0$, que equivale a pedir

$$\sum_{j=0}^k \alpha_j = 0 \quad \& \quad \sum_{j=0}^k j\alpha_j = \sum_{j=0}^k \beta_j.$$

Definição. Dado um método linear de k passos da forma

$$\sum_{j=0}^k \alpha_j \mathbf{y}_{n+j} = h \sum_{j=0}^k \beta_j \mathbf{f}_{n+j},$$

os **polinômio característicos associados ao método** por

$$\rho(\zeta) = \sum_{j=0}^k \alpha_j \zeta^j \quad \& \quad \sigma(\zeta) = \sum_{j=0}^k \beta_j \zeta^j.$$

O polinômio $\rho(\zeta)$ é chamado **primeiro polinômio característico**, enquanto que $\sigma(\zeta)$ é o **segundo polinômio característico**. $\square$

Os polinômio característicos fazem parte do estudo de consistência, estabilidade e convergência.

Exercício 6. Mostre que um MML é consistente se, e somente se, $\rho(1) = 0$ e $\rho'(1) = \sigma(1)$;

Exercício 7. Encontre os polinômio característicos dos métodos multipassos exemplificados e avalie a consistência deles.

Aqui, é importante deixarmos claro o tipo de assunto que vamos estudar:

Definição. Um **estudo de zero-estabilidade** para o problema teste $u'(t) = 0$, $u(0) = 0$, consiste em avaliar o comportamento do método numérico para ele. A solução exata do problema é $u \equiv 0$, e portanto o método numérico também deve recuperar tal solução para ser chamado de zero-estável. $\square$

Em suma, estudar a estabilidade absoluta de um método para PVI consiste em avaliar o comportamento do método em um problema teste de autovalor do tipo $u'(t) = \lambda u(t)$, com $\lambda \in \mathbb{C}_-$; a definição pode parecer óbvia, mas vamos considerar o seguinte método multipasso linear:

$$U^{n+2} - 3U^{n+1} + 2U^n = -kf(U^n).$$

Aplicando ao problema teste $u'(t) = 0$, obtém-se a seguinte fórmula de recorrência:

$$U^{n+2} - 3U^{n+1} + 2U^n = 0,$$

cuja solução é, em termos de valores iniciais U^0 e U^1 , dada por

$$U^n = 2U^0 - U^1 + 2^n(U^1 - U^0).$$

O que acontece com a solução quando $U^0 \neq U^1$? Será que ela se anula? Não! Na verdade, $U^n \rightarrow \infty$.

Definição. Um método multipasso linear consistente aplicado à resolução de um problema de valor inicial $\mathbf{u}'(t) = \mathbf{f}(\mathbf{u}(t), t)$, $\mathbf{u}(0) = \underline{\eta}$, é dito **convergente** se, e somente se, ele for zero-estável. $\square$

Em suma,

$$\boxed{\text{Consistência} + \text{Zero-Estabilidade} \iff \text{Convergência}}$$

Este problema acontece pois o método em questão não satisfaz a propriedade de zero-estabilidade! Assim, determinar a zero-estabilidade de um MML envolve a solução de uma recorrência não trivial, mas ela não é tão prática de ser avaliada puramente pela definição. Para isso, temos um teorema:

Teorema. Se as raízes $\zeta_1, \dots, \zeta_k$ do polinômio característico $\rho(\zeta)$ associado a um MML de k -passos satisfazem as seguintes condições:

$$|\zeta_j| \leq 1 \quad \forall j = 1, 2, \dots, k; \quad |\zeta_j| < 1 \text{ sempre que } \zeta_j \text{ for raiz múltipla.}$$

Então, o MML é zero-estável.

Exercício 8. Mostre que métodos multipasso lineares com $k = 1$ são sempre zero-estáveis, e portanto, sempre convergentes.

Note que, mesmo sendo zero-estável, um método ainda pode sofrer dos mesmos problemas de estabilidade absoluta já estudados anteriormente. Considere o problema $u'(t) = \lambda u(t)$, $u(0) = \eta$, discretizando-o por um MML:

$$\sum_{j=0}^k \alpha_j U^{n+j} = h \sum_{j=0}^k \beta_j \lambda U^{n+j} \Rightarrow \sum_{j=0}^k (\alpha_j - z \beta_j) U^{n+j} = 0,$$

com $z = h\lambda$.

Além disso, é uma relação de recorrência análoga ao problema de zero-estabilidade, mas agora considerando coeficientes $\alpha_j - z\beta_j$ ao invés de simplesmente α_j .

Definição. Dado um método linear de k passos com polinômio característicos como antes, ao aplicá-lo à equação teste

$$y' = \lambda y, \quad z = h\lambda,$$

obtém-se o **polinômio de estabilidade associado ao MML** é definido por

$$\pi(\zeta; z) = \sum_{j=0}^k (\alpha_j - z\beta_j)\zeta^j = \rho(\zeta) - z\sigma(\zeta). \quad \square$$

Com esse polinômio de estabilidade, suas raízes determinam a estabilidade do método para cada valor de z !

Definição. A **região de estabilidade absoluta** de um MML é o conjunto S do plano complexo dado por

$$S = \{z = \lambda h, h \in \mathbb{R}_+ : \text{ as raízes de } \pi(\zeta; z) \text{ satisfazem o } \textit{teorema}\}. \quad \square$$

Um termo comumente utilizado para se referir às condições do teorema é **condições de raiz**:

$$|\zeta_j| \leq 1 \quad \forall j = 1, 2, \dots, k; \quad |\zeta_j| < 1 \text{ sempre que } \zeta_j \text{ for } \textit{raiz múltipla}.$$

Exemplo 32. Para o método de Euler explícito, tem-se $\pi(\zeta; z) = \zeta - (1 + z)$, cuja única raiz é $\zeta_1 = 1 + z$. Os valores de $z \in \mathbb{C}$ que fazem com que ζ_1 satisfaça as condições de raiz é justamente um disco de centro em -1 e raio 1, coincidindo com a região de estabilidade do método de Euler vista anteriormente.

Finalmente, vale comparar os dois tipos de métodos com uma tabelinha:

Tabela 4: Métodos Um-passo X Multipassos.

Métodos de 1-passo	Métodos de k-passos
Aplicação direta para problemas de valor inicial	Precisam de outros método para primeiras aproximações
Difícil atingir ordens mais elevadas	Fácil de produzir métodos de ordens altas
Métodos mais precisos têm alto custo computacional	Baixo custo computacional
São automaticamente zero-estáveis	Nem todos os métodos são zero-estáveis
Fácil lidar com passo h variável	Difícil lidar com passo h variável

Lembrete!	Raiz Múltipla
Um elemento $\zeta \in \mathbb{C}$ é uma raiz de multiplicidade k do polinômio $\sigma(x)$ se existe um polinômio $\sigma(x)$ tal que $\sigma(\zeta) \neq 0$ e	
$\rho(x) = (x - \zeta)^k \sigma(x).$	

13 Aula 13 - 20 de Maio, 2026

13.1 Motivações

- Equação do Calor/de Difusão.

13.2 Equação do Calor: método progressivo, retrógrado e Crank-Nickolson.

Vamos considerar a equação do calor em um domínio limitado $x \in (0, 1)$ para tempo $t > t_0 = 0$, um exemplo clássico da equação parabólica:

$$u_t = k u_{xx}, \quad 0 < x < 1, \quad t > 0.$$

Precisamos de uma condição inicial em $t_0 = 0$, como

$$u(x, 0) = \eta(x), \quad 0 \leq x \leq 1$$

e condições de contorno

$$u(0, t) = g_0(t), \quad t > 0$$

$$u(1, t) = g_1(t), \quad t > 0.$$

Para simplificar, vamos pedir que $k = 1$; caso k fosse negativo, $u_t = k u_{xx}$ seria um problema de calor retrógrado, que é mal posto.

Para a discretização do domínio, considere uma grade discreta com pontos (x_i, t_n) , onde

$$x_i = ih, \quad t_n = nk,$$

pois nesse ponto, já temos um certo conhecimento que podemos aplicar sobre discretização de problemas. Aqui, $h = \Delta x$ é um distanciamento de malha no eixo x e $k = \Delta t$ é um intervalo de tempo.


Tome $U_i^n \approx u(x_i, t_n)$ representando uma aproximação numérica de u em (x_i, t_n) ; uma bem natural seria utilizar a diferença progressiva

$$\begin{aligned} \frac{u(x_j, t_n + \Delta t) - u(x_j, t_n)}{\Delta t} + O(\Delta t) &= \frac{u(x_j + h, t_n) - 2u(x_j, t_n) + u(x_j - h, t_n)}{h^2} + O(h^2) \\ \Rightarrow \frac{U_i^{n+1} - U_i^n}{\Delta t} &= \frac{1}{h^2} (U_{i-1}^n - 2U_i^n + U_{i+1}^n), \end{aligned}$$

que faz uso das já conhecidas diferenças centradas no espaço e uma diferença posterior de tempo. Como podemos computar cada U_i^{n+1} explicitamente em termos dos valores anteriores, este método é explícito:

$$U_i^{n+1} = U_i^n + \frac{k}{h^2}(U_{i-1}^n - 2U_i^n + U_{i+1}^n)$$

Como já sabemos as condições iniciais e as de contorno, podemos começar a computar num ponto próximo da borda e, a partir dele, encontrar uma solução aproximada com isso, e é este o princípio geral do diferenças progressivas, conhecido também como *método de Euler progressivo* (De novo!), utilizando um método de um passo temporalmente, conhecido como método de dois níveis, já que envolve a solução em dois tempos diferentes.



O método de diferenças progressivas pode ser representado matricialmente

por

$$\begin{bmatrix} U_1^{n+1} \\ U_2^{n+1} \\ U_3^{n+1} \\ \vdots \\ U_{m-1}^{n+1} \\ U_m^{n+1} \end{bmatrix} = \begin{bmatrix} (1-2\sigma) & \sigma & & & & \\ \sigma & (1-2\sigma) & \sigma & & & \\ & \sigma & (1-2\sigma) & \sigma & & \\ & & \ddots & \ddots & \ddots & \\ & & & \sigma & (1-2\sigma) & \sigma \\ & & & & \sigma & (1-2\sigma) \end{bmatrix} \begin{bmatrix} U_1^n \\ U_2^n \\ U_3^n \\ \vdots \\ U_{m-1}^n \\ U_m^n \end{bmatrix} + \begin{bmatrix} \sigma g_0(t_n) \\ 0 \\ 0 \\ \vdots \\ 0 \\ \sigma g_1(t_n) \end{bmatrix}.$$

, que equivale, sem as condições de contorno e colocando $\sigma = \frac{\Delta t}{h^2}$, à equação

$$U_j^{n+1} = \sigma U_{j-1}^n + (1-2\sigma)U_j^n + \sigma U_{j+1}^n,$$

ou, juntando tudo, ao sistema

$$U^{n+1} = AU^n + g^n.$$

Veremos mais alguns métodos hoje, incluindo o método regressivo e o método de *Crank-Nickolson*

E se mudássemos a discretização? Agora, queremos uma discretização espacial, mas regressiva temporalmente, para a qual fica parecida com a progressiva, mas com uma mudança:

$$\begin{aligned} \frac{u(x_j, t_n) - u(x_j, t_n - \Delta t)}{\Delta t} + O(\Delta t) &= \frac{u(x_j + h, t_n) - 2u(x_j, t_n) + u(x_j - h, t_n)}{h^2} + O(h^2) \\ \Rightarrow \frac{U_j^n - U_j^{n-1}}{\Delta t} &= \frac{U_{j+1}^n - 2U_j^n + U_{j-1}^n}{h^2}, \end{aligned}$$

resultando no método

$$\boxed{\sigma U_{j-1}^{n+1} + (1+2\sigma)U_j^{n+1} - \sigma U_{j+1}^{n+1} = U_j^n}$$

conhecido como *Euler Regressivo* (Mais uma vez), que é o método de Euler implícito!

Afinal, o estêncil desse método depende de pontos que dependem dos anteriores, resultando no sistema linear

$$\begin{bmatrix} (1-2\sigma) & \sigma & & & & \\ \sigma & (1-2\sigma) & \sigma & & & \\ & \sigma & (1-2\sigma) & \sigma & & \\ & & \ddots & \ddots & \ddots & \\ & & & \sigma & (1-2\sigma) & \sigma \\ & & & & \sigma & (1-2\sigma) \end{bmatrix} \begin{bmatrix} U_1^{n+1} \\ U_2^{n+1} \\ U_3^{n+1} \\ \vdots \\ U_{m-1}^{n+1} \\ U_m^{n+1} \end{bmatrix} =$$

$$= \begin{bmatrix} U_1^n \\ U_2^n \\ U_3^n \\ \vdots \\ U_{m-1}^n \\ U_m^n \end{bmatrix} + \begin{bmatrix} \sigma g_0(t_{n+1}) \\ 0 \\ 0 \\ \vdots \\ 0 \\ \sigma g_1(t_{n+1}) \end{bmatrix}$$

O método ficou mais caro, mas veremos que ele tem uma vantagem em breve. Esperamos que esses métodos tenham erros de truncamento da ordem $O(\Delta t + h^2)$, pois foram os dois termos descartados, e deseja-se que este erro tenda a zero quando Δt e h tendem a 0.

Quanto ao método de Crank-Nickolson, ele seria um método de diferenças centrais com uma maracutaia – se fizermos um método por diferenças centrais usuais, gostaríamos de evitar fazer dois níveis por enquanto por conta da quantidade de pontos que ele vai envolver; faremos uma ampliação da malha espaço-temporal com $t_{n+1/2} = t_n + \frac{\Delta t}{2}$, dando

$$u(x_n, t_{n+1/2}) = u_{xx}(x_j, t_{n+1/2}) = \frac{u(x_n, t_n + \Delta t) - u(x_j, t_n)}{2(\frac{\Delta t}{2})} + O(\Delta t^2) \Rightarrow$$

$$\frac{u(x_n, t_n + \Delta t) - u(x_j, t_n)}{\Delta t} + O(\Delta t^2) = \frac{u(x_j - h, t_{n+1/2}) - 2u(x_j, t_{n+1/2}) + u(x_j + h, t_{n+1/2})}{h^2} + O(h^2),$$

só que isso resulta em pontos no meio da malha, e isso aumenta a resolução do problema mais do que deveria, criando graus de liberdade a mais. Como resolver isso? Interpolando na média! Daí, o lado direito ganha um erro de interpolação e

fica

$$\frac{1}{2h^2} \left(u(x_j - h, t_{n+1}) - 2u(x_j, t_{n+1}) + u(x_j + h, t_{n+1}) \right. \\ \left. + u(x_j - h, t_n) - 2u(x_j, t_n) + u(x_j + h, t_n) \right) + O(h^2) + \varepsilon$$

Passando a discretização, obtemos

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} = \frac{1}{2} \frac{U_{j-1}^{n+1} - 2U_j^{n+1} + U_{j+1}^{n+1}}{h^2} + \frac{1}{2} \frac{U_{j-1}^n - 2U_j^n + U_{j+1}^n}{h^2} \\ \Rightarrow U_j^{n+1} - U_j^n = \frac{\sigma}{2} (U_{j+1}^{n+1} - 2U_j^{n+1} + U_{j-1}^{n+1}) + \frac{\sigma}{2} (U_{j-1}^n - 2U_j^n + U_{j+1}^n) \\ \Rightarrow -\frac{\sigma}{2} U_j^{n+1} + (1 + \sigma) U_j^{n+1} - \frac{\sigma}{2} U_{j+1}^{n+1} = \frac{\sigma}{2} U_{j-1}^n + (1 - \sigma) U_j^n + \frac{\sigma}{2} U_{j+1}^n,$$

cuja matriz fica

$$\begin{bmatrix} (1 + \sigma) & -\frac{\sigma}{2} & & & & \\ -\frac{\sigma}{2} & (1 + \sigma) & -\frac{\sigma}{2} & & & \\ & -\frac{\sigma}{2} & (1 + \sigma) & -\frac{\sigma}{2} & & \\ & & \ddots & \ddots & \ddots & \\ & & & -\frac{\sigma}{2} & (1 + \sigma) & -\frac{\sigma}{2} \\ & & & & -\frac{\sigma}{2} & (1 + \sigma) \end{bmatrix} \begin{bmatrix} U_1^{n+1} \\ U_2^{n+1} \\ U_3^{n+1} \\ \vdots \\ U_{m-1}^{n+1} \\ U_m^{n+1} \end{bmatrix} = \\ = \begin{bmatrix} (1 - \sigma) & \frac{\sigma}{2} & & & & \\ \frac{\sigma}{2} & (1 - \sigma) & \frac{\sigma}{2} & & & \\ & \frac{\sigma}{2} & (1 - \sigma) & \frac{\sigma}{2} & & \\ & & \ddots & \ddots & \ddots & \\ & & & \frac{\sigma}{2} & (1 - \sigma) & \frac{\sigma}{2} \\ & & & & \frac{\sigma}{2} & (1 - \sigma) \end{bmatrix} \begin{bmatrix} U_1^n \\ U_2^n \\ U_3^n \\ \vdots \\ U_{m-1}^n \\ U_m^n \end{bmatrix} \\ + \begin{bmatrix} \frac{\sigma}{2} (g_0(t_{n+1}) + g_0(t_n)) \\ 0 \\ 0 \\ \vdots \\ 0 \\ \frac{\sigma}{2} (g_1(t_{n+1}) + g_1(t_n)) \end{bmatrix}$$

No fim, é só muita conta algébrica mesmo. Este método ainda é um método implícito, afinal as incógnitas estão dependendo umas das outras, como dá para ver no

sistema linear acima da forma

$$A\underline{U}^{n+1} = B\underline{U}^n + \underline{g}^n + \underline{g}^{n+1},$$

resultando no método de Crank-Nickolson

$$\boxed{-\frac{\sigma}{2}U_j^{n+1} + (1 + \sigma)U_j^{n+1} - \frac{\sigma}{2}U_{j+1}^{n+1} = \frac{\sigma}{2}U_{j-1}^n + (1 - \sigma)U_j^n + \frac{\sigma}{2}U_{j+1}^n}$$

Não é potência! É índice!

O problema é se essas aproximações que fizemos forem resultar numa redução da ordem do método. Para verificar isso, precisamos ver o erro de truncamento de cada um deles, ou seja, $\tau_F(x_i, t_n)$ do Euler-Forward, $\tau_B(x_i, t_n)$ pro Euler-Backward e $\tau_{CN}(x_i, t_n)$. Neste sentido, a definição é a mesma de sempre, resultando em

$$\tau_F(x, t) = \frac{u(x, t + \Delta t) - u(x, t)}{\Delta t} - \frac{1}{h^2}(u(x - h, t) - 2u(x, t) + u(x + h, t)),$$

onde devemos ter cuidado com usar a forma de diferenças que modelam diretamente a equação diferencial. Agora, é questão de expandir em Taylor.

14 Aula 14 - 25 de Maio, 2026

14.1 Motivações

- Consistência e Estabilidade da Equação Parabólica;
- Método das Linhas.

14.2 Consistência e Estabilidade da Equação Parabólica

O método de Crank-Nicolson foi introduzido na aula passada, com forma geral

$$-\frac{\sigma}{2}U_j^{n+1} + (1 + \sigma)U_j^{n+1} - \frac{\sigma}{2}U_{j+1}^{n+1} = \frac{\sigma}{2}U_{j-1}^n + (1 - \sigma)U_j^n + \frac{\sigma}{2}U_{j+1}^n$$

que dá a aproximação seguindo o triângulo de Pasqual:

$$\begin{aligned}u(x + h, t + k) &= u(x, t) + hu_x(x, t) + ku_t(x, t) \\&\quad + \frac{1}{2!}(h^2u_{xx}(x, t) + 2hku_{xt}(x, t) + k^2u_{tt}(x, t)) \\&\quad + \frac{1}{3!}(h^3u_{xxx} + 3h^2ku_{xxt} + 3hk^2u_{xtt} + k^3u_{ttt} \\&\quad + \dots,\end{aligned}$$

usado para construir a matriz do método.

Assim como anteriormente, esperamos que consistência e alguma forma de estabilidade garanta a convergência do método em cada ponto fixo (X, T) conforme refinamos a malha nas dimensões de espaço e tempo; mais ainda, esperamos que, para um método estável, a ordem global de precisão concordará com a ordem local do erro de truncamento; por exemplo, para o Crank-Nicolson, espera-se que

$$U_i^n - u(X, T) = O(\Delta t^2 + h^2) \rightarrow 0$$

conforme h e k tendem a 0 quando $ih \equiv X$ e $n\Delta t \equiv T$ são fixos. O termo que sobra no erro de truncamento local age como se fosse um erro espúrio, um sintoma ao resolver o problema diferencial, e por isso desejamos que ela tenda a zero ao invés de explodir!

A estabilidade, por sua vez, está relacionada justamente a um acúmulo exponencial de erros, pois gostaríamos que um método numérico tivesse uma solução que não explodisse; anteriormente, vimos que a zero-estabilidade estava relacionada ao esquema para discretizar a derivada, especialmente com os que não acumulassem

erros desastrosamente, ao mesmo tempo que vimos a estabilidade absoluta, relacionada ao uso do método para resolver $u' = \lambda u$ e dando uma escolha para o passo h : poderíamos escolher um passo h que restaurava a habilidade do método de resultar numa solução *sem* acúmulo desastroso do erro, analisando as regiões de estabilidade e etc, fora da qual o método acumula potências enormes de erro e acabou-se o método, então a escolha adequada do h iria impedir isso ao encaixar o método dentro da região. No caso das equações parabólicas, usaremos mecanismos semelhantes! Ao final, iremos “provar” o Teorema de Equivalência de Lax:

“Para EDPs lineares, ter ‘consistência’ mais ‘uma forma de estabilidade’ é equivalente à ‘convergência’.”

Para entender como a teoria de estabilidade para EDPs temporais se relaciona com a teoria de estabilidades de EDOs atemporais, é mais fácil considerar o chamado **métodos das linhas** (MOL), uma discretização das EDPs que é semidiscreta: a ideia é manter contínuo em um aspecto e discretizar no outro, por exemplo manter o tempo contínuo e discretizar no espaço⁶, de forma que a equação diferencial passa a ser avaliada em

$$u_t(x_j, t) = u_{xx}(x_j, t),$$

e procuramos uma discretização que respeite isso. O tempo continua como está; para a discretização de $u_{xx}(x_j, t)$, usamos a discretização

$$\frac{u(x_j, t) - 2u(x_j, t) + u(x_j + h, t)}{h^2} + O(h^2)$$

e descartamos os erros, fornecendo uma aproximação para a função $U_j(t)$ dada por

$$U_j(t) \approx u(x_j, t).$$

Daí, a derivada temporal $u_t(x_j, t)$ passa a ser uma derivada ordinária!

$$\boxed{\frac{d}{dt} U_j(t) = \frac{1}{h^2} \left(U_{j-1}(t) - 2U_j(t) + U_{j+1}(t) \right)}$$

Obtivemos um sistema de EDOs, que torna-se um PVI! Ao fazer a discretização espacial, as condições de contorno ficam embutidas na forma acima, e a condição inicial continua tratada conforme anteriormente; por exemplo, se $u(x, 0) = \eta(x)$, ficamos com $U_j(0) = \eta(x_j)$ para todo j . O bom disso é que sabemos (supostamente) resolver PVI's.

⁶Por isso chama método das linhas – fica com linhas em uma das dimensões!

Se outra discretização espacial fosse feita, outro método teria sido obtido, mas exploraremos esse que conseguimos por um tempo, igualmente descrito pelo problema

$$\frac{d}{dt}\underline{U}(t) = \overbrace{A\underline{U}(t) + \underline{g}(t)}^{\text{Condições de contorno}}, \quad A = \frac{1}{h^2} \begin{bmatrix} -2 & 1 & & \\ 1 & -2 & 1 & \\ \vdots & \vdots & \ddots & \vdots \\ & & 1 & -2 \end{bmatrix}$$

Exemplo 33 (Contorno de Dirichlet). Se tivéssemos condições de contorno

$$\underline{g}(t) \begin{cases} u(0, t) = g_0(t) \\ u(1, t) = g_1(t) \end{cases},$$

o sistema acima daria

$$A = \frac{1}{h^2} \begin{bmatrix} -2 & 1 & & \\ 1 & -2 & 1 & \\ \vdots & \vdots & \ddots & \vdots \\ & & 1 & -2 \end{bmatrix}, \quad \underline{g}(t) = \begin{bmatrix} \frac{1}{h^2}g_0(t) \\ 0 \\ \vdots \\ 0 \\ \frac{1}{h^2}g_1(t) \end{bmatrix}$$

e

$$\underline{U}(0) = \begin{bmatrix} \eta(x_1) \\ \eta(x_2) \\ \vdots \\ \eta(x_m) \end{bmatrix} \quad \& \quad \underline{U}(t) = \begin{bmatrix} U_1(t) \\ U_2(t) \\ \vdots \\ U_m(t) \end{bmatrix}.$$

Agora, podemos ficar aplicando os métodos que já conhecemos; com o método de Euler, obteríamos

$$\underline{U}^{n+1} = \underline{U}^n + \Delta t[A\underline{U}^n + \underline{g}^n],$$

ou

$$\underline{U}^{n+1} = (I + \Delta t A)\underline{U}^n + \Delta t \underline{g}^n,$$

tal que

$$I + \Delta t A = \begin{bmatrix} (1 - 2\sigma) & \sigma & & \\ \sigma & (1 - 2\sigma) & \sigma & \\ \vdots & \vdots & \ddots & \vdots \\ & & \sigma & (1 - 2\sigma) \end{bmatrix},$$

exatamente o Euler progressivo! Se fosse o Euler implícito aplicado, recuperaríamos o Euler regressivo.

Com o trapézio, ficaria

$$\underline{U}^{n+1} = \underline{U}^n + \frac{\Delta t}{2}(\underline{F}(\underline{U}^n) + \underline{F}(\underline{U}^{n+1})),$$

que com o exemplo, teríamos

$$\underline{U}^{n+1} = \underline{U}^n + \frac{\Delta t}{2}(A\underline{U}^n + \underline{g}^n) + \frac{\Delta t}{2}(A\underline{U}^{n+1} + \underline{g}^{n+1}),$$

ou então

$$\left(I - \frac{\Delta t}{2}A\right)\underline{U}^{n+1} = \left(I + \frac{\Delta t}{2}A\right)\underline{U}^n + \frac{\Delta t}{2}(\underline{g}^n + \underline{g}^{n+1}),$$

que é exatamente o método de Crank-Nicolson, mas obtido muito mais simplesmente – apenas discretizamos em espaço, resultando numa EDP, seguida de uma discretização no tempo com o método do trapézio.

Essa técnica dá diversos métodos que podemos usar para resolver e que nem vimos aqui, por exemplo discretizando em espaço e usando RK para resolver a EDO resultante. Porém, o mais interessante dessa técnica é que ela permite utilizar essa transformação do problema em um PVI para analisar a estabilidade do problema de equações parabólicas, e é exatamente essa tática que usaremos. Tomando o método de Euler de exemplo, ele está aplicado ao problema linear

$$\frac{d}{dt}\underline{U}(t) = A\underline{U}(t) + \underline{g}(t),$$

e analisar a estabilidade dele requer conhecimento do espectro de A , olhando qual dos autovalores dá a maior restrição no espectro de tempo. Porém, a A daqui é uma A especial – ela aparece na tridiagonal resultante da discretização por diferenças centrais, então já sabemos que os autovalores são

$$\lambda_p = \frac{2}{h^2}(\cos(p\pi h) - 1), \quad p = 1, 2, \dots, m,$$

onde m e h são relacionados por $h = \frac{1}{m+1}$. Sabemos, sobre o método de Euler, que a região de estabilidade dele é um círculo de raio 1 centrado em -1, mas temos que olhar a questão da estabilidade nova; gostaríamos que todos os $\Delta t \lambda_p$ estejam dentro da região de estabilidade do Método de Euler, pois isso garante que a solução não exploda de erros.

Sobre os autovalores, percebe-se que eles são todos números reais negativos, caindo exatamente no eixo-x que corta o círculo no meio, apenas para a esquerda do 0, e que o autovalor de maior módulo é o menor autovalor sem módulo; assim,

para que λ_m pertença à região de estabilidade absoluta, como

$$\lambda_m = \frac{2}{h^2} \left(\cos \left(\frac{m}{m+1} \pi \right) - 1 \right)$$

implica que é necessário que

$$-\frac{4}{h^2} \Delta t > -2 \Rightarrow \frac{\Delta t}{h^2} < \frac{1}{2},$$

dando uma restrição que diz que o método de Euler é estável, mas é **condicionalmente estável**, e a condição para ele ser estável é $\frac{\Delta t}{h^2} \leq \frac{1}{2}$.

Temos, então, uma “competição” entre os autovalores e a análise do problema de valor inicial: queremos que os autovalores estejam dentro da região, precisando que Δt seja reduzido; porém, ao reduzir h , o termo cresce, jogando os autovalores para fora ao refinar o h ! Fica uma briga que tende muito mais ao h do que ao Δt por conta do termo h^2 . Logo, ao resolver um problema desse, mesmo usando um Δt moderado, é necessário usar um h muito pequeno para satisfazer a condição! Normalmente, o que se faz é pedir que Δt seja menor ou igual a um fator de tolerância ξ multiplicado por h^2 , onde $\xi < 1/2$.

Vamos repetir essa análise para o método do trapézio, cuja região de estabilidade é metade o hiperplano esquerdo do plano complexo – é irrestrito! Então, qual seria a condição para que $\Delta t \lambda_p$ esteja dentro da região de estabilidade? Ora, basta que λ_p seja negativo, que ele já satisfaz por natureza, então a condição não existe! Todos os autovalores sempre estarão dentro dela. Portanto, o método de Crank-Nicolson é **Incondicionalmente Estável**. Apesar de métodos implícitos serem mais caros, eles garantem a estabilidade incondicional, enquanto os métodos diretos são baratos, mas têm estabilidade condicional.

Testemos com a *regra do ponto médio*, dada por

$$\underline{U}^{n+2} = \underline{U}^n + 2\Delta t \underline{U} F^{n+1}.$$

Ela resolve um problema parabólico? Não! Os autovalores são reais positivos, então eles nunca vão para a região de estabilidade do ponto médio, que é dada pelos números puramente imaginários (apenas no eixo-y), garantindo um método **incondicionalmente instável**, podendo ser usado apenas nos casos em que os autovalores são complexos, especialmente os que são puramente complexos (basta que A seja antissimétrica).

14.3 Exemplos de Códigos

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 import time
4
5 # Dados iniciais
6 a = 0.
7 b = 1.
8 T = 0.5
9 kappa = 1.
10
11 N = 40                      # discretizacao em x
12 dx = (b - a)/N
13
14 # Calcula dt para que sigma seja menor que 0.5
15 dt = 0.4*dx*dx/kappa
16
17 M = int(np.ceil(T/dt))
18 dt = T/M
19
20 sigma = kappa*dt/(dx*dx)
21 print(f'sigma = {sigma:.6f}')
22
23 U = np.zeros((N + 1, M + 1))
24 x = np.linspace(a, b, N + 1)
25
26 # Condicao inicial
27 U[:, 0] = x*(1 - x)
28
29
```

Listing 4: Implementação do Parabólico Explícito

```

1  # Aplicando o metodo de Euler explicito
2  start_time = time.time()
3  for n in range(M):
4      for i in range(1, N):
5          U[i, n + 1] = U[i, n] + sigma*(U[i - 1, n] - 2*U[i, n] + U[i
            + 1, n])
6
7  elapsed_time = time.time() - start_time
8  print(f"Tempo de execucao: {elapsed_time:.6f} segundos")
9  # Plot
10 plt.figure(figsize=(8, 5))
11 # for n in range(0, M + 1, max(1, M // 10)):
12 #     plt.plot(x, U[:, n], label=f't={n*dt:.3f}')
13 for n in range(0, M + 1):
14     plt.plot(x, U[:, n], label=f't={n*dt:.3f}')
15 plt.xlabel('x')
16 plt.ylabel('U(x,t)')
17 plt.title('Solucao da Equacao do Calor - Metodo Explicito')
18 # plt.legend()
19 plt.grid(True)
20 plt.show()

```

Listing 5: Implementação de Crank-Nicolson

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 import time
4 from scipy.linalg import solve
5
6 # Dados iniciais
7 a = 0.
8 b = 1.
9 T = 0.5
10 kappa = 1.
11
12 N = 40 # discretizacao em x
13 M = 10 # discretizacao em t
14
15 dx = (b - a)/N
16 dt = T/M
17
18 sigma = kappa*dt/(dx*dx)
19
20 # limite para estabilidade
21 dt_lim = 0.5*dx*dx/kappa
22 sigma_lim = kappa*dt_lim/(dx*dx)
23
24 print(f'dx = {dx:.6f}, dt = {dt:.6f}, sigma = {sigma:.6f}, sigma_lim
    = {sigma_lim:.6f}')
25
26 U = np.zeros((N + 1, M + 1))
27 x = np.linspace(a, b, N + 1)
28
29 # Condição inicial
30 U[:, 0] = x * (1 - x)
```

```

1  # Montagem das matrizes A e B
2  main_diag_A = (2 + 2*sigma)*np.ones(N - 1)
3  diag_A2 = -sigma*np.ones(N - 2)
4  A = np.diag(main_diag_A) + np.diag(diag_A2, 1) + np.diag(diag_A2,
    ↪ -1)
5
6  main_diag_B = (2 - 2*sigma)*np.ones(N - 1)
7  diag_B2 = sigma*np.ones(N - 2)
8  B = np.diag(main_diag_B) + np.diag(diag_B2, 1) + np.diag(diag_B2,
    ↪ -1)
9
10 start_time = time.time()
11
12 for n in range(M):
13     # Condições de Dirichlet
14     U[0, n + 1] = 0
15     U[-1, n + 1] = 0
16
17     # Resolve o sistema linear
18     c = np.zeros(N - 1)
19     U[1:-1, n + 1] = solve(A, B @ U[1:-1, n] + c)
20
21 elapsed_time = time.time() - start_time
22 print(f"Tempo de execucao: {elapsed_time:.6f} segundos")
23
24 # Plot
25 plt.figure(figsize=(8, 5))
26 for n in range(M + 1):
27     plt.plot(x, U[:, n], label=f't={n * dt:.3f}')
28 plt.xlabel('x')
29 plt.ylabel('U(x,t)')
30 plt.title('Solucao da Equacao do Calor - Metodo de Crank-Nicolson')
31 plt.legend()
32 plt.grid(True)
33 plt.show()

```

15 Aula 15 - 27 de Maio, 2026

15.1 Motivações

- Análise de Convergência;
- Estabilidade Lax-Richtmyer;
- Equivalência de Lax/Critério da Matriz.

15.2 Análise de Convergência

Até o momento, os métodos que estudamos podem ser resumidamente escritos na forma

$$\underline{U}^{n+1} = \underline{B}(\Delta t)\underline{U}^n + \underline{b}^n(\Delta t),$$

onde $\underline{B}(\Delta t) \in \mathbb{R}^{m \times m}$ é uma matriz em uma malha, com $h = \frac{1}{m+1}$ e $\underline{b}^n(\Delta t) \in \mathbb{R}^m$. Em geral, estes métodos dependem tanto de Δt quanto de h , mas vamos assumir que alguma regra fixa relaciona h e Δt , como foi o caso quando vimos o método de Euler anteriormente e obtivemos a restrição $\Delta t \leq \frac{1}{2}h^2$. Aproveitando a menção do exemplo, vamos olhar ele pela óptica da equação geral acima.

Exemplo 34 (Encaixando Euler). A equação de Euler progressiva aplicada ao sistema MOL

$$U'(t) = AU(t) + g(t)$$

deu

$$\underline{U}^{n+1} = \underline{U}^n + \Delta t A \underline{U}^n + \Delta t \underline{g}^n,$$

ou seja, em termos da expressão vista,

$$\underline{b}^n(\Delta t) = \Delta t \underline{g}^n, \quad \underline{B}(\Delta t) = (I + \Delta A).$$

Exemplo 35 (Encaixando Crank-Nicolson). No caso de Crank-Nicolson, a equação era

$$\underline{U}^{n+1} = \underline{U}^n + \frac{\Delta t}{2}(A \underline{U}^{n+1} + A \underline{U}^n) + \frac{\Delta t}{2}(\underline{g}^n + \underline{g}^{n+1}),$$

que, isolando o termo $(n+1)$, dá

$$\left(I - \frac{\Delta t}{2}A\right)\underline{U}^{n+1} = \left(I + \frac{\Delta t}{2}A\right)\underline{U}^n + \frac{\Delta t}{2}(\underline{g}^n + \underline{g}^{n+1}),$$

ou seja,

$$B(\Delta t) = \left(I - \frac{\Delta t}{2}A\right)^{-1} \left(I + \frac{\Delta t}{2}A\right) \underline{U}^n$$

e

$$b(\Delta t) = \frac{\Delta t}{2} \left(I - \frac{\Delta t}{2}A\right)^{-1} (\underline{g}^n + \underline{g}^{n+1}).$$

É importante colocarmos esta forma geral pois ela permitirá conversarmos sobre convergência, estabilidade e consistência. Como de costume, a consistência requer que o erro de truncamento tenda a 0 conforme o intervalo de tempo Δt faz o mesmo; a estabilidade, por sua vez, é um tipo conhecida por **Lax-Richtmyer**:

Definição. Um método linear da forma

$$\underline{U}^{n+1} = B(\Delta t)U^n + b^n(\Delta t)$$

é dito **Lax-Richtmyer estável** se, para todo tempo T , existir uma constante $c_T > 0$ tal que

$$\|B(\Delta t)^n\| \leq c_T$$

para todo $\Delta t > 0$ e inteiros n tais que $n\Delta t \leq T$. $\square$

Com isso,

Teorema (Equivalência de Lax). *Um método linear consistente da forma*

$$\underline{U}^{n+1} = B(\Delta t)U^n + b^n(\Delta t)$$

é convergente se, e somente se, ele é Lax-Richtmyer estável.

Finalmente, ganhamos um critério para a convergência, apesar de ficar meio estranha a questão de

$$\|B(\Delta t)^n\| < c_T.$$

Para ajudar, vamos tentar entender o caso do método de Euler, onde

$$B(\Delta t) = (I + \Delta t A);$$

para que o termo $B(\Delta t)^n$ seja limitado, uma das formas disso já foi feita, que foi quando olhamos os autovalores da matriz A

$$\lambda_p^A = \frac{2}{h^2} \cos(p\pi h) - 1.$$

Para a matriz B, eles serão

$$\lambda_p^B = 1 + \Delta t \frac{2}{h^2} \cos(p\pi h) - 1.$$

Assim, para ser Lax-Richtmyer estável, é necessário que potências da norma de $B(\Delta t)$ sejam limitadas, que, no sentido da convergência forte, consiste em mostrar que a norma de B em L^2 é menor que 1; para tanto, é necessário mostrar que λ_p^B têm que ser menor que 1! Fazendo isso, ganhamos

$$\begin{aligned} -1 < 1 + \Delta t \frac{2}{h^2} \cos(p\pi h) - 1 < 1 &\iff -2 < \Delta t \frac{2}{h^2} (\cos(p\pi h) - 1) < 0 \\ &\iff -h^2 < \Delta t (\cos(p\pi h) - 1) < 0 \\ &\stackrel{\text{pior caso é}}{\cos(p\pi h-1)=-1} \iff -h^2 \leq -2\Delta t \\ &\iff \Delta t \leq \frac{h^2}{2}. \end{aligned}$$

Outro nome dessa análise é **critério da matriz**.

Exercício 9. Repita a análise para o método de Euler implícito.

Para ambos os métodos que vimos, obtivemos $\|B\| \leq 1$, que é chamada **estabilidade forte**; porém, dá pra relaxar o critério: se existir uma constante α tal que $\|B\| \leq 1 + \alpha\Delta t$ para alguma norma, então ainda assim temos estabilidade Lax-Richtmyer nessa norma, já que

$$\|B^n\| \leq (1 + \alpha\Delta t)^n \leq e^{\alpha T}, \quad n\Delta t \leq T.$$

Existe uma forma diferente de analisar a estabilidade, conhecida como *Estabilidade de Von Neumann*, que é um pouco mais simplificada do que a versão vista: nela, é preciso utilizar a norma de B, mas é complicado encontrar uma forma fechada dos autovalores de B quando ela não for tridiagonal.

O método de Von Neumann é um método mais simplificado para fazer a análise de estabilidade, mas tem seus poréns, como esperado – vamos considerar que o problema é de Cauchy, indo de $-\infty$ a ∞ , sem condições de contorno (poderia-se pensar que é em torno de um círculo/periódico ao invés disso); a ideia é pegar a expansão de Fourier, pegar cada um dos modos dela independentemente e testar se a propagação do método é desastrosa. A ideia física deses método é que, num sistema estável, a energia de todos os componentes de frequência decaem independentemente para 0 conforme o tempo evolui.

Na prática, suponha que V é obtido de um conjunto de $v(x) \in L^2(\mathbb{R})$ em pontos de grade $x_j = jh$ para $j = 0, \pm 1, \pm 2, \dots$, que podem ser pensadas como versões discretas de $v(x)$, as chamadas **funções de malha/grade**; então, propriedades de Fourier bem semelhantes ao caso contínuo continuam válidos! Se $V_j \in \ell_2(\mathbb{Z})$, ou seja, se

$$\|V\|_2 := \left(h \sum_{j=-\infty}^{\infty} |V_j|^2 \right)^{\frac{1}{2}} < \infty,$$

então V_j pode ser expressa como na *Transformada de Fourier*:

$$V_j = \frac{1}{\sqrt{2\pi}} \int_{-\frac{\pi}{h}}^{\frac{\pi}{h}} \hat{V}(\zeta) e^{i(jh)\zeta} d\zeta,$$

onde

$$\hat{V}(\zeta) = \frac{h}{2\pi} \sum_{j=-\infty}^{\infty} V_j e^{-i(jh)\zeta} = \langle V_j, e^{i(jh)\zeta} \rangle_{\ell_2}.$$

Note que a frequência do número de onda, π/h , tende a infinito conforme a malha é reduzida em tamanho. A transformação linear entre V_j e $\hat{V}(\zeta)$ também preserva norma e satisfaz a *relação de Parseval*, com:

$$\|V\|_2 := \left(h \sum_{j=-\infty}^{\infty} |V_j|^2 \right)^{\frac{1}{2}} \quad \& \quad \|\hat{V}\|_2 := \left(\int_{-\frac{\pi}{h}}^{\frac{\pi}{h}} |\hat{V}(\zeta)|^2 d\zeta \right)^{\frac{1}{2}}.$$

Gostaríamos de mostrar que o método de diferenças finitas é estável na 2-norma, que constitui mostrar, para todo n , que

$$\|U^{n+1}\|_2 \leq (1 + \alpha \Delta t) \|U^n\|_2,$$

mas é complicado fazer isso diretamente. Como temos a identidade de Parseval em mãos e $\|U^n\|_2 = \|\hat{U}^n\|_2$, é suficiente mostrar que, na verdade, para todo n

$$\|\hat{U}^{n+1}\|_2 \leq (1 + \alpha \Delta t) \|\hat{U}^n\|_2.$$

Mais ainda, aplicando a transformação de Fourier em ambos os lados do método, junto à *regra de Translação*, chegamos em

$$\hat{U}^{n+1}(\zeta) = g(\zeta) \hat{U}^n(\zeta),$$

onde $g(\zeta)$ vai dependes da matriz $B(\Delta t)$. Logo, se mostrarmos que

$$|g(\zeta)| \leq 1 + \alpha \Delta t,$$

onde α independe de ζ , obteremos a estabilidade, pois, para todo ζ

$$|\hat{U}_j^{n+1}(\zeta)| \leq (1 + \alpha \Delta t) |\hat{U}_j^n(\zeta)|.$$

Agora que temos o desenho do que vamos fazer, consideremos um método de diferenças finitas progressivo

$$U_j^{n+1} = U_j^n + \frac{\Delta t}{h^2} (U_{j-1}^n - 2U_j^n + U_{j+1}^n).$$

Para aplicar a análise de Von Neumann, temos que considerar como este método irá funcionar num número de onda $\zeta \neq 0$, que corresponde a impôr $U_j^n = e^{ijh\zeta}$; esperamos que

$$U_j^{n+1} = g(\zeta) e^{ijh\zeta}$$

onde $g(\zeta)$ é o **fator de amplificação** para o número de onda ζ . Substituindo estes termos no método, obtemos

$$g(\zeta) e^{ijh\zeta} = e^{ijh\zeta} + \frac{\Delta t}{h^2} (e^{i\zeta(j-1)h} - 2e^{ijh\zeta} + e^{i\zeta(j+1)h}) = e^{ijh\zeta} \left(1 + \frac{\Delta t}{h^2} (e^{-ih\zeta} - 2 + e^{ih\zeta}) \right).$$

Consequentemente,

$$g(\zeta) = 1 + \frac{2\Delta t}{h^2} (\cos(\zeta h) - 1).$$

O pior caso possível é quando o cosseno vale -1, que dá exatamente o caso que vimos antes: para todo $\zeta \neq 0$,

$$1 - \frac{4\Delta t}{h^2} < g(\zeta) < 1,$$

e garantir que $|g(\zeta)| \leq 1$ para todo ζ consistirá em pedir que

$$\frac{4\Delta t}{h^2} \leq 2,$$

que é exatamente a restrição

$$\Delta t \leq \frac{h^2}{2}.$$

Exercício 10. Refaça os raciocínios acima para o método Crank-Nicolson, escrito

na forma de componentes como

$$U_j^{n+1} = U_j^n + \frac{\Delta t}{2h^2}(U_{j-1}^n - 2U_j^n + U_{j+1}^n + U_{j-1}^{n+1} - 2U_j^{n+1} + U_{j+1}^{n+1}).$$

Spoiler: tem que obter $\mathbf{g} = \frac{1 + \frac{1}{2}z}{1 - \frac{1}{2}z}$, onde

$$z = \frac{2\Delta t}{h^2}(\cos(\zeta h) - 1),$$

e obtendo que o $|\mathbf{g}| \leq 1$ para todo $\zeta \neq 0$, equivalente à estabilidade incondicional.

A principal diferença entre a análise de Lax-Richtmyer e a de Von Neumann é que, nesta segunda, descartamos completamente os termos de condições de contorno, e tudo bem em alguns casos, mas se fosse uma condição de Robin, por exemplo, que modifica a matriz do método, então pode haver um problema de estabilidade que será detectada pela estabilidade de Lax-Richtmyer, mas não pela de Von Neumann, justamente porque ela nem existiria nele! Isso pode ser um grande problema dependendo do problema analisado!

Lembrete!

Produto interno L^2 e Transformada de Fourier

Se $v(x) \in L^2(\mathbb{R})$, onde

$$L^2(\mathbb{R}) := \left\{ v : \mathbb{R} \rightarrow \mathbb{R} : \int_{-\infty}^{\infty} |v(x)|^2 dx < \infty \right\}, \quad \|v\|_2 = \left(\int_{-\infty}^{\infty} |v(x)|^2 dx \right)^{\frac{1}{2}}.$$

Então, existe uma base de funções que pode ser usada para expressar $v(x)$ em uma combinação linear, dada por $\{e^{i\zeta x} : \zeta \in \mathbb{R}\} \subseteq L^2(\mathbb{R})$, e com a expressão sendo:

$$v(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \hat{v}(\zeta) e^{i\zeta x} d\zeta.$$

Aqui, as projeções $\hat{v}(\zeta)$ é conhecido como **transformada de Fourier** de $v(x)$, expressa por

$$\hat{v}(\zeta) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} v(x) e^{-i\zeta x} dx = \langle v(x), e^{i\zeta x} \rangle_{L^2},$$

que é exatamente o produto interno de L^2 entre $v(x)$ e $e^{i\zeta x}$.

Lembrete!**Propriedades da Transformada de Fourier**

A **relação de Parseval** é a propriedade de preservação de Norma da transformada de Fourier:

$$\|v\|_2 = \|\hat{v}\|_2,$$

e para qualquer translação do ponto $\bar{x}$, vale a **Regra da translação**

$$v(x - \bar{x}) = e^{-i\zeta\bar{x}} \hat{v}(\zeta).$$

Lembrete!**Relação de Euler**

Para um ângulo θ , valem as relações:

$$e^{i\theta} = \cos \theta + i \sin \theta,$$

e, por isso,

$$\cos \theta = \frac{e^{i\theta} + e^{-i\theta}}{2} \quad \& \quad \sin \theta = \frac{e^{i\theta} - e^{-i\theta}}{2i}$$

16 Aula 16 - 01 de Junho, 2026

16.1 Motivações

- Problemas multidimensionais.

16.2 Alguns Comentários Sobre Equações Parabólicas

Antes do próximo toco, é importante comentarmos algumas coisas sobre equações parabólicas, por exemplo que o tratamento de condições de contorno de Neumann são similares ao caso anterior, envolvendo os pontos fantasmas para estimar o ponto com a derivada e alterações à matriz $\mathbf{B}(\Delta t)$; então, a consequência disso é que a análise de estabilidade de Von Neumann torna-se inutilizável para melhor descrever um problema de contorno de Neumann: se um problema de estabilidade vier da discretização, a análise de Von Neumann não irá pegar ela.

Se tivermos duas condições de contorno de Neumann, o problema deixa de ser singular, tal que ele pode atingir um estágio estacionário, ou não! A solução pode ou não evoluir até a derivada temporal ser nula, como se tivesse uma fonte fornecendo cada vez mais calor ao sistema; ainda assim, podemos resolver esse sistema, mas a solução será transiente.

Da mesma forma que fizemos a discretização espacial do tipo

$$\frac{d}{dx} \left(\kappa(x) \frac{du}{dx} \right) = f(x)$$

previamente, poderíamos fazer algo parecido para problemas temporais, especialmente quando modelamos meios porosos: se considerarmos uma função como $\kappa(x, t)$, então a discretização espacial seria algo como

$$\frac{\partial u}{\partial t} = \frac{\partial}{\partial x} \underbrace{\left(\kappa(x, t) \frac{\partial u}{\partial x} \right)}_{\text{velocidade de escoamento}} + f(x, t),$$

usado bastante, por exemplo, para avaliar a extração de petróleo em um meio poroso com permeabilidade $\kappa(x)$.

O último comentário vai aparecer inclusive quando formos estudar equações hiperbólicas, e envolve os chamados problemas de difusão

$$\frac{\partial u}{\partial t} + v \frac{\partial u}{\partial x} = \kappa \frac{\partial^2 u}{\partial x^2},$$

onde aparece o **termo de transporte** $v \frac{\partial u}{\partial x}$, o qual também deve ser discretizado. É interessante, também, o caso geral desse, onde há uma equação não linear

$$\frac{\partial u}{\partial t} = f\left(x, t, u, \frac{\partial u}{\partial x}, \frac{\partial^2 u}{\partial x^2}, \frac{\partial u}{\partial t}\right),$$

ou quasilinear (sem o termo $\partial_t u$); para resolver um problema desse tipo, é necessário fazer método de Newton e discretizar a função f , sendo que, dependendo da forma como isso é feito, a aplicação do método das linhas, a exemplo, geraria algo do tipo

$$\frac{d}{dt}U_j = f(x_j, t, U_j(t), \text{Discretizações}),$$

como no caso de

$$\frac{d}{dt}U_j = f\left(x_j, t, \frac{U_{j+1}(t) - U_{j-1}(t)}{2h}, \frac{U_{j+1}(t) - 2U_j(t) + U_{j-1}(t)}{h^2}\right),$$

e aplicar um método de Euler normalmente, ou RK, Crank-Nickolson, etc, gerando métodos implícitos ou explícitos e todo o processo que já vimos.

16.3 Problemas Multidimensionais

Armados com um grande arcabouço ferramental dos diversos métodos estudados até agora, o próximo passo é aumentar a complexidade do problema: resolver um problema de uma caixa como um unidimensional é considerar que a linha onde resolvemos aproxima bem tudo que ocorre abaixo dela; ao invés disso, poderíamos recortar a caixa diagonalmente por um plano, analisando o escoamento nele, dando uma modelagem um pouco melhor já, mas foi preciso aprender a resolver um problema parabólico com mais dimensões espaciais (2, especificamente); mas esse é o melhor que podemos fazer? E se considerarmos o cubo todo?

Vamos comentar esse caso, que não muda muito do processo de passagem das condições de contorno para equações elípticas. Nosso problema consiste em encontrar uma função $u(\underline{x}, t)$, onde $\underline{x}$ é, agora, um vetor da forma

$$\underline{x} = \begin{bmatrix} x \\ y \end{bmatrix} \in \mathbb{R}^2,$$

permitindo escrevermos $u(x, y, t)$, e queremos que u satisfaça uma equação parabó-

lica do tipo, como

$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2}.$$

Podemos supor que conhecemos a solução num certo contorno Γ_1 , dada por $u(\underline{x}, t) = g(\underline{x}, t)$, $\underline{x} \in \Gamma_1$, ou com uma condição de Neumann em outro contorno Γ_2

$$\nabla u(\underline{x}, t) \cdot n = \sigma(\underline{x}, t) \quad \forall \underline{x} \in \Gamma_2,$$

junto a uma condição inicial $u(\underline{x}, 0) = \eta(\underline{x})$.

Essencialmente, precisamos discretizar espacialmente o domínio Ω , suposto por simplicidade como sendo $\Omega = (0, 1) \times (0, 1)$, como no caso dos problemas elípticos, tal qual usando o Laplaciano de 5 pontos:

$$\nabla_h^2 U_{ij} = \frac{1}{h^2} \left(U_{i-1,j} + U_{i+1,j} + U_{i,j-1} + U_{i,j+1} - 4U_{ij} \right), \quad 1 \leq i, j \leq m.$$

Discretizando no tempo também em seguida, supondo que estamos usando algo tipo Euler, teríamos a equação

$$\frac{\partial u}{\partial t}(x_{ij}, t_n) = \frac{\partial^2 u}{\partial x^2}(x_{ij}, t_n) + \frac{\partial^2 u}{\partial y^2}(x_{ij}, t_n),$$

que, discretizada, é

$$\begin{aligned} \frac{u(x_i, y_j, t_{n+1})}{\Delta t} + O(\Delta t) &= \frac{u(x_i + \Delta x, y_j, t_n) - 2u(x_i, y_j, t_n) + u(x_i - \Delta x, y_j, t_n)}{\Delta x^2} + O(\Delta x^2) \\ &+ \frac{u(x_i, y_j + \Delta y, t_n) - 2u(x_i, y_j, t_n) + u(x_i, y_j - \Delta y, t_n)}{\Delta y^2} + O(\Delta y^2). \end{aligned}$$

Descartando os erros, portanto, ganhamos a aproximação com base em $U_{i,j}^n \approx u(x_i, y_j, t_n)$ e

$$\boxed{\frac{U_{i,j}^{n+1} - U_{i,j}^n}{\Delta t} = \frac{U_{i+1,j}^n - 2U_{i,j}^n + U_{i-1,j}^n}{\Delta x^2} + \frac{U_{i,j+1}^n - 2U_{i,j}^n + U_{i,j-1}^n}{\Delta y^2}}.$$

Vamos pensar no caso do meio poroso, tipo um complexo de pedras que têm canais diferentes fazendo o escoamento poroso muito mais rápido numa direção do que em outro. Dessa forma, seria interessante introduzir uma discretização que fosse fina na direção de maior escoamento, para capturar mais coisa, e grossa em outra: o Δx e o Δy seriam diferentes, justamente porque existe uma diferença na prioridade do que queremos capturar. Fazendo isso, a parte do lado direito pode ser

simplificada para algo do tipo

$$U_{i,j}^{n+1} = U_{i,j}^n + \frac{\Delta t}{h^2} \left(U_{i+1,j}^n + U_{i-1,j}^n + U_{i,j+1}^n + U_{i,j-1}^n - 4U_{i,j}^n \right),$$

ou, usando a notação do operador laplaciano discretizado

$$\nabla_h^2 U_{i,j}^n := U_{i+1,j}^n + U_{i-1,j}^n + U_{i,j+1}^n + U_{i,j-1}^n - 4U_{i,j}^n,$$

simplesmente escrever

$$U_{i,j}^{n+1} = U_{i,j}^n + \frac{\Delta t}{h^2} \nabla_h^2 U_{i,j}^n.$$

Poderíamos escrever isso na forma matricial, mas ganharíamos um problema com o ordenamento das incógnitas (também já vimos como lidar), usando a enumeração por linhas, por coluna, o red-blue (red-black), etc, levando a

$$\underline{U}^{n+1} = \underline{U}^n + \Delta t A \underline{U}^n, \quad A = \frac{1}{h^2} \begin{bmatrix} -4 & 1 & 0 & \dots & 1 & & \\ 1 & -4 & 1 & \dots & 0 & 1 & \\ 0 & 1 & -4 & \dots & 0 & 0 & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & \dots & 1 & -4 & 1 & \dots & 1 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \vdots \end{bmatrix},$$

que é exatamente a mesma coisa de antes! A única coisa que muda é a complexidade dos termos, dos vetores, etc, mudando um pouco a notação, mas nem tanto, afinal a expressão acima é exatamente

$$\underline{U}^{n+1} = B(\Delta t) \underline{U}^n + \underline{g}^n, \quad B(\Delta t) = I + \Delta t A.$$

O método de Crank-Nicolson dessa versão, pela mesma lógica, ficaria

$$U_{i,j}^{n+1} = U_{i,j}^n + \frac{\Delta t}{h^2} \left(\nabla_h^2 U_{i,j}^n + \Delta_h^2 U_{i,j}^{n+1} \right),$$

ou

$$\begin{aligned}
U_{i,j}^{n+1} - \frac{\Delta t}{2h^2} \nabla_h^2 U_{i,j}^{n+1} &= U_{i,j}^n + \frac{\Delta t}{2h^2} \nabla_h^2 U_{i,j}^n \\
\iff \left(I - \frac{\Delta t}{2h^2} \nabla_h^2 \right) U_{i,j}^{n+1} &= \left(I - \frac{\Delta t}{2h^2} \nabla_h^2 \right) U_{i,j}^n \\
\iff \left(I - \frac{\Delta t}{2h^2} A \right) \underline{U}^{n+1} &= \left(I - \frac{\Delta t}{2h^2} A \right) \underline{U}^n \\
\text{Considerando h} & \\
\text{dentro de } \nabla_h^2 & \\
\iff \boxed{\left(I - \frac{\Delta t}{2} A \right) \underline{U}^{n+1} = \left(I - \frac{\Delta t}{2} A \right) \underline{U}^n} &
\end{aligned}$$

A única mudança realmente grande é que é preciso enumerar certinho as dimensões e tomar cuidados com indexação, mas a forma geral dos métodos continua praticamente igual; a do Crank-Nickolson geral, por exemplo, é

$$\underline{U}^{n+1} = \underbrace{\left(I - \frac{\Delta t}{2} A \right)^{-1} \left(I + \frac{\Delta t}{2} A \right)}_{B(\Delta t)} U_{i,j}^n + \underbrace{\left(I - \frac{\Delta t}{2} A \right)^{-1}}_{b(\Delta t)} (\underline{g}^n + \underline{g}^{n+1}).$$

17 Aula 17 - 03 de Junho, 2026

17.1 Motivações

- Problemas Multidimensionais

17.2 Problemas Multidimensionais

Antes de continuarmos, retomemos a forma geral dos métodos numérico para problemas parabólicos:

$$\underline{U}^{n+1} = B(\Delta t)\underline{U}^n + \underline{b}(\Delta t)$$

Seja $A = I - \frac{\Delta t}{2}\nabla_h^2$, com os mesmos padrões de entradas não nulas que a matriz de ∇_h^2 , mas multiplicados por $\Delta t/2$ e subtraída da identidade; os autovalores de A, com $h = \frac{1}{m+1}$, são:

$$\Lambda_{p,q} = 1 - \frac{\Delta t}{h^2} \left((\cos(p\pi h) - 1) + (\cos(q\pi h) - 1) \right) > 0, \quad p, q = 1, 2, \dots, m.$$

A numeração p, q é conveniência da numeração bidimensional, mas são m^2 autovalores ao todo.

Logo, os maiores e menores autovalores são dados por

$$\begin{aligned} \lambda_{m,m} &\approx 1 - \frac{\Delta t}{h^2}(-2 - 2) = 1 + \frac{4\Delta t}{h^2} = O\left(\frac{\Delta t}{h^2}\right) \\ \lambda_{1,1} &= 1 - \frac{2\Delta t}{h^2} \left(1 - \frac{\pi^2 h^2}{2} + \frac{\pi^4 h^4}{24} + \dots - 1 \right) = 1 + \pi^2 \Delta t + O(\Delta t h^2) = 1 + O(\Delta t). \end{aligned}$$

Continuando as contas, no caso unidimensional, chegamos na relação $\frac{\Delta t}{\Delta x^2} \leq \frac{1}{2}$, mas para o Euler, foi $\frac{\Delta t}{\Delta x^2} \leq \frac{1}{4}$ por conta de um termo de 1/2 nos autovalores A partir de um número muito grande de incógnitas, fica muito complicado resolver estes problemas com métodos diretos, sendo necessário entrar com os métodos iterativos, tendo em mente que eles têm muita sensibilidade ao raio espectral da matriz. Assim, é de interesse entender que, decorrente dos resultados acima, o número de condição de A é

$$\kappa_2(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\lambda_{m,m}}{\lambda_{1,1}} = O(\Delta t h^{-2}),$$

formalmente definido por

Definição. O **número de condição** de uma matriz A é a razão de seu maior

autovalor pelo menor autovalor:

$$\kappa_2(A) = \frac{\lambda_{m,m}}{\lambda_{1,1}}. \quad \square$$

Por outro lado, o operador ∇_h^2 sozinho tem número de condição $\mathcal{O}(h^{-2})$; quanto menor o número de condição, pelo menos no caso presente, mais rápida será a convergência dos métodos iterativos, pois o número de condição cresce quadraticamente com o inverso de h .

Veremos algumas formas de reduzir o custo computacional, mas dando uma breve contextualização antes. Por exemplo, vamos considerar chutes para $\underline{U}^{n+1}$ no método de Crank-Nicolson:

$$\underline{U}_{ij}^{n+1} = \underline{U}_{ij}^n + \frac{\Delta t}{2} \left(\nabla_h^2 \underline{U}_{ij}^n + \nabla_h^2 \underline{U}_{ij}^{n+1} \right), \quad 1 \leq i, j \leq m.$$

Como $\underline{U}_{ij}^{n+1} = \underline{U}_{ij}^n + \mathcal{O}(\Delta t)$, podemos usar $\underline{U}_{ij}^n$ (ou seja, valores das últimas passadas de tempo) como chutes para um método iterativo; melhor ainda, é possível fazer uma extrapolação progressiva no tempo usando

$$\underline{U}_{ij}^{[0]} = 2\underline{U}_{ij}^n - \underline{U}_{ij}^{n-1},$$

ou mesmo com um método explícito

$$\underline{U}_{ij}^{[0]} = (1 + \Delta t \nabla_h^2) \underline{U}_{ij}^n.$$

Ao invés de resolver uma equação de matriz esparsa acoplada para cada incógnita, partindo da equação discretizada de Crank-Nicolson na forma de operador

$$\nabla_h^2 \underline{U}_{ij}^n = \underbrace{\frac{1}{h^2} (\underline{U}_{i-1,j} - 2\underline{U}_{ij} + \underline{U}_{i+1,j})}_{:=D_x^2} + \underbrace{\frac{1}{h^2} (\underline{U}_{i,j-1} - 2\underline{U}_{ij} + \underline{U}_{i,j+1})}_{:=D_y^2}$$

e do método de Crank-Nicolson em sua forma matricial

$$\left(I - \frac{\Delta t}{2} A \right) \underline{U}^{n+1} = \left(I + \frac{\Delta t}{2} A \right) \underline{U}^n,$$

uma alternativa é utilizar o **método localmente unidimensional** (LOD – *Locally One-Dimensional method*): como a difusão atua em todas as direções ao mesmo tempo, vamos desacoplar ela primeiro, resolver o problema em uma direção, e depois

reacoplar. Primeiro, resolvemos apenas a direção x, depois na direção y:

$$U_{ij}^* = U_{ij}^n + \frac{\Delta t}{2}(D_x^2 U_{ij}^n + D_x^2 U_{ij}^*) \quad (\text{Crank-Nicolson na direção x})$$

$$U_{ij}^{n+1} = U_{ij}^* + \frac{\Delta t}{2}(D_y^2 U_{ij}^* + D_y^2 U_{ij}^{n+1}) \quad (\text{Crank-Nicolson na direção y})$$

Após obter o termo U_{ij}^* , ele foi utilizado para resolver a discretização na direção y – resolvemos na direção x, obtivemos U_{ij}^* e prosseguimos resolvendo na direção y.

Parte da física desse sistema, porém, acaba demorando mais para ser propagada, passando a ter um retardo na difusão; no entanto, sendo um processo iterativo, este efeito tende a ser minimizado, apesar de infelizmente depender bastante da escolha inicial, principalmente para casos onde a difusão começa muito mais forte em alguma direção específica.

Mesmo com todas estas consequências, estas ideias dão algumas coisas bem interessantes, como prevenir a resolução de uma matriz pentadiagonal, para a qual métodos diretos resolvem com $\mathcal{O}(N^3)$ operações, e $\mathcal{O}(N^2)$ para os métodos iterativos, então é bem caro; usando o LOD, porém, o termo $I - \frac{\Delta t}{2}D_x$ e o mesmo no y são duas matrizes tridiagonais, tornando o custo computacional bem mais barato de apenas duas matrizes com custo $\mathcal{O}(N)$. Não entraremos em detalhes sobre isso, mas o LOD é bem ruim em lidar com condições de contorno.

Outro método usado frequentemente é uma modificação do LOD; ou melhor, é uma classe de métodos conhecidos como ADI (*Alternating Direction Implicitly method*), que trata as direções alternando-as ao invés de separando-as. Sua forma clássica é

$$U_{ij}^* = U_{ij}^n + \frac{\Delta t}{2}(D_y^2 U_{ij}^n + D_x^2 U_{ij}^*),$$

$$U_{ij}^{n+1} = U_{ij}^* + \frac{\Delta t}{2}(D_x^2 U_{ij}^* + D_y^2 U_{ij}^{n+1}),$$

dando novamente sistemas tridiagonais desacoplados em cada etapa:

$$\left(I - \frac{\Delta t}{2}D_x^2\right)U^* = \left(I + \frac{\Delta t}{2}D_y\right)U_{ij}^n$$

$$\left(I - \frac{\Delta t}{2}D_y^2\right)U^* = \left(I + \frac{\Delta t}{2}D_x\right)U_{ij}^n,$$

com cada uma delas alternando qual operador será o implícito e qual será o explícito.

Daqui pra frente, o grau de complexidade continua aumentando, podendo incluir mais termos, coeficientes que ficam alternando, presença de termos não line-

ares; mas todas as tecnologias que vimos para lidar com isso continuam funcionando, como a linearização por método de Newton, por preditor-corretor, etc. O problema multidimensional não introduz novos problemas, mas introduz novas complexidades, principalmente quanto à enumeração das incógnitas. A grande novidade daqui é justamente o ADI!

Se tivéssemos um problema tridimensional, poderíamos gerar um ADI de três etapas, cada uma em uma direção, mas com erros e complexidades que ficam se acumulando a cada aumento desses – todo mundo depende de todo mundo, e desacoplar gera um retardo cada vez maior de acordo com isso. O bom deles é que eles preservam a estrutura das malhas, uma grande vantagem conforme surgem problemas piores.

18 Aula 18 - 10 de Junho, 2026

18.1 Motivações

- Equação de Advecção

18.2 Equações Hiperbólicas

Começamos o tópico das equações para sistemas hiperbólicos, que apesar de ser simples no caso unidimensional e com problema de Cauchy, passa a ter complexidade considerável com mudanças nessas condições, vide Navier-Stokes

$$\underbrace{\frac{\partial \underline{u}}{\partial t} + \underline{u} \cdot \nabla \underline{u}}_{\text{Parte hiperbólica}} = -\nabla p + \mu \nabla \cdot (\nabla \underline{u} + \nabla \underline{u}^T)$$

A parte hiperbólica, correspondente ao transporte, é o termo mais complicador de Navier-Stokes.

Começamos com um problema simples, chamado **equação de advecção**, por enquanto como problema de Cauchy:

$$u_t + au_x = 0, \quad -\infty < x < \infty, \quad t > 0, \quad u(x, 0) = \eta(x),$$

onde a seria um termo que representa a “velocidade de transporte”; para uma breve revisão do aspecto analítico dela, vamos considerar $x = x(s)$, $t = t(s)$ tal que $u(x, t) = u(x(s), t(s))$. Pela regra da cadeia,

$$\frac{\partial u}{\partial s} = \frac{\partial u}{\partial x} \frac{\partial x}{\partial s} + \frac{\partial u}{\partial t} \frac{\partial t}{\partial s} = 0,$$

que é essencialmente a equação de transporte se $\partial_s x = a$ e $\partial_s t = 1$. Logo,

$$x(s) = x_0 + as \quad \& \quad t(s) = t_0 + s,$$

que são as *curvas características* da equação transporte – com estas identificações, a equação representa o transporte de algum perfil inicial ao longo do tempo e do espaço.




Figura 11: a linha vermelha foi transportada ao longo do espaço a cada tempo.

Agora, como $\partial_s u = 0$, sabemos que $u(x, t)$ deve ser constante para qualquer s ! Por isso, para $s = 0$, deve acontecer

$$\begin{aligned} \text{cte} = u(x(s), t(s)) &= u(x_0 + as, s) \\ &= u(x_0, 0) \text{ (usando } s=0) \\ &= \eta(x_0) \\ &= \eta(x_0 - as) \\ &= \eta(x_0 - at) \text{ (usando } t=s), \end{aligned}$$

que é a condição inicial transladada at unidades para a direita. As curvas características são, então, as direções de propagação de informações das equações hiperbólicas!

Se tivermos uma equação da forma

$$u_t + au_x + bu = d,$$

podemos obter

$$\frac{dx}{dt} = a \Rightarrow \frac{du}{dt} = d - bu,$$

ou então, por exemplo,

$$u_t + tu_x = 3 \Rightarrow \frac{dx}{dt} = t \Rightarrow x(t) = \frac{t^2}{2} + x_0.$$

Com nosso conhecimento de discretização, iremos discretizar a equação hiperbólica e ver o que podemos obter! Partindo de

$$u_t + au_x = 0,$$

o primeiro passo é discretizar no tempo por Δt (ou k) e no espaço por Δx (ou h),

obtendo pares $(x_j, t_n) = (jh, nk)$. Usando uma aproximação de diferenças finitas e diferenças centrais para

$$u_t(x_j, t_n) + au_x(x_j, t_n) = 0,$$

segue que

$$u_t(x_j, t_n) \approx \frac{u(x_j, t_n + \Delta t) - u(x_j, t_n)}{\Delta t} + O(\Delta t)$$

e

$$u_x(x_j, t_n) \approx \frac{u(x_j + \Delta x, t_n) - u(x_j - \Delta x, t_n)}{2\Delta x} + O(\Delta x^2),$$

tal que, denotando por $U_j^n \approx u(x_j, t_n)$, obtemos o método

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} + a \frac{U_{j+1}^n - U_{j-1}^n}{2\Delta x} = 0,$$

que é de consistência à ordem $O(\Delta t + \Delta x^2)$. Resta analisarmos a convergência dele, que vai ser a estabilidade (já temos a consistência), podendo ser feito por Von-Neumann isolando o termo do passo temporal $n+1$:

$$U_j^{n+1} = U_j^n - a \frac{\Delta t}{2\Delta x} (U_{j+1}^n - U_{j-1}^n).$$

Denotando $\xi h =: \beta$ e usando $U_j^n = e^{ijh\xi} = e^{i\beta j}$, comparamos a expressão acima com

$$U_j^{n+1} = g(\xi) U_j^n,$$

tal que

$$g e^{i\beta j} = e^{i\beta j} - \frac{a\Delta t}{2\Delta x} (e^{i\beta(j+1)} - e^{i\beta(j-1)}) = e^{i\beta j} \left(1 - \frac{a\Delta t}{2\Delta x} (e^{i\beta} - e^{-i\beta}) \right),$$

e obtemos

$$g = 1 - \frac{a\Delta t}{2\Delta x} (e^{i\beta} - e^{-i\beta}) = 1 - \frac{a\Delta t}{2\Delta x} 2i \sin \beta = 1 - \frac{a\Delta t}{\Delta x} i \sin \beta.$$

Agora, analisamos o módulo de g , de modo que

$$|g|^2 = 1 + \left(\frac{a\Delta t}{\Delta x} \right)^2 \sin^2 \beta,$$

mas como a norma é sempre maior que 1, **o método é incondicionalmente instável!** Não adianta usar o método mais simples, porque ele não vai convergir. E agora?

O próximo passo natural é partir para um método diferente, especificamente o **método Lax-Friedrichs**, que consiste em trocar o termo U_j^n da discretização por uma média entre dois espaços:

$$U_j^{n+1} = \frac{1}{2}(U_{j-1}^n + U_{j+1}^n) - \frac{a\Delta t}{2\Delta x}(U_{j+1}^n - U_{j-1}^n)$$

Repetindo a análise de Von-Neumann para este caso, observar-se-á que

$$g = \frac{1}{2}(e^{i\beta} + e^{-i\beta}) - \frac{a\Delta t}{2\Delta x}(e^{i\beta} - e^{-i\beta}) = \cos \beta - \frac{a\Delta t}{\Delta x}i \sin \beta,$$

o qual é um número complexo dentro de um círculo, cujo raio será menor que 1 se, e somente se, o termo $(a\Delta t)/\Delta x$ tiver módulo menor ou igual a 1! Agora sim, temos um método condicionalmente estável e com condição de estabilidade dada por

$$\frac{|a|\Delta t}{\Delta x} \leq 1;$$

o termo à esquerda é chamado **número de Courant**.

Com essa pequena modificação, conseguimos um método com custo computacional de um método explícito, convergente desde que Δt e Δx tenham a mesma ordem de convergência, que não é uma restrição severa!

Exercício 11. Calcule o erro de truncamento do *método Lax-Friedrichs*.

Em suma, o que fizemos até agora foi testar uma discretização central, que foi instável, e uma pequena modificação nele garantiu uma estabilidade condicional. Em seguida, vamos convencionar $a > 0$, tornando as características em retas que levam a informação da esquerda à direita; o método que fizemos, essencialmente, pega informação em formato de T invertido – o $(n+1)$ -ésimo passo temporal usa o $(j-1)$, o $(j+1)$ e o j -ésimo passos temporais no tempo n . Compor a solução acima consiste em pegar informação à esquerda e à direita! O primeiro faz sentido pela forma que a informação se propaga, mas o segundo não! Então, fazer um estêncil simétrico talvez não seja a melhor coisa aqui, pois a informação à direita ainda nem existe às vezes. Logo, usaremos uma discretização regressiva para o termo derivado em x :

$$u_x \approx a \frac{u(x_j, t_n) - u(x_j - \Delta x, t_n)}{\Delta x} + O(\Delta x),$$

dando o **método upwind** para propagações da esquerda à direita da forma

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} + a \frac{U_j^n - U_{j-1}^n}{\Delta x} = 0;$$

por outro lado, se $a < 0$, o sentido de propagação passa a ser da direita para a esquerda, sendo então preciso um método progressivo em x :

$$u_x \approx a \frac{u(x_j + \Delta x, t_n) - u(x_j, t_n)}{\Delta x} + O(\Delta x),$$

do qual obtemos o **método *downwind*** para o transporte

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} + a \frac{U_{j+1}^n - U_j^n}{\Delta x} = 0.$$

Exercício 12. Determine se os métodos acima convergem ou não. **Dica:** a consistência é da ordem $O(\Delta t + h)$, e a análise de Von-Neumann tem que dar a mesma condição de antes no número de Courant.

De forma compacta,

$$U_j^{n+1} = \begin{cases} U_j^n - \frac{a\Delta t}{\Delta x}(U_j^n - U_{j-1}^n), & a \geq 0 \\ U_j^n - \frac{a\Delta t}{\Delta x}(U_{j+1}^n - U_j^n), & a < 0 \end{cases}.$$

Normalmente, não queremos resolver o método em um espaço infinito, então costuma ser bom limitar o intervalo, por exemplo, a um espaço $[0, 1]$, resolvendo até certo tempo T , sendo necessário impôr apenas uma condição de contorno pela unidimensionalidade; onde ela deve ser posta? Depende de cada problema; se o transporte é da esquerda pra direita, coloca à esquerda, no 0, mas se ela for da direita pra esquerda, então tem que pôr a condição à direita, no 1. Porém, considerando o primeiro caso, surge um problema: ao chegar no limite à direita, fica faltando um ponto para descrever o problema! Por isso acaba sendo vantajoso usar métodos unilaterais ao invés dos simétricos, mesmo sendo possível ajustar a condição de contorno no limite, afinal isso acaba adicionando erros ao método. Uma solução mais ingênua que aparece às vezes é considerar uma condição de contorno fictícia, por exemplo que o que está saindo não é pra ser mexido, impondo a condição 0.

Definição. O lado por onde o escoamento entra é chamado **inflow**, e o lado por onde sai é chamado **outflow** (se vai estar à esquerda ou à direita depende do sinal do a). $\square$

O caso de $a < 0$ é análogo.

19 Aula 19 - 15 de Junho, 2026

19.1 Motivações

- Discretizando a Equação Hiperbólica;
- Método Lax-Wendroff.

19.2 Introduzindo Difusão à Advecção

Utilizamos o método das linhas para discretizar a equação hiperbólica, obtendo

$$u_t(x_j, t) + a \left(\frac{u(x_{j+1}, t) - u(x_{j-1}, t)}{2\Delta x} \right) + O(h^2) = 0,$$

mas dessa vez olharemos as condições de contorno periódicas, como se restringíssemos o problema a um círculo ao invés da reta toda.

Consideramos a discretização espacial $u_0(t), u_1(t), \dots, u_m(t), u_{m+1}(t) = u_0(t)$; assim, se for necessário aplicar um estêncil centrado, o $j + 1$ do ponto à extrema direita vai ser o mesmo que o ponto logo após o 0, ou seja, o 1 (analogamente para o ponto mais à esquerda). Como o tempo foi mantido contínuo, temos o sistema de EDOs resultante

$$\frac{d}{dt} U_j(t) + \frac{a}{2\Delta x} (U_{j+1}(t) - U_{j-1}(t)) = 0,$$

mas é necessário tomar uma decisão se chamaremos os índices de 0 até m ou de 1 até $m+1$; manteremos este segundo, obtendo, para $j = 1$, o sistema

$$\frac{d}{dt} U_1(t) + \frac{a}{2\Delta x} (U_2(t) - U_{m+1}(t)) = 0$$

e, para $j = m + 1$, o ponto à direita dele “é o 1”:

$$\frac{d}{dt} U_{m+1} + \frac{a}{2\Delta x} (U_1 - U_m(t)) = 0 \iff \underline{U}'(t) = A \underline{U}(t), \quad U_j(0) = \eta(x_j).$$

Agora, montamos a forma como isso aparece matricialmente, que será

$$\frac{d}{dt} \begin{bmatrix} U_1(t) \\ U_2(t) \\ \vdots \\ U_{m+1}(t) \end{bmatrix} + \frac{a}{2\Delta x} \begin{bmatrix} 0 & 1 & 0 & \dots & 0 & -1 \\ -1 & 0 & 1 & 0 & \dots & \\ \vdots & \ddots & \vdots & \vdots & \vdots & \vdots \\ 1 & 0 & \dots & 0 & -1 & 0 \end{bmatrix} \begin{bmatrix} U_1(t) \\ U_2(t) \\ \vdots \\ U_{m+1}(t) \end{bmatrix} = 0$$

e já de cara dá pra notar que a matriz A é diferente dos casos anteriores pois ela

é *antisimétrica*, os elementos acima da diagonal são iguais aos da diagonal inferior, mas com sinais invertidos ($A^T = -A$), além de que **todos os seus autovalores são não reais**, com forma

$$\lambda_p = -i \frac{a}{\Delta x} \sin(2\pi p \Delta x), \quad p = 1, 2, \dots, m+1;$$

assim, por seno variar entre -1 e 1, os autovalores estão todos entre $-i \frac{a}{\Delta x}$ e $i \frac{a}{\Delta x}$. Se fossemos resolver por Euler explícito, sabemos onde ficam os seus autovalores de estabilidade, estando no círculo entre -2 e 0, mas todos os autovalores deste método estão no eixo imaginário puro! Logo, o resultado da falta de estabilidade do método de Euler explícito ganhou mais uma explicação. Qual método que havíamos visto e que foi descartado no método parabólico justamente porque a estabilidade surgia apenas para autovalores imaginários puros? O método do ponto médio:

$$\boxed{\underline{U}^{n+2} = \underline{U}^n + 2\Delta t \underline{U} F^{n+1}}.$$

Antes de aplicá-lo, consideremos uma discretização espacial por diferenças progressivas:

$$\underline{U}^{n+1} = \underline{U}^n + \Delta t \underline{A} \underline{U}^n = \underbrace{(I + \Delta t \underline{A})}_{B(\Delta t)} \underline{U}^n;$$

então, o método será convergente se conseguirmos Δt tender a 0 mais rápido que Δx , por exemplo tomando $\Delta t = \Delta x^2$, caso no qual

$$\|1 + \Delta t \underline{A}\|_2^2 = \rho((I - \Delta t \underline{A})(I + \Delta t \underline{A})) = \rho(I - \Delta t^2 \underline{A}^2) \leq 1 + \Delta t^2 \frac{a^2}{\Delta x^2} = 1 + a^2 \Delta t.$$

Logo, se $n\Delta t \leq T$ e $\Delta t = \Delta x^2$, teremos a estabilidade Lax-Richtmeyer

$$\|(I + \Delta \underline{A})^n\|_2 \leq (1 + a^2 \Delta t)^{\frac{n}{2}} \leq e^{a^2 \frac{T}{2}}.$$

O problema é que essa limitação de $\Delta t = \Delta x^2$ é muito ruim, tornando a análise acima, que parecia muito útil, em inútil.

Agora, utilizando a regra do ponto médio ao PVI, obtemos o chamado **método leapfrog** para a equação hiperbólica:

$$\boxed{U_j^{n+1} = U_j^{n-1} - \frac{a\Delta t}{2\Delta x} (U_{j+1}^n - U_{j-1}^n)},$$

resultando num método explícito de 3 níveis e de ordem dois tanto no espaço quanto

no tempo. Mais ainda, a estabilidade é dada justamente pela condição

$$\frac{|a|\Delta t}{\Delta x} \leq 1,$$

novamente voltando ao número de Courant. Logo, o método leapfrog é um explícito que parece funcionar bem para esse problema.

Retomemos, dessa vez, o método Lax-Friedrichs

$$U_j^{n+1} = \frac{1}{2}(U_{j-1}^n + U_{j+1}^n) - \frac{a\Delta t}{2\Delta x}(U_{j+1}^n - U_{j-1}^n)$$

e somemos $0 = U_j^n - \frac{1}{2}2U_j^n$ em volta do primeiro parêntesis:

$$U_j^{n+1} = U_j^n + \frac{1}{2}(U_{j-1}^n - 2U_j^n + U_{j+1}^n) - \frac{a\Delta t}{2\Delta x}(U_{j+1}^n - U_{j-1}^n).$$

Rearranjando, obtemos a expressão

$$\frac{U_j^{n+1} - U_j^n}{\Delta t} + a\left(\frac{U_{j+1}^n - U_{j-1}^n}{2\Delta x}\right) = \frac{\Delta x^2}{2\Delta t}\left(\frac{U_{j-1}^n - 2U_j^n + U_{j+1}^n}{\Delta x^2}\right),$$

que ainda é o método Lax-Friedrichs, afinal apenas somamos 0 e multiplicamos 1, mas ele recebeu a discretização de u_t , de u_x e u_{xx} à direita da igualdade! Porém, como o método de Lax-Friedrichs é consistente de ordem 2 no espaço e 1 no tempo para a equação do transporte sem o termo $\frac{\Delta x^2}{2\Delta t}$, estamos essencialmente escrevendo a versão discretizada de uma equação de advecção-difusão

$$u_t + au_x = \varepsilon u_{xx}, \quad \varepsilon = \frac{\Delta x^2}{2\Delta t},$$

tal que, olhando para a matriz de amplificação com o termo εu_{xx} ,

$$A_\varepsilon = -\frac{a}{2\Delta x} \begin{bmatrix} 0 & 1 & 0 & \dots & -1 \\ -1 & 0 & 1 & 0 & \dots \\ \vdots & \ddots & \vdots & \vdots & \vdots \\ 1 & 0 & \dots & 0 & -1 & 0 \end{bmatrix} + \frac{\varepsilon}{\Delta x^2} \begin{bmatrix} -2 & 1 & 0 & \dots & 1 \\ 1 & -2 & 1 & 0 & \dots \\ & 1 & -2 & 1 & \dots \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ & & & 1 & -2 & 1 \\ 1 & 0 & \dots & 0 & -1 & -2 \end{bmatrix},$$

os autovalores passam a ter uma parte real:

$$\mu_p = -\frac{ia}{\Delta x} \sin(2\pi p \Delta x) - \frac{2\varepsilon}{h^2}(1 - \cos(2\pi p \Delta x)),$$

caindo dentro da região de estabilidade do método de Euler! Os valores $\Delta t \mu$ estão numa elipse centrada em

$$-2 \frac{\Delta t \varepsilon}{\Delta x^2} = -1,$$

com semieixos de tamanho $2\Delta t \varepsilon / \Delta x^2 = 1$ na direção x e $a \frac{\Delta t}{\Delta x}$ na direção y, sendo estável quando

$$\left| \frac{a \Delta t}{\Delta x} \right| \leq 1.$$

O interessante é que esse tipo de análise não é inédito ao método Lax-Friedrichs, pode ser feito também, por exemplo, no método upwind, entre outros (vide imagem abaixo)




Figura 12: alguns exemplos de $k\mu_p$ para vários valores de ε e métodos.

O problema de adicionar difusão para conseguir estabilidade é que tem algumas consequências não desejáveis, e o resultando numérico começa a ficar disperso, picos podem sumir e a precisão diminui ao descrever o transporte:




Figura 13: o pico começa a sumir por conta da dispersão, e até mesmo passa a ter uma oscilação severa da solução.

Até agora, estivemos usando diferenças finitas para resolver transporte, mas elas precisam de expansões em Taylor, por sua vez precisam de derivadas de ordens cada vez maiores e suavidade de graus maiores, mas nem todo transporte usa etapas contínuas! O **método Lax-Wendroff** é um que existe para problemas descontínuos, mas não é a dedução que vamos fazer aqui porque o foco do curso é justamente a questão das diferenças finitas. Em sua dedução com diferenças finitas, aplica-se a expansão de Taylor diretamente a $u_t + au_x = 0$, resultando em

$$u(x, t + \Delta t) = u(x, t) + \Delta t u_t(x, t) + \frac{1}{2} \Delta t^2 u_{tt}(x, t) + \dots ;$$

trocando $u_t = -au_x$ e $u_{tt} = (-au_x)_t = -a(u_t)_x = a^2 u_{xx}$, obtemos

$$u(x, t + \Delta t) = u(x, t) - \Delta t a u_x(x, t) + \frac{1}{2} \Delta t^2 a^2 u_{xx}(x, t) + \dots$$

Assim, usando a aproximação central padrão para u_x e u_{xx} , abandonando termos

de ordens superiores, obtemos o **método Lax-Wendroff**

$$U_j^{n+1} = U_j^n - a \frac{\Delta t}{2\Delta x} (U_{j+1}^n - U_{j-1}^n) + \frac{a^2 \Delta t^2}{2\Delta x^2} (U_{j+1}^n - 2U_j^n + U_{j-1}^n)$$

Cuidado: apesar do termo da derivada de segunda ordem, a estabilidade do método acima é para a equação $u_t + au_x = 0$, e ela apenas introduz difusão numérica novamente!

Exercício 13. Mostre que o *método de Lax-Wendroff* é um método de precisão quadrática no espaço e no tempo, caracterizando o melhor que vimos até o momento para a equação hiperbólica!

Análise a consistência e estabilidade de todos os métodos da aula de hoje.

Novamente, podemos examinar a região de estabilidade do Lax-Wendroff, com autovalores

$$\Delta t \mu_p = -i \left(\frac{a \Delta t}{\Delta x} \right) \sin(p\pi \Delta x) - \left(\frac{a \Delta t}{\Delta x} \right)^2 (1 - \cos(p\pi \Delta x)),$$

que resulta novamente no número de Courant menor que 1 como critério de estabilidade.

A ideia de introduzir a difusão numérica aos métodos pode também ser aplicada ao upwind, reescrevendo-o como

$$U_j^{n+1} = U_j^n - \frac{a \Delta t}{2\Delta x} (U_{j+1}^n - U_{j-1}^n) + \frac{a \Delta t}{2\Delta x} (U_{j-1}^n - 2U_j^n + U_{j+1}^n),$$

que é a discretização de Euler progressivo para $\underline{U}'(t) = A_\varepsilon U(t)$ com $\varepsilon = a\Delta x/2$, e é tão parecido com o Lax-Wendroff que dá para repetir a análise de estabilidade; no fim, os três métodos, Lax-Wendroff, upwind e Lax-Friedrichs, podem todos ser vistos como a equação $u_t + au_x = \varepsilon u_{xx}$, mas com diferentes ε :

$$\varepsilon_{LW} = \frac{a^2 \Delta t}{2} = \frac{a \Delta x v}{2}, \quad \varepsilon_{UP} = \frac{a \Delta x}{2} \quad \& \quad \varepsilon_{LF} = \frac{\Delta x^2}{2\Delta t} = \frac{a \Delta x}{2v},$$

onde $v = \frac{a \Delta t}{\Delta x}$. Com isso, obtemos as relações

$$\varepsilon_{LW} = v \varepsilon_{UP} \quad \& \quad \varepsilon_{UP} = v \varepsilon_{LF},$$

de modo que se $0 < v < 1$, então $\varepsilon_{LW} < \varepsilon_{UP} < \varepsilon_{LF}$, com os métodos sendo estáveis para qualquer ε entre ε_{LW} e ε_{LF} .

20 Aula 20 - 17 de Junho, 2026

20.1 Motivações

- Domínios de Dependência;
- Condição CFL;
- Characteristics Tracing.

20.2 Domínio de Dependências

A aula de hoje é particularmente importante no entendimento das equações hiperbólicas. Começamos vendo mais um método, conhecido como **método beam-warming**, que tem acurácia de ordem 2 unilateral, obtido de forma parecida ao Lax-Wendroff, mas com aproximações de u_x e u_{xx} em x_j , começando pela mesma discretização, mas usando diferenças regressivas ao discretizar ambos. Se a for positivo,

$$U_j^{n+1} = U_j^n - \frac{a\Delta t}{2\Delta x}(3U_j^n - 4U_{j-1}^n + U_{j-2}^n) + \frac{a^2\Delta t^2}{2\Delta x^2}(U_j^n - 2U_{j-1}^n + U_{j-2}^n)$$

Exercício 14. Deduza o método beam-warming e mostre que ele será estável se $0 < \nu \leq 2$; deduza o mesmo para o caso $a < 0$, mas para $-2 \leq \nu < 0$.

Exercício 15. Faça as análises de Von-Neumann dos métodos da aula passada e do beam-warming.

Para o próximo raciocínio, vamos utilizar como base o *método upwind* discretizado; tomando um ponto $u(x_j, t_n) \approx U_j^n$, queremos que a solução aproxime $u(x_j, t_n)$, e por ser um problema hiperbólica, a informação para isso vem da curva característica que carrega a informação para o ponto desejado, que tem forma

$$u(x_j, n\Delta t) = \eta(x_j - at_n),$$

tal que a solução exata depende apenas do ponto $x_j - at_n$. Logo, fazendo mudanças na condição inicial em qualquer ponto diferente dele **não irá alterar a solução!**; essa é a direção da nossa análise de hoje, o chamado **domínio de dependência da solução exata**: $\mathcal{D}_E(u(x, t))$, que, neste caso, é $\mathcal{D}_E(u(x, t)) = \{x - at\}$, o que significa que, se queremos calcular a solução exata em qualquer ponto, ela dependerá apenas dos pontos no domínio de dependência. Assim, a definição é:

Definição. O **domínio de dependência real** de uma solução exata para uma EDP é o conjunto de todos os pontos iniciais que afetam o valor da solução do método em um ponto (x, t) . Por outro lado, o **domínio de dependência numérico**, $\mathcal{D}_N$, é o conjunto de pontos da malha inicial ou de passos anteriores que afetam o valor aproximado pelo método numérico em (x_j, t_n) $\square$

Se fizermos um refinamento de malha (em Δt e em Δx) e recalcularmos o domínio de dependência, nota-se que ele passa a ficar mais refinado, até que, no limite ao infinito, torna-se um intervalo em torno dos pontos na fronteira (?). Para sistemas hiperbólicos, é possível mostrar que

$$\mathcal{D}_N(U_j^n) = \{x_j - \lambda_p T : p = 1, \dots, s\}.$$

Queremos convergência do método numérico; nessa situação da malha com o domínio de dependência, o método converge quando Δt e Δx vão para zero? Não! O motivo é que, pela forma que o método foi construído, as curvas características e as escolhas de Δt e Δx continuam pegando informação de um ponto fora do domínio de dependência da solução real, então o método nunca enxerga os pontos onde estão as soluções reais. Caso as características estivessem dentro do domínio do método, aí sim a convergência iria depender de estabilidade e consistência, mas se ele já falha em ter as características no domínio numérico, o método já falha:

Teorema (Condição Courant-Friedrichs-Lewy (CFL)). *Um método numérico só pode ser convergente se seu domínio de dependência numérico contém o domínio de dependência real da EDP, pelo menos nos limites Δt e Δx indo a 0.*

Para consertar um problema de domínio de dependência separados, é preciso ajustar a malha, para obter um estêncil que inclua os dois.

Para o método upwind, o domínio de dependência real e numérico para um ponto (x_j, t_n) são, respectivamente,

$$\mathcal{D}_E(u(x_j, t_n)) = \{x_j - at_n\} \quad \& \quad \mathcal{D}_N(U_j^n) = [x_j - n\Delta t, x_j],$$

tal que a [Condição CFL](#) passa a ser

$$\mathcal{D}_E \subseteq \mathcal{D}_N \iff x_j - nh \leq x_j - an\Delta t \leq x_j \iff -n\Delta x \leq -a_n\Delta t \leq 0,$$

que resulta na condição

$$\frac{a\Delta t}{\Delta x} \leq 1.$$

Parece familiar? Deveria, pois é a condição de estabilidade para o método upwind; no entanto, nem todo caso vai ser assim: a condição CFL é uma condição *necessária*, mas não suficiente (um “somente se” do se, e somente se), e a condição de estabilidade caracteriza a estabilidade, que é parte da convergência. Portanto, a **condição CFL NÃO É uma condição de estabilidade!!** Eles até vão coincidir para esses casos lineares e simples, mas nada garante quando saímos deles.


Exemplo 36 (Lax-Wendroff). Como o *Lax-Wendroff* tem um esquema centrado, o domínio de dependência dele forma uma pirâmide:

$$\mathcal{D}(x_j, t_2) = \{x_{j-2}, x_{j-1}, x_j, x_{j+1}, x_{j+2}\}$$

em $n = 2$ e

$$\mathcal{D}(x_j, t_4) = \{x_{j-4}, \dots, x_j, \dots, x_{j+4}\}$$

para $n = 4$.



Exemplo 37 (Beam-warming). No *Beam-warming*, como a cada Δt que é percorrido, $2\Delta x$ são também, o domínio de dependência real estar dentro do numérico dele é justamente que $0 > \nu \geq 2$ (ou sinais invertidos), e a condição a estabilidade dele requer que o número de Courant seja menor ou igual a 2.

Observação

Com o método central que começamos essa seção, ele ilustra um caso onde a *condição CLF* é satisfeita, mas mesmo assim não converge – para ele, a condição CFL é $|a| \frac{\Delta t}{\Delta x} \leq 1$, que é satisfeita.


20.3 Acompanhamento de Características e Interpolação

Vamos dar uma olhada no chamado Acompanhamento de características (*characteristic tracing*), considerando o caso $u(x_j, t_{n+1})$ e que $a \frac{\Delta t}{\Delta x} \leq 1$. Traçar as características de forma retrograda no tempo dentro da malha x_j resulta, para cumprir a

condição CFL, na relação

$$u(x_j, t_{n+1}) = u(x_j - a\Delta t, t_n), \quad x_{j-1} < x_j - a\Delta t < x_j,$$

que é representado pela imagem



Como já sabemos a solução no ponto U_{j-1}^n e em U_j^n , podemos usar um polinômio interpolador para encontrar ela em U_j^{n+1} ; é necessário um polinômio interpolador avaliado em x_j que resulte em um termo com $j - 1$:

$$p(x) = (x - x_{j-1})U_j^n + (x_j - x)U_{j-1}^n$$

Para os termos multiplicando as aproximações ficarem de acordo com as aproximações, precisamos dividir ambos por Δx , resultando em

$$p(x) = \frac{x - x_{j-1}}{\Delta x} U_j^n + \frac{x_j - x}{\Delta x} U_{j-1}^n,$$

e quando x for x_j ou x_{j-1} , apenas um deles irá restar. Este processo é chamado de **interpolação de características**, e aplicando ele ao valor inicial $x_j - a\Delta t$, segue que

$$U_j^{n+1} = p(x_j - a\Delta t) = U_j^n + ((x_j - a) - x_j) \left(\frac{U_j^n - U_{j-1}^n}{\Delta x} \right) = U_j^n - \frac{a\Delta t}{\Delta x} (U_j^n - U_{j-1}^n),$$

tal que a interpolação linear feita entre U_{j-1}^n e U_j^n resultou no *método upwind*! Aproveitamos a informação sobre propagação de informação de características e tentamos aproveitar ela, resultando num dos métodos que havíamos visto antes, mas por outro caminho, dando outra fábrica de métodos para usarmos.

O mesmo processo pode ser usado para obter o *Método de Lax-Wendroff* e *Beam-warming*, com o primeiro usando uma interpolação quadrática entre U_{j-1}^n , U_j^n e U_{j+1}^n , enquanto o segundo usa uma interpolação quadrática de U_{j-2}^n , U_{j-1}^n e U_j^n .

Exercício 16. Deduza os dois métodos mencionado usando interpolação de carac-

terísticas. Deduza, também, o método resultante do polinômio interpolador linear que usa U_{j-1}^n e U_{j+1}^n .

Alguns comentários a parte que valem a pena (talvez apenas 1, dependendo do quanto eu entender) fazer incluem o problema de Riemann, que afeta principalmente os métodos advecção-difusão, pois é caracterizado por uma condição inicial em salto, e a descontinuidade resulta em difusão extrema, que foram os que sobraram pra lidar com dados iniciais com grande variação! O que resta, portanto, é construir métodos melhores, mas construídos de maneira mais sofisticada, principalmente para os casos não lineares – eles introduzem um problema completamente novo e à parte. Por exemplo, uma equação usada bastante nesse tipo de problema é

$$u_t + uu_x = 0,$$

que parece até que simples, mas mesmo que fosse dada uma condição inicial suave, como as características têm inclinação dada pela recíproca da velocidade de transporte, a u em si explode para infinito rapidamente quando chega ao fim da inclinação suave! A solução fica cada vez menos suave, até chegar ao ponto de ficar descontínua, resultando também em cruzamento de características – duas características chegam ao mesmo ponto e torna-se impossível distinguir qual das soluções é a certa. Logo, mesmo com condições iniciais suaves, os problemas lineares ainda ficam descontínuo, e o que significa uma solução descontínua de uma equação que tem derivadas?

Por conta disso, entram os métodos de volumes finitos ou elementos finitos, porque os métodos de diferenças finitas não dão conta desses grandes problemas.

O **polinômio interpolador** é o polinômio de menor grau possível (logo, é único a menos de coeficiente líder) que passe por todos os pontos de um estêncil; em particular, um polinômio

$$p(x) = a_0 + a_1x + \dots + a_nx^n$$

interpola os dados se $p(x_j) = y_j$ para todo j entre 0 e n , com os dados sendo $(x_0, y_0), \dots, (x_n, y_n)$.

A **interpolação de Lagrange** tem forma

$$p(x) = \sum_{i=0}^n \frac{p(x_i)}{p'(x_i)(x - x_i)} y_i,$$

e a **interpolação de Newton** entre um polinômio p_n de grau até n interpolado com um função f em pontos x_i , $i = 0, 1, \dots, n$ é dada por

$$p_{n+1}(x) = p_n(x) + a_{n+1} \prod_{i=0}^n (x - x_i),$$

onde, usando a notação $w_n(x) := \prod_{i=0}^n (x - x_i)$ para a chamada **base de Newton**, o termo a_{n+1} tem forma

$$a_{n+1} := \frac{f(x_{n+1}) - p_n(x_{n+1})}{w_n(x_{n+1})},$$

21 Aula 21 - 22 de Junho, 2026

21.1 Motivações

- Equações da onda.

21.2 Equação da Onda

Consideremos a equação da onda

$$u_{tt} - c^2 u_{xx} = 0, \quad x \in [0, 1],$$

com condições iniciais

$$u(x, 0) = f(x), \quad u_t(x, 0) = g(x)$$

e fronteiras

$$u(0, t) = h_1(t), \quad u(1, t) = h_2(t).$$

Vamos definir $v = cu_x$ e $w = -u_t$; assim, obtemos as equações

$$v_t = cu_{tt}, \quad v_x = cu_{xx}, \quad w_x = -u_{tt} \text{ \& } w_t = -u_{tt},$$

ou seja, obtivemos o sistema acoplado

$$\begin{cases} v_t + cw_x = 0 \\ w_t + cv_x = 0 \\ v(x, 0) = cu_x(x, 0) = cf'(x) \\ w(x, 0) = -u_t(x, 0) = -g(x) \end{cases}$$

que, em forma de matriz, assume

$$\frac{\partial}{\partial t} \begin{bmatrix} v \\ w \end{bmatrix} + \frac{\partial}{\partial x} \begin{bmatrix} 0 & c \\ c & 0 \end{bmatrix} \begin{bmatrix} v \\ w \end{bmatrix} = 0, \quad \underline{u}(x, 0) = \begin{bmatrix} cf'(x) \\ -g(x) \end{bmatrix},$$

e chegamos na equação

$$\underline{u}_t + A\underline{u}_x = 0.$$

Agora, diagonalizamos A por meio dos seus autovalores e autovetores para desacoplar o sistema:

$$\det(A - \lambda I) = 0 \Rightarrow \det \begin{bmatrix} -\lambda & c & c \\ c & -\lambda & c \\ c & c & -\lambda \end{bmatrix} = 0 \Rightarrow \lambda^2 - c^2 = 0 \Rightarrow \lambda_1 = -c, \lambda_2 = c.$$

Os autovetores, por sua vez, são

$$\begin{cases} A\underline{v}^1 = -c\underline{v}^1 \\ A\underline{v}^2 = c\underline{v}^2 \end{cases} \Rightarrow \underline{v}^1 = \begin{bmatrix} -1 \\ 1 \end{bmatrix} \quad \& \quad \underline{v}^2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Sendo assim, colocando

$$R = \begin{bmatrix} -1 & 1 \\ 1 & 1 \end{bmatrix} \Rightarrow R^{-1} = \begin{bmatrix} -\frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{bmatrix}, \quad \Lambda = \begin{bmatrix} -c & 0 \\ 0 & c \end{bmatrix},$$

obtemos a diagonalização de A como $A = R\Lambda R^{-1}$. Na equação diferencial, obtemos

$$\underline{u}_t + A\underline{u}_x = 0 \Rightarrow \underline{u}_t + R\Lambda R^{-1}\underline{u}_x = 0 \Rightarrow R^{-1}\underline{u}_t + \Lambda R^{-1}\underline{u}_x = 0,$$

tal que, colocando $\underline{w} := R^{-1}\underline{u}$ com coordenadas w_1 e w_2 , a equação torna-se

$$\underline{w}_t + \Lambda \underline{w}_x = 0 \Rightarrow \begin{cases} \frac{\partial}{\partial t} w_1 - c \frac{\partial}{\partial x} w_1 = 0 \\ \frac{\partial}{\partial t} w_2 + c \frac{\partial}{\partial x} w_2 = 0 \end{cases}$$

Pra que todo esse esforço? Pois estes w_1 e w_2 desacoplados podem ser vistos como ondas fundamentais da solução, e são duas equações de transporte com sinais opostos: a primeira transporta a onda w_1 para a esquerda, e a outra transporta a w_2 para a direita – a solução da onda nada mais é do que duas soluções da equação do transporte! Uma delas gera características indo pra esquerda, a outra gera pra direita, sem que haja sobreposição de informações!

Construir a solução exata dessa equação se dá por um processo semelhante ao das equações dos transportes: considerando cada uma isolada, sabemos que a solução se dá pela condição inicial, ou seja,

$$w_1(x, t) = w_1(x + ct, 0) \quad \& \quad w_2(x, t) = w_2(x - ct, 0),$$

mas isso requer que as condições iniciais do sistema que usamos no começo também passem pelas transformações aplicadas (depois de resolver, pode reverter as transformações pelas inversas).

Finalmente, podemos estimar a solução numérica dos sistemas acoplado (Sis-

tema 1) e desacoplado (Sistema 2); este segundo, por ser só duas equações do transporte, já temos uma boa noção do que fazer – por exemplo, podemos aplicar Lax-Friedrichs, utilizando as notações

$$w_1(x_j, t_n) \cong W_1 \Big|_j^n \quad \& \quad w_2(x_j, t_n) \cong W_2 \Big|_j^n$$

para obter

$$W_1 \Big|_j^{n+1} = \frac{1}{2} (W_1 \Big|_{j+1}^n + W_1 \Big|_{j-1}^n) - (-c) \frac{\Delta t}{2\Delta x} (W_1 \Big|_{j+1}^n - W_1 \Big|_{j-1}^n)$$

e

$$W_2 \Big|_j^{n+1} = \frac{1}{2} (W_2 \Big|_{j+1}^n + W_2 \Big|_{j-1}^n) - (-c) \frac{\Delta t}{2\Delta x} (W_2 \Big|_{j+1}^n - W_2 \Big|_{j-1}^n),$$

com forma matricial

$$\begin{bmatrix} W_1 \Big|_j^{n+1} \\ W_2 \Big|_j^{n+1} \end{bmatrix} = \frac{1}{2} \left(\begin{bmatrix} W_1 \Big|_{j+1}^n \\ W_2 \Big|_{j+1}^n \end{bmatrix} + \begin{bmatrix} W_1 \Big|_{j-1}^n \\ W_2 \Big|_{j-1}^n \end{bmatrix} \right) - \Lambda \frac{\Delta t}{2\Delta x} \left(\begin{bmatrix} W_1 \Big|_{j+1}^n \\ W_2 \Big|_{j+1}^n \end{bmatrix} - \begin{bmatrix} W_1 \Big|_{j-1}^n \\ W_2 \Big|_{j-1}^n \end{bmatrix} \right),$$

ou, equivalentemente,

$$\underline{W}_j^{n+1} = \frac{1}{2} (\underline{W}_{j+1}^n + \underline{W}_{j-1}^n) - \Lambda \frac{\Delta t}{2\Delta x} (\underline{W}_{j+1}^n - \underline{W}_{j-1}^n),$$

que podemos multiplicar por R para chegar em

$$\begin{aligned} R \underline{W}_j^{n+1} &= \frac{1}{2} R (\underline{W}_{j+1}^n + \underline{W}_{j-1}^n) - R \Lambda \frac{\Delta t}{2\Delta x} (\underline{W}_{j+1}^n - \underline{W}_{j-1}^n) \\ \iff R R^{-1} \underline{W}_j^{n+1} &= \frac{1}{2} R R^{-1} (\underline{W}_{j+1}^n + \underline{W}_{j-1}^n) - R R^{-1} \Lambda \frac{\Delta t}{2\Delta x} (\underline{W}_{j+1}^n - \underline{W}_{j-1}^n) \\ \iff \underline{U}_j^{n+1} &= \frac{1}{2} (\underline{U}_{j+1}^n + \underline{U}_{j-1}^n) - A \frac{\Delta t}{2\Delta x} (\underline{U}_{j+1}^n - \underline{U}_{j-1}^n) \end{aligned}$$

Com $\underline{U}_j^n = \begin{bmatrix} V_j^n \\ W_j^n \end{bmatrix}$, recuperamos o *Lax-Friedrichs* de antes, com a única diferença de que o escalar “a” multiplicando tornou-se uma matriz “A”! Similarmente, o *Lax-Wandroff* assume a forma

$$\underline{U}_j^{n+1} = \underline{U}_j^n - \frac{\Delta t}{2\Delta x} A (\underline{U}_{j+1}^n - \underline{U}_{j-1}^n) + \frac{\Delta t^2}{2\Delta x^2} A^2 (\underline{U}_{j+1}^n - 2\underline{U}_j^n + \underline{U}_{j-1}^n)$$

e o *upwind* também, mas com uma pequena mudança de que a aproximação pra w_1 e w_2 têm sinais opostos, então separamos a matriz em uma só para a parte positiva

e outra só para a parte negativa:

$$\Lambda = \begin{bmatrix} -c & 0 \\ 0 & c \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & c \end{bmatrix} + \begin{bmatrix} -c & 0 \\ 0 & 0 \end{bmatrix} =: \Lambda^+ + \Lambda^-,$$

forneendo a aproximação para $\underline{W}_j^{n+1}$ na forma

$$\underline{W}_j^{n+1} = \underline{W}_j^n - \frac{\Delta t}{\Delta x} \Lambda^+ (\underline{W}_j^n - \underline{W}_{j-1}^n) - \frac{\Delta t}{\Delta x} \Lambda^- (\underline{W}_{j+1}^n - \underline{W}_j^n).$$

Exercício 17. Faça a transformação que fizemos previamente para obter a forma do sistema acoplado, com $A^+ := R\Lambda^+R^{-1}$ e $A^- := R\Lambda^-R^{-1}$.

Existe um método mais direto para resolver, partindo da mesma equação definida no começo,

$$u_{tt} - c^2 u_{xx} = 0, \quad x \in [0, 1],$$

com condições iniciais

$$u(x, 0) = f(x), \quad u_t(x, 0) = g(x)$$

e contorno

$$u(0, t) = h_1(t), \quad u(1, t) = h_2(t).$$

Dessa vez, faremos a estratégia de discretizar em x e em t com 2 passos e níveis (a discretização em cruz), com todo aquele processo que já conhecemos de avaliar em (x_j, t_n) , substituir a derivada, descartar o erro de truncamento, etc, resultando em

$$\frac{1}{\Delta t^2} (U_j^{n+1} - 2U_j^n + U_j^{n-1}) - c^2 \frac{1}{\Delta x^2} (U_{j+1}^n - 2U_j^n + U_{j-1}^n) = 0.$$

Reescrevendo ela, com $\sigma^2 := c^2 \frac{\Delta t^2}{\Delta x^2}$, chegamos em

$$U_j^{n+1} = -U_j^{n-1} + \sigma^2 U_{j-1}^n + (2 - 2\sigma^2) U_j^n + \sigma^2 U_{j+1}^n,$$

que normalmente cairia na questão de ter um problema no limite de tempo mais no passado ou mais no futuro, mas podemos nos aproveitar da condição $u_t(x, 0) = g(x)$ para lidar com isso: quando $n = 0$, a equação seria

$$U_j^1 = -U_j^{-1} + \sigma^2 U_{j-1}^0 + (2 - 2\sigma^2) U_j^0 + \sigma^2 U_{j+1}^0;$$

todos os termos U^0 são da forma $f(x_j)$ pela condição inicial, enquanto que o $-U_j^{-1}$

pode ser lidado com utilizando a derivada:

$$U_t(x_j, 0) = g(x_j) \Rightarrow \frac{U_j^1 - U_j^{-1}}{2\Delta t} = g(x_j) \Rightarrow U_j^{-1} = U_j^1 - 2\Delta t g(x_j),$$

a partir do qual basta substituir na equação original:

$$\begin{aligned} U_j^1 &= -U_j^1 + 2\Delta t g(x_j) + \sigma^2 U_{j-1}^0 + (2 - 2\sigma^2) U_j^0 + \sigma^2 U_{j+1}^0 \\ \Rightarrow 2U_j^1 &= 2\Delta t g(x_j) + \sigma^2 U_{j-1}^0 + (2 - 2\sigma^2) U_j^0 + \sigma^2 U_{j+1}^0 \end{aligned}$$

Agora, fica a grande pergunta – este método funciona? Descubra!

Exercício 18. Analise a convergência do método: compute o erro de truncamento, mostre que a consistência dele é da ordem $\mathcal{O}(\Delta t^2 + \Delta x^2)$ e que a estabilidade dele por Von Neumann é dada pela condição $|c| \frac{\Delta t}{\Delta x} \leq 1$

Surpreendentemente, o método de diferenças centrais funciona bem aqui, mesmo sendo horrível para a equação do transporte! Moral da história: se for propor um método diferente, tem que analisar ele pra ver se vai funcionar ou não, independente do que você ache que vá acontecer.

Um último comentário é da questão da condição CFL, que mantém-se na forma $\frac{|c|\Delta t}{\Delta x} \leq 1$, e a condição é satisfeita para que haja a convergência.

22 Aula 22 - 24 de Junho, 2026

22.1 Motivações

- Equação da Onda;
- Equações não Lineares.

22.2 Estabilidade da Equação da Onda

Vamos considerar a equação

$$u_{tt} + c^2 u_{xx} = 0,$$

com condições iniciais e de contorno como antes e $\sigma = c \frac{\Delta t}{\Delta x}$. Na análise de Estabilidade Von-Neumann, escrevemos

$$U_j^n = e^{i\beta j} \quad \& \quad U_j^{n+1} = \zeta U_j^n,$$

além de podermos escrever até o passo anterior em termos de U_j^n :

$$\zeta U_j^{n-1} = U_j^n \Rightarrow U_j^{n-1} = \zeta^{-1} U_j^n;$$

usaremos isso para analisar quando que $|\zeta| \leq 1$, garantindo a estabilidade.

Discretizando a equação da onda e usando a relação acima, segue que

$$\begin{aligned} U_j^{n+1} &= U_j^{n-1} + \sigma^2 U_{j-1}^n + (2 - 2\sigma^2) U_j^n + \sigma^2 U_{j+1}^n \zeta e^{i\beta j} \\ &= -\zeta^{-1} e^{i\beta j} + \sigma^2 e^{i\beta(j-1)} + (2 - 2\sigma^2) e^{i\beta j} + \sigma^2 e^{i\beta(j+1)}. \end{aligned}$$

Isolando os termos com ζ obtemos

$$\begin{aligned} \zeta + \zeta^{-1} &= \sigma^2 e^{-i\beta} + (2 - 2\sigma^2) + \sigma^2 e^{i\beta} \\ &\stackrel{\times \zeta}{\Rightarrow} \zeta^2 + 1 - \zeta(2\sigma^2 \cos \beta + 2 - 2\sigma^2) = 0 \\ &\Rightarrow \zeta^2 - \zeta[2\sigma^2 \cos \beta + 2 - 2\sigma^2] + 1 = 0. \end{aligned}$$

Assim, aplicando a identidade

$$\cos \beta = \cos \left(\frac{\beta}{2} + \frac{\beta}{2} \right) = \cos^2 \frac{\beta}{2} - \sin^2 \frac{\beta}{2} = 1 - 2 \sin^2 \frac{\beta}{2},$$

o termo em colchetes pode ser escrito como

$$\underbrace{2\sigma^2 - 4\sigma^2 \sin^2 \frac{\beta}{2}}_{\alpha} + 2 - 2\sigma^2,$$

permitindo tratarmos a equação de antes como uma quadrática em ζ , e colocando $b = \alpha - 2$, seu discriminante é

$$\Delta = \sqrt{(\alpha - 2)^2 - 2} = \sqrt{\alpha(\alpha - 4)},$$

e suas raízes são

$$\zeta_{1,2} = \frac{-(\alpha - 2) \pm \sqrt{\alpha(\alpha - 4)}}{2}.$$

Caso $\alpha > 4$: quando α é maior que quatro, temos

$$|\zeta_1| \leq 1 \iff -2 \leq -(\alpha - 2) + \sqrt{\alpha(\alpha - 4)} \leq 2 \Rightarrow -2 + \alpha - 2 \leq \sqrt{\alpha(\alpha - 4)} \leq 2 + \alpha - 2,$$

ou seja,

$$\alpha - 4 \leq \sqrt{\alpha(\alpha - 4)} \leq \alpha,$$

que é basicamente a expressão

$$p^2 \leq pq \leq q^2$$

com $p = \alpha - 4$ e $q = \alpha$. Logo, a primeira raiz satisfaz a condição de estabilidade.

A segunda, por sua vez, cai no caso da desigualdade

$$\underbrace{\alpha - 4}_{>0} \leq \underbrace{-\sqrt{\alpha(\alpha - 4)}}_{<0} \leq \underbrace{\alpha}_{>0},$$

que é um absurdo, mostrando que α tal que $|\zeta_2| < 1$ não existe

Caso $\alpha < 4$: neste caso, $0 > \Delta = \sqrt{\alpha(\alpha - 4)} = i\sqrt{\alpha(4 - \alpha)}$; daí,

$$|\zeta|^2 = \frac{(\alpha - 2)^2}{4} + \frac{(\sqrt{\alpha(4 - \alpha)})^2}{4} = 1$$

para qualquer uma das raízes. Consequentemente, as raízes sempre têm módulo menor ou igual a 1.

Exercício 19. Analise a estabilidade para $\alpha = 4$.

A análise de Von-Neumann mostra que $\alpha \leq 4$ garante a estabilidade do

método, mas $\alpha > 4$ quebra isso. Retomando quem era α , a condição equivale a

$$4\sigma^2 \sin^2 \frac{\beta}{2} \leq 4 \Rightarrow \sigma^2 \leq 1 \Rightarrow |c| \frac{\Delta t}{\Delta x} \leq 1.$$

22.3 Uma Breve Menção dos Problemas não Lineares

Conforme a pessoa se aprofunda mais em métodos numéricos para equações diferenciais, ela se depara eventualmente com as chamadas **leis de conservação**, que permitem inclusive reescrever todo o conteúdo apresentado em termos delas, mas trazem a grande vantagem de permitirem lidar com o caso não linear! A segunda forma de lidar com eles, e provavelmente a principal, é o **esquema de volumes finitos** (Ver o livro do Mishra![4]). Considerando um domínio genérico Ω limitado por $\partial\Omega$, podemos dizer que a variação temporal de alguma propriedade em Ω é balanceada pelo fluxo na fronteira e o que está sendo criado ou destruído dentro dele (Teorema da Divergência):

$$\underbrace{\frac{d}{dt} \int_{\omega} U dx}_{\text{variação temporal da quantidade total de U em } \Omega} + \underbrace{\int_{\omega} \text{div}(F) dx}_{\text{fluxo de conteúdo escoando na fronteira}} = \underbrace{\int_{\omega} S dx}_{\text{fonte de criação ou destruição de algo}}$$

para todo subdomínio genérico ω de Ω , e podemos escolher um ω infinitesimal para obter a chamada **Lei de Balanço**

$$\underline{U}_t + \text{div}(\underline{F}) = S.$$

Quanto a fonte vale 0, ou seja, quando $S = 0$, então temos uma **lei de conservação**

$$\underline{U}_t + \text{div}(\underline{F}) = 0.$$

Exemplo 38 (Equação de Transporte Linear). Se a equação for $F = au$ e u for um escalar, a lei de balanço fornece

$$U_t + aU_x = 0,$$

que é exatamente a equação do transporte linear

Exemplo 39 (Equação do Calor). Usando a Lei de Fick-Fourier, que dita

$$\underline{F}(\underline{U}) = -k\nabla U,$$

e substituindo na equação do balanço, temos

$$U_t + U_{xx} = 0,$$

que é a equação do calor.

Quando a equação fica não-linear, por exemplo quando tomamos $a = u$ na equação do transporte:

$$u_t + uu_x = 0,$$

temos que definir uma função de fluxo para reescrever a equação acima; neste caso, $f(u) = \frac{u^2}{2}$ dá

$$u_t + f(u)_x = u_t + f'(u)u_x = u_t + uu_x = 0.$$

A equação acima é chamada **equação de Burgers**, e ela mostra um problema sério com a solução! Basta considerar que, considerando uma condição inicial U_0 suave com pelo menos um ponto onde $U'_0(x) = 0$; então, independentemente da suavidade da condição inicial, a equação de Burgers irá desenvolver uma descontinuidade em

$$t_{min} = -\frac{1}{\min_{x \in \mathbb{R}} U'_0(x)},$$

causando até mesmo o cruzamento de múltiplas curvas características mencionado anteriormente, tornando impossível encontrar qual é a solução! Essa descontinuidade leva o nome de **choque**, que ocorre, por exemplo, quando o escoamento do ar em torno do avião (modelado por uma equação hiperbólica) tem a frente de pressão rompida e ocorre a quebra da barreira do som.

Se a continuação inicial for composta por duas partes uniformes desconectadas, como uma função salto, o ponto de transição entre elas (a linha reta conectando o fim da linha 0 e o começo da linha 1) causa outra descontinuidade do tipo **rarefação**, e tanto o choque quanto a rarefação aparecem na equação de Burgers. Logo, precisamos dar algum sentido a estes problemas, e isso é feito olhando a “solução fraca” do problema: considere a lei de conservação $u_t + f(u)_x = 0$; multiplicaremos isso por uma função-teste $\varphi \in C_c^1(\mathbb{R} \times \mathbb{R}_+)$ e integrar no domínio:

$$\int_{\mathbb{R}_+} \int_{\mathbb{R}} \varphi u_t + \varphi f(u)_x dx dt = 0,$$

que podemos fazer por partes, e essa é a tática desejada (pelo menos nesse caso),

pois muda a derivada para a φ ao invés da u :

$$\int_{\mathbb{R}_+} \int_{\mathbb{R}} u \varphi_t + f(u) \varphi_x dx dt + \int_{\mathbb{R}} u_0(x) \varphi(x, 0) dx = 0$$

mudando o espaço das soluções para todas as que satisfazem a relação acima ao invés da equação inicial. Um resultado particularmente importante é que

Proposição. *Se U for uma solução fraca do problema acima e ela for diferenciável, então ela satisfaz a equação diferencial pontualmente.*

Definição. Uma função $U \in L^\infty(\mathbb{R} \times \mathbb{R}_+)$ é uma **solução fraca** da equação diferencial se, para toda função teste $\varphi \in C_c^1(\mathbb{R} \times \mathbb{R}_+)$, ela satisfaz

$$\int_{\mathbb{R}_+} \int_{\mathbb{R}} u \varphi_t + f(u) \varphi_x dx dt + \int_{\mathbb{R}} u_0(x) \varphi(x, 0) dx = 0. \quad \square$$

É possível mostrar que, se a solução vier sempre da esquerda, ela resolve a equação; mas, se ela vier sempre da direita, também resolve! Há um problema com a unicidade da solução. Para isso, é necessário introduzir um conceito de *entropia* como uma noção de restringir a solução para a forma que funciona na natureza. Por exemplo, se tivéssemos parabolizado a equação, teríamos uma solução única para

$$u_t + f(u)_x = \varepsilon u_{xx},$$

e uma solução da equação não linear seria

$$u = \lim_{\varepsilon \rightarrow 0} u^\varepsilon,$$

tal que, com a entropia, dá pra provar que essa é a única solução certa naturalmente, e consiste nas médias das soluções que vêm pela esquerda e pela direita.

Definição. Sejam U uma solução fraca de $u_t + f(u)_x = 0$ e U_l , U_r os valores de choque e rarefação com uma certa velocidade s . Diremos que a solução satisfaz a **condição de entropia de Oleinik** se:

i) Para todo k entre U_l e U_r , vale

$$\frac{f(U_r) - f(k)}{U_r - k} \leq s \leq \frac{f(U_l) - f(k)}{U_l - k};$$

ii) Se $U_r > U_l$, então

$$f(\alpha U_l + (1 - \alpha)U_r) \geq \alpha f(U_l) + (1 - \alpha)f(U_r), \quad \forall \alpha \in [0, 1]; \text{ e}$$

iii) Se $u_r < U_l$, então

$$f(\alpha U_l + (1 - \alpha)U_r) \leq \alpha f(U_l) + (1 - \alpha)f(U_r), \quad \forall \alpha \in [0, 1]. \quad \square$$

Agora, quanto à resolução numérica disso tudo, alteramos o paradigma de aproximação trabalhando com conjuntos $C_j = [x_{j-1/2}, x_{j+1/2}]$, onde houve uma discretização do espaço $[x_L, x_R]$ por pontos denotados como

$$x_j = x_L + (j + 1/2)\Delta x, \quad j = 0, \dots, m, \quad \Delta x = \frac{x_R - x_L}{m + 1}.$$

Com isso, a aproximação numérica será a média formal nos C_j :

$$U_j^n \approx \frac{1}{\Delta x} \int_{C_j} U(x, t^n) dx.$$

Essa é a base do **método dos volumes finitos**, com o objetivo de atualizar a média de cada célula da malha e da parte desconhecida a cada passo no tempo, começando em

$$U_j^0 = \frac{1}{\Delta x} \int_{x_{j-1/2}}^{x_{j+1/2}} U_0(x) dx.$$

Assim, podemos escrever a lei de conservação numa forma integral com

$$\int_{t_n}^{t_{n+1}} \int_{x_{j-1/2}}^{x_{j+1/2}} u_t(x, t) dx dt + \int_{t_n}^{t_{n+1}} \int_{x_{j-1/2}}^{x_{j+1/2}} f(u)_x dx dt = 0,$$

e, pelo Teorema Fundamental do Cálculo, isso dá

$$\int_{x_{j-1/2}}^{x_{j+1/2}} u(x, t_{n+1}) - u(x, t_n) dx + \int_{t_n}^{t_{n+1}} f(u(x_{j+1/2}, t)) - f(u(x_{j-1/2}, t)) dt = 0.$$

Para aparecer o U_j^n , multiplicamos tudo por $\frac{1}{\Delta x}$, dando origem à relação

$$\frac{1}{\Delta x} \int_{x_{j-1/2}}^{x_{j+1/2}} u(x, t_{n+1}) - u(x, t_n) dx = -\frac{1}{\Delta x} \int_{t_n}^{t_{n+1}} f(u(x_{j+1/2}, t)) - f(u(x_{j-1/2}, t)) dt,$$

ou seja,

$$U_j^{n+1} - U_j^n = -\frac{1}{\Delta x} \int_{t_n}^{t_{n+1}} f(u(x_{j+1/2}, t)) dt + \frac{1}{\Delta x} \int_{t_n}^{t_{n+1}} f(u(x_{j-1/2}, t)) dt.$$

Definimos uma função $\bar{F}_{j+1/2}^n$ como a média temporal da função de fluxo:

$$\bar{F}_{j+1/2}^n = \frac{1}{\Delta t} \int_{t_n}^{t_{n+1}} f(U(x_{j+1/2}, t)) dt,$$

que pode ser substituída na relação encontrada anteriormente para dar a **forma fundamental dos métodos de volume finito**:

$$U_j^{n+1} = U_j^n - \frac{\Delta t}{\Delta x} (\bar{F}_{j+1/2}^n - \bar{F}_{j-1/2}^n)$$

Até agora, não houve nenhuma aproximação, mas elas surgem agora para tornar o método interpretável, trocando $F_{j+1/2}^n \approx \bar{F}_{j+1/2}^n$.

A equação acima age como uma fábrica de métodos de volumes finitos, e um deles é devido a Godunov, que notou a presença, em cada célula, de um problema do tipo Riemann, que as pessoas já sabem resolver; disso, bastou resolverem o problema de Riemann em cada passo:

$$\begin{cases} U_t + f(U)_x = 0 \\ U(x, t^n) = \begin{cases} U_j^n, & x < x_{j+1/2} \\ U_{j+1}^n, & x > x_{j+1/2} \end{cases} \end{cases}$$

A cada passo Δt , o problema de Riemann é definido e resolvido, que é a essência do método de Godunov. Uma de suas limitações é que pode ocorrer das características se cruzarem dentro de uma célula, mas dá pra contornar isso impondo uma condição CFL do tipo

$$\max_j |f'(U_j^n)| \frac{\Delta t}{\Delta x} \leq \frac{1}{2}.$$

A grande maioria dos métodos usados nesses contextos são chamado de **solucionadores de Riemann aproximados**, justamente porque eles não tentam resolver os problemas Riemann de maneira exata quando necessário, mas sim aproximar a solução deles, por exemplo pedindo que $F_{j+1/2}^n = \frac{1}{2}(U_{j+1} + U_j)$, que, sendo substituída na fábrica de métodos, fornece o método de diferenças centrais, mas ele não estável, então essa função de fluxo não serve. Outra ideia é linearizar localmente a função de fluxo não linear a cada passo, conhecido como **método Roe**, resultando

em

$$F_{j+1/2}^n = F^{\text{Roe}}(U_j^n, U_{j+1}^n) = \begin{cases} f(U_j^n), & \hat{A}_{j+1/2} \geq 0 \\ f(U_{j+1}^n), & \hat{A}_{j+1/2} < 0, \end{cases}$$

onde

$$\hat{A}_{j+1/2} = \begin{cases} \frac{f(U_{j+1}^n) - f(U_j^n)}{U_{j+1}^n - U_j^n}, & U_{j+1}^n \neq U_j^n \\ f'(U_j^n), & U_{j+1}^n = U_j^n \end{cases},$$

é basicamente o método upwind!

É possível definir versões do Lax-Friedrichs, esquemas centrais, e todo o resto pensando em diferentes escolhas de fluxos para aproximar; Lax-Friedrichs, no caso, tem

$$F_{j+1/2}^n = \frac{f(U_j^n) + f(U_{j+1}^n)}{2} - \frac{\Delta x}{2\Delta t}(U_{j+1}^n - U_j^n),$$

mas obviamente tem métodos novos também.

Referências

- [1] Burden, R. L.; Faires, J. D. **Análise Numérica**, Cengage.
- [2] Cuminato, J. A.; Jr Meneguette, M. **Discretização de Equações Diferenciais Parciais**, SBM, 2013
- [3] LeVeque, R. J. **Finite Difference Methods for Ordinary and Partial Differential Equations**, SIAM, 2006.
- [4] MISHRA, Siddhartha. Numerical methods for conservation laws and related equations. [S. l.]: ETH Zürich, 2010. Disponível em: <https://web.iitd.ac.in/~vvksrini/Oldhomepage/smishra.pdf>.